预算约束下电商营销策略的因果评估与增量利润优化

Lrvin

liliw@126.com

2026 年 10 月 24 日

数据来源：合成数据 / 已知 DGP（非真实企业数据）

摘　要

电商营销长期以转化率为目标。该指标无法区分真实增量、利润侵蚀与需求提前，也支撑不了“是否发券、发给谁、发多大面额”的组合决策。本文构建微观机制已知的分层模拟器（L0–L3），以每位合格用户的净增量贡献利润为首要指标、转化率为共同主指标，在预算与风险约束下评估营销策略的因果效应与策略价值。模拟器的真值由解析式给出，策略学习与评估使用不相交用户。方法包括随机实验（样本量双指标、AA 与 SRM 校验、ITT、护栏非劣效与 Holm 校正）、观察性识别（朴素差分、PSM、IPW、DR 随未观测混淆强度 λ 扫描，每格重复 100 次并给 Clopper–Pearson 区间）与预算约束优化（0-1 背包、线性松弛上界）。20 万用户、重复 200 次的结果是：ITT 偏差 +0.002 元/人，覆盖率 0.950；定向发券人均增量利润 0.349 元（95% CI 0.318–0.384），为随机发券 0.122 元（200 个种子）的 2.9 倍，每元回报 2.08 元（95% CI 1.91–2.29），占真值贪心解 86%（95% CI 82%–91%）。边界结论：样本量约束者可以不是主指标，翻转临界 0.36 元/人；护栏检验功效仅 0.198，非劣效通过只说明未能检出恶化；轻度混淆（$\lambda = 0.25$）下 IPW/DR 覆盖率跌至 0.82/0.79，而标准化均值差全部低于 0.004，平衡性诊断全绿时观察性估计仍可能失效。贪心另有一处边界：全规模下与松弛上界几乎重合（99.9999%），3 件大额件的反例中损失 33%。结果基于合成数据与已知 DGP，结论只在给定生成机制内成立。

关键词：因果推断；增量利润；异质性处理效应；预算约束优化；模拟验证

目录

1 引言 3

2 研究方法 4

3 结果 6

4 讨论 11

5 结论 13

参考文献 13

附录 A 关键参数表 14

附录 B 复现方式与可复现性等级 14

附录 C 数据字典与 SQL 对象清单 15

1 引言

1.1 研究背景

某电商平台“加购未支付”用户的首单转化率约 10%，运营侧持有固定预算，要决定是否发券、发给谁、发多大面额。转化率与 GMV 无法区分三种机制：真实增量、利润侵蚀与需求提前。真实增量下转化与利润同升；利润侵蚀下本会购买的用户多领了券，转化升而利润降；需求提前则是窗内升、长期为零。利润侵蚀的个体效应为负，转化率完全反映不出来。以转化率为核心的目标因此会高估营销价值[10]。行业 A/B 测试实践也把“把点击或转化当作唯一目标”列为实验平台最常见的失效模式之一[10]。

1.2 问题提出

由此产生三个问题。把目标换成净增量贡献利润后，“该不该发券”还能不能被无偏地回答，估计量是否有偏、区间是否校准。随机化不可行、只能使用观察数据时，常见调整方法在多大的混淆强度下开始失效，失效是渐变还是断崖，能否给出可操作的阈值。定向投放比随机发送多创造多少价值，离理论最优还差多远。最后一个差距必须能量化，否则“精准营销”只是一句口号。

1.3 研究目的与意义

方法上，模拟器的真值已知，偏差因此从不可观测量变成可核对的量。真值只取自数据生成过程的解析式；策略学习与评估使用不相交的用户；结论写成条件式[12]。实践上要回答的是一个可执行的问题：给定预算与风险护栏，定向发券的每元回报是多少，落在多大概率区间内，在什么条件下失效。表 1 对照“深度”的四个维度与三个信号。

表 1　“深度”的四个维度、三个信号与本文的响应

条目	判据	本文的响应
维度 • 业务背景	有明确的问题与约束	加购未支付用户；$B = 10{,}042$ 元、护栏 0.5pp、7/30 天双窗口、面额 5∼20 元
维度 • 分析链路	洞察 → 策略 → 评估 → 迭代	口径 →DGP→ 实验 → 异质性 → 观察性 → 优化 → 四指标 → 决策（图 1）
维度 • 可量化价值	结论可翻译为业务语言	每元回报 2.08 元（95% CI 1.91–2.29）、占真值贪心解 86%（82%–91%）、覆盖 15,985 人
维度 • 思维深度	说清为什么选、trade-off、边界	三学习器的代价、贪心与背包的边界、观察性阈值（§3.5）
信号 • 增量利润	目标不是“提升转化率”	$\tau_\Pi(X) = \mathbb{E}[\Pi(1) - \Pi(0) \mid X]$；分解出 GMV 中被券吃掉的部分（图 4b）
信号 • 真值对照	不只报一个提升百分比	已知 DGP 解析真值；六个 ITT 区间与逐用户 CATE 对真值评估（表 4、图 5）
信号 • 独立测试集	训练与评估分离、四指标并列	按用户切分 10/4/6 万；RMSE、排序、策略价值、regret 并列（表 5）

1.4 研究问题与假设

- RQ1：在同样的用户与预算下，以净增量贡献利润为目标的定向策略，每元回报能否显著超过 1（即“发券赚钱”），并显著超过随机发券？
- RQ2：观察性调整（PSM、IPW、DR）在什么混淆强度下失去校准能力，失效能否用区间而非点估计判定？
- RQ3：预测精度（RMSE）、排序质量与策略价值三者能否互相替代？
- H1：利润是高度零膨胀的重尾变量，方差不足以让它成为样本量的约束者，主指标与样本量约束指标会分离。
- H2：可观测特征被完全平衡并不保证无偏，覆盖率会比偏差更早崩塌。
- H3：策略只依赖 τ 的符号与排序，RMSE 的差距不会等比例转化为策略价值的差距。



图 1 技术路线：从业务问题到决策建议的八个环节

1.5 论文结构安排

研究按“设计、估计、评估、决策”四步推进。先确定研究对象与口径，再在分层模拟器中估计因果效应，随后比较策略价值，最后讨论边界与局限。附录给出关键参数、复现说明与数据字典。

2 研究方法

2.1 研究对象

研究对象是某电商平台“加购未支付”的 20 万名合格用户。分析单位是随机分配，每名用户一次。未下单用户的净贡献利润记为 0，仍留在分母中。单用户净贡献利润的定义为式 (1)：

$$\Pi_i^{\text{net}} = R_i - G_i - F_i - C_i - H_i \tag{1}$$

括号内依次是收入、商品成本、履约成本、券成本与退款手续费。退款单的四项分别处理：收入冲减为 0，并加收 1% 通道费；商品成本按 85% 的可回收率冲减；履约成本刚性，不回收；券默认不退，成本保留。

2.2 数据来源

数据为合成数据。已知的数据生成过程产出五张关系表：用户表 20 万行、事件表 120.1 万行、券分配表 20 万行、订单表 26,471 行、用户结果表 40 万行。五表存入 SQLite，另加一层脏数据，包括渠道差异化缺失、刷单、重复上报与上报延迟。选择合成数据是因为识别问题：真实业务里个体的反事实与 CATE 真值不可观测，偏差无法直接度量。模拟器把真值变成可计算量[12]。外部效度只能靠公开营销实验数据另行检验，例如 Hillstrom 的 MineThatData 数据集[11]，留待后续工作。全部业务参数见附录 A，字段口径见附录 C。

口径红线 R1、R2、R3 中，两条写进了数据模型约束。R1 的分母由分配表驱动：未下单用户记 0，不丢行。R2 由结果表的约束保证：7 天转化窗口的利润列必须为空，30 天利润窗口必须非空。R3 由逐单利润表达式保证：券成本只出现一次。全部口径再由 9 条质量闸门与 20 项数据库单元测试兜底。闸门与测试跑同一批数据，任何一条被违反就抛错，不打印警告后继续。

复购路径是检验 R3 的关键。模拟器让约 5% 的已转化用户产生第二单，复购不带券，1,256 个用户因此有两笔订单。若用户级利润按“取最大值”而不是“求和”汇总，这 1,256 户的第二单利润会被静默丢掉。第二单单均净贡献 13.98 元，合计 17,555 元，折算到全体用户约 0.088 元/人，相当于 ITT（0.67 元/人）的 13%。所有闸门都不会报错，因为每用户只有一单时两种汇总方式结果相同。复购因此写进数据生成过程，并补了一条“多单用户的用户级利润等于各单之和”的测试。

2.3 研究设计

分层数据生成过程见表 2。每一层只放松一条假设，参数取业务可解释的目标量：转化率 10%，ATE 5 个百分点。截距由一维求根反解。潜在结果采用共单调耦合：同一条 U_i 驱动两个潜在转化结果，保证 $Y_i(1) \geq Y_i(0)$；订单经济特征共享抽样，个体效应只含转化增量与券成本。独立抽样会让个体效应被两倍噪声淹没[1]。识别的前提是 SUTVA，即个体间无干扰、处理版本唯一[1]。模拟器显式满足这一前提，§5.3 说明打破它需要更换随机化单位，而非更换估计量。

表 2　分层数据生成过程：每层只增加一类麻烦

层级	增加了什么麻烦	违反的假设	真值如何计算	本文用它检验什么
L0	无，理想世界	无	常数	校准评估流程本身
L1	个体效应异质：新客更强、老客更弱	无	$\tau(x)$ 解析已知	三种 CATE 学习器的差距
L2	有限样本、30/70 不等分流、效应随时间衰减	无（设计约束）	各期效应加权平均	功效损失与区间宽度
L3	运营按可观测与不可观测因素挑人	可忽略性	未观测 U 已知，可积分	观察性方法的失效阈值

真值为 $\tau_{\Pi}(x) = p_1(x)A_1 - p_0(x)A_0$，其中 A_t 是处理状态 t 下已转化用户的期望净贡献，含首单与复购期望。复购路径因此进入真值，恒等式 (2)仍然成立：

$$\tau_{\Pi}(x) = p_1(x)\,A_1 - p_0(x)\,A_0, \qquad A_t = A_t^{\text{first}} + \pi_{\text{rep}} \cdot A_t^{\text{second}}. \tag{2}$$

设计意图要真实存在。新客组人均净利润的处理组与对照组之差为 1.49 元，老客组只有 0.40 元；转化率差分别为 7.34 与 4.01 个百分点。这是“定向发券”的依据。

2.4 实验方法

（1）双指标样本量与随机化。估计目标是意向处理效应（ITT）。按随机分组建样本，未领券、未核销的用户仍留在实验组。只报告领券用户的效果，会把随机实验变成观察性比较[2]。两组按 1:1 分流，两个窗口等长：转化 7 天，利润 30 天。样本量按两个指标分别计算，取较大者，见式 (3)。

$$n_{\text{conv}} = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2\,[p_1(1-p_1) + p_0(1-p_0)]}{\Delta_Y^2}, \quad n_{\text{profit}} = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 \cdot 2\sigma_{\Pi}^2}{\Delta_{\Pi}^2}. \tag{3}$$

主估计量是两组人均净贡献利润之差，见式 (4)。两组方差不同，检验用 Welch t；二值指标用两比例 z 检验。

$$\widehat{\tau}_{\Pi} = \frac{1}{n_1}\sum_{i:T_i=1} \Pi_i^{\text{net}} - \frac{1}{n_0}\sum_{i:T_i=0} \Pi_i^{\text{net}}. \tag{4}$$

（2）识别有效性的检查。AA 校验做 1000 次无效应重复，看 p 值分布与假阳性率。SRM 检查用卡方检验比较分流比例，判据为 $p < 0.001$[10]。护栏非劣效针对退款率，界值 0.5 个百分点。不显著只说明未能检出差异，不能推出安全，因此用单侧置信上界判定，见式 (5)。

$$\text{非劣效成立} \iff \hat{d} + z_{1-\alpha}\,\widehat{\text{se}}(\hat{d}) < \delta. \tag{5}$$

多重比较用 Holm 校正。两个预设主指标是利润（primary）与转化率（co-primary）。

（3）异质性效应学习。在 L1 上按用户切分 10 万、4 万、6 万，比较 T-learner、S-learner 与 Causal Forest 三种元学习器[6][7]。四个指标并列：RMSE 与 R^2、排序（Spearman 相关与 Top-20% 重合）、增量口径的策略价值（式 6）、regret。

$$V_{\text{inc}}(\pi) = \frac{1}{n}\sum_i \pi_i \left(\Pi_i(1) - \Pi_i(0)\right), \qquad V_{\text{inc}}(\pi) = 0 \text{ 当 } \pi \equiv 0. \tag{6}$$

绝对口径 $V_{\text{abs}}(\pi) = n^{-1}\sum_i[\pi_i\Pi_i(1) + (1-\pi_i)\Pi_i(0)]$ 与它只差一个与策略无关的常数 $\mathbb{E}[\Pi(0)]$。这个常数会稀释方法间的差距，全文因此统一用增量口径。

（4）观察性识别。L3 让处理分配与基线转化率同时含未观测项，e 与 p_0 各加 λU。扫描网格取 7 个点，每点重复 100 次，样本 2 万。估计器只使用可观测的 X，不接触 U。λ 的含义是未观测变量每 1 个标准差推动基线 logit 多少。$\lambda = 0.25$ 相当于漏掉一个系数 0.25 的变量，恰好等于浏览深度的系数；$\lambda = 0.5$ 已经强于历史 GMV 的 0.40。比较对象是 naive 差分、PSM[3]、IPW[4] 与 DR（AIPW）[5]。

（5）预算约束优化。这是带资源约束的策略学习问题[8]，目标见式 (7)。

$$\max_{\pi} \sum_i \pi_i \tau_i \quad \text{s.t.} \quad \sum_i \pi_i c_i \le B, \quad \pi_i \in \{0,1\}, \tag{7}$$

其中 $c(X)$ 是面额乘以核销概率 $P(\text{核销} \mid \text{发券}, X)$。直接用面额会把预算占用高估一个数量级。预算 $B = 10{,}042$ 元，等于覆盖 20% 合格用户的期望券成本，即 $B = 0.20 \times \sum_i c(X_i)$。两种策略规则：$\hat{\tau} > 0$ 即投放、不加预算约束（表 5）；按 $\hat{\tau}/c$ 贪心取到预算用尽（表 7）。

2.5 分析工具

计算环境为 Python 3.13。统计与区间用 numpy、pandas、scipy；三种 CATE 学习器与 Causal Forest 用 scikit-learn、LightGBM 与 econml；数据层用 SQLite，含 6 个视图与 19 条命名查询；图由 matplotlib 绘制。全部业务参数集中在配置文件中，代码里不写业务常数。随机性由主种子、随机流与序号三元组派生，同一组合必然产出同一串随机数。另有 404 项自动化测试校验口径。

2.6 研究程序

全部产物由同一套流程顺序生成：数据构建、实验主线、异质性与观察性分析、策略优化、组图、产物清单。任何一步失败即中止，不产出“看似完整但口径已坏”的结果。共 64 个产物文件，复现等级与核对方式见附录 B。

3 结果

3.1 数据层与口径校验

质量检查共 20 项。干净数据 20/20 通过；注入四类缺陷后 19/20，唯一失败项是故意注入的 36,034 行重复上报。两条独立实现，一条走 numpy 快速路径，一条走 pandas 关系表聚合，最大逐用户利润差为 0.026 元。金额按分存储，舍入上限为两单 $\times$ 3 个金额字段 $\times$ 0.005 元，0.026 元落在上限之内。数据库口径的 ITT 为利润 +0.7240 元/人、转化 +0.0501、GMV +6.2376 元/人，与 pandas 路径一致。脏数据层的购物车缺失按渠道差异化，范围 2.02%～12.11%，加权 5.58%。

3.2 实验设计与识别有效性

样本量计算取 $p_0 = 0.10$、$\Delta_Y = 1$ 个百分点、$\sigma_\Pi = 11.08$ 元、$\Delta_\Pi = 0.5$ 元、$\alpha = 0.05$、功效 0.80。σ_Π 是加入复购路径后的实测标准差。结果是转化率每组 14,749 人，利润每组 7,709 人，取大者合计 29,498 人，约束者为转化率。两个样本量都与 MDE 的平方成反比；令二者相等，得约束者翻转的临界值 $\Delta_\Pi^* \approx 0.36$ 元/人。AA 校验的假阳性率为 5.9%（95% CI 4.6%–7.5%）与 4.0%（3.0%–5.4%），KS 检验 p 值 0.262 与 0.311。SRM 的分流为 100,330 / 99,670，$z = 1.48$、$\chi^2 = 2.18$、$p = 0.140$，不拒绝 50/50。护栏差值为 −0.32 个百分点，标准误 0.35，单侧 95% 上界 0.248 个百分点，低于界值，非劣效成立。但检验功效只有 0.198，真实恶化为 +0.225 个百分点；要让功效达到 0.80，每组需要 117,608 名已转化用户，折合总样本约 194 万。界值敏感性上，同一份差值只在 0.2pp 界值处判为不成立，0.3、0.5、1.0pp 三档均判为成立。Holm 校正后两个主指标仍被拒绝，利润的 p 值为 2.28×10^{-48}，转化率为 2.24×10^{-249}。

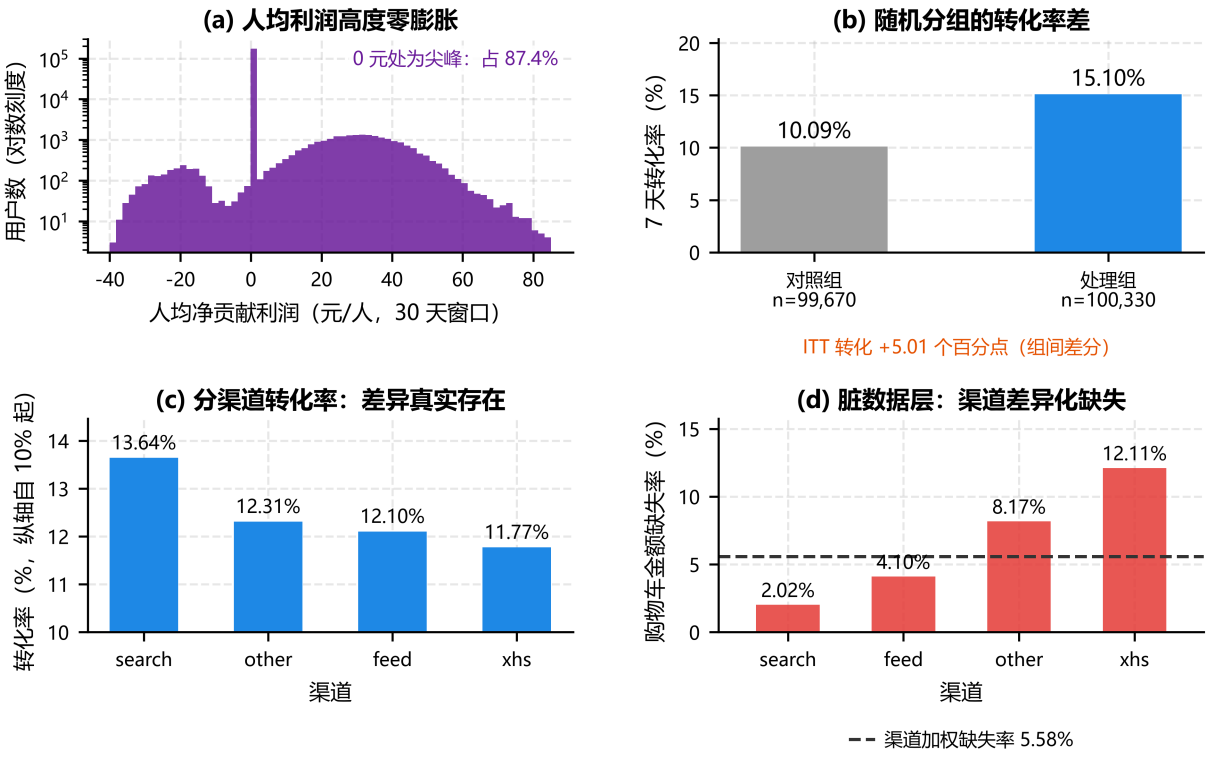


图 2　数据层证据：利润零膨胀、分组与分渠道转化率、脏数据层的渠道差异化缺失

3.3 ITT 估计与利润分解

三个层级、两个指标共六个 ITT 估计，六个 95% 置信区间全部覆盖解析真值（表 3）。重复 200 次的利润均值为 0.6703，偏差 +0.0027 元/人，相对真值 0.4%；覆盖率 0.950，转化的覆盖率为 0.945–0.950。人均 GMV 由 12.38 元升至 18.62 元，增幅 50%；人均净利润由 3.00 元升至 3.73 元，增幅 24%。每 100 人的分解见图 4b：多转化 5.01 人，按 24.69 元计，贡献 +123.7 元；原购买者中 54.8% 用券，形成 −55.3 元券成本；订单经济差异 +4.1 元；合计 +72.4 元，与 ITT 一致。核销率有两个口径：占已发券 8.28%，占已下单 54.8%。

表 3　样本量设计与六个 ITT 估计对真值的覆盖（n=200,000；L0/L1/L2 为 DGP 层级）

环节	指标	每组样本量 / 点估计	95% 置信区间	真值	结论
样本量	转化率	14,749	—	0.10	约束者
样本量	净增量利润	7,709	—	0.668	非约束者
L0	净增量利润	0.622	[0.525, 0.719]	0.668	覆盖
L0	转化率	0.0495	[0.0466, 0.0524]	0.0500	覆盖
L1	净增量利润	0.724	[0.627, 0.821]	0.668	覆盖
L1	转化率	0.0501	[0.0472, 0.0530]	0.0500	覆盖
L2	净增量利润	0.827	[0.627, 1.027]	0.900	覆盖
L2	转化率	0.0565	[0.0504, 0.0625]	0.0595	覆盖

3.4 异质性处理效应

三种学习器在测试集上的表现见表 4 与图 5。真值 CATE 的标准差为 0.669，非负比例为 86.0%。Causal Forest 的校准在中段接近完美，两端过冲：高端为 2.06，真值为 1.37。重复实验中，T-learner 的 RMSE 为 1.600 [1.538, 1.703]（R=20），S-learner 为 0.531 [0.464, 0.606]（R=20），Causal Forest 为 0.557 / 0.468，仅 2 次。

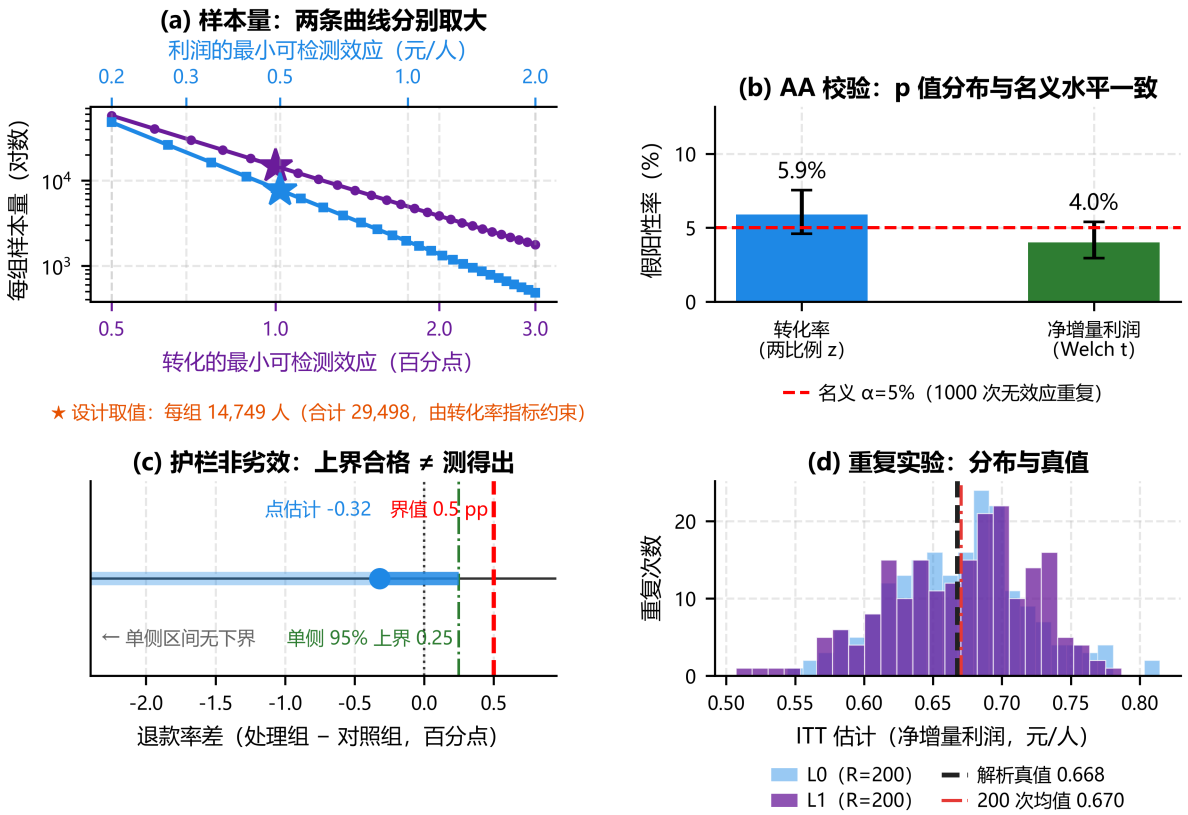


图 3　实验设计：样本量双指标、AA 校验、护栏非劣效上界与重复 200 次的 ITT 分布

表 4　三种异质性效应学习器的测试集表现（L1，测试集 6 万人；T = T-learner、S = S-learner、CF = Causal Forest；RMSE / 增量价值 / regret / 偏差单位均为元/人，选中比例 = 非负策略选中用户占比；*CF 只跑 2 次，T/S 各 20 次）

学习器	RMSE	R^2	Spearman	Top-20%	增量价值	regret	偏差	选中比例
T	1.625	−4.90	0.335	0.374	0.571	0.109	+0.137	76.2%
S	0.595	0.208	0.637	0.597	0.629	0.051	+0.104	89.5%
CF*	0.557	0.307	0.647	0.633	0.644	0.036	+0.134	89.6%

表 4 中，策略规则为 $\hat{\tau} > 0$ 即投放，不加预算约束；预算约束留给表 7。regret $= V(\pi^*) - V(\pi)$，π^* 为真值非负策略。

3.5 观察性识别的失效边界

$\lambda = 0$ 时，IPW 与 DR 的偏差绝对值不超过 0.06，覆盖率为 0.92/0.94；naive 的偏差为 +0.876，覆盖率为 0.00；PSM 的偏差为 −0.061，覆盖率只有 0.77（0.68–0.85）。$\lambda = 0.25$ 时，IPW 与 DR 的偏差为 0.15～0.16 元，约为真值的 1/4；覆盖率降至 0.82（0.73–0.89）与 0.79（0.70–0.87），Clopper–Pearson 区间上界均低于 0.90。$\lambda = 0.5$ 时，DR 的偏差为 0.531，覆盖率为 0.13；$\lambda \geq 0.75$ 时，三种调整方法的覆盖率全为 0。偏差随 λ 近似线性增长，最高到 3.94～4.42 元（表 5、表 6、图 6）。

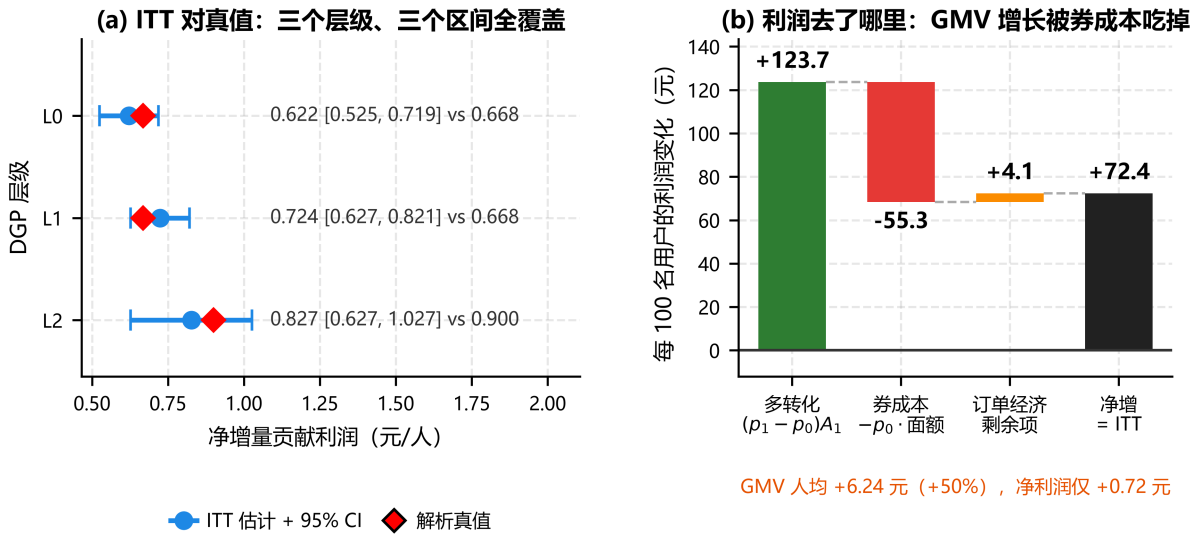


图 4　ITT 对真值的覆盖与利润侵蚀分解

表 5　四种观察性方法的偏差随混淆强度的变化（每格 100 次重复，单位：元/人；Naive 的覆盖率在所有 λ 下均为 0）

λ	Naive	PSM	IPW	DR	IPW / DR 覆盖率
0.00	+0.876	−0.061	+0.054	+0.039	0.92 / 0.94
0.25	+0.967	+0.040	+0.160	+0.147	0.82 / 0.79
0.50	+1.300	+0.493	+0.542	+0.531	0.11 / 0.13
0.75	+1.837	+1.142	+1.141	+1.129	0 / 0
1.00	+2.559	+1.987	+1.936	+1.926	0 / 0
1.25	+3.439	+2.991	+2.890	+2.881	0 / 0
1.50	+4.421	+4.047	+3.943	+3.936	0 / 0

表 6　PSM / IPW / DR 的 95% 区间覆盖率与 Clopper–Pearson 区间（每格 100 次重复；覆盖为 0 的格，区间上界 ≤ 0.04）

λ	PSM 覆盖	IPW 覆盖	DR 覆盖
0.00	0.77 (0.68-0.85)	0.92 (0.85-0.96)	0.94 (0.87-0.98)
0.25	0.76 (0.66-0.84)	0.82 (0.73-0.89)	0.79 (0.70-0.87)
0.50	0.25 (0.17-0.35)	0.11 (0.06-0.19)	0.13 (0.07-0.21)
0.75	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)
1.00	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)
1.25	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)
1.50	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)

$\lambda = 0.5$ 时，IPW 加权后 7 个特征的标准化均值差由 0.05～0.35 全部压到 0.0038 以下。历史 GMV 从 0.354 降到 0.004，购物车金额从 0.353 降到 0.003。同一份数据上，IPW 的偏差为 +0.542 元/人，真值为 0.629。

3.6 预算约束下的策略价值

六种策略在同一测试集（6 万人）、同一预算（$B = 10{,}042$ 元）下的结果见表 7 与图 7。定向-贪心选中 15,985 人，人均增量价值 0.349 元，bootstrap 95% CI 为 0.318–0.384；每元回报 2.085 元（1.909–2.290）；占真值贪心解 86%（82%–91%）。随机策略取 200 个种子，均值为 0.122 ± 0.011 元，每元回报 0.730。真值贪心解为 0.405 元，LP 松弛上界 0.404745 元/人，与启发式解 0.404744 只差 1.8×10^{-7}。预算敏感性上，定向相对随机的倍数在最紧预算（×0.2）为 4.55 倍，×3.0 为 1.67 倍；绝对增益在 ×1.6 达峰（+0.263 元/人）。四参数各取 ±20% 的 12 个单元均为定向优于随机，每元回报 1.57～3.03。

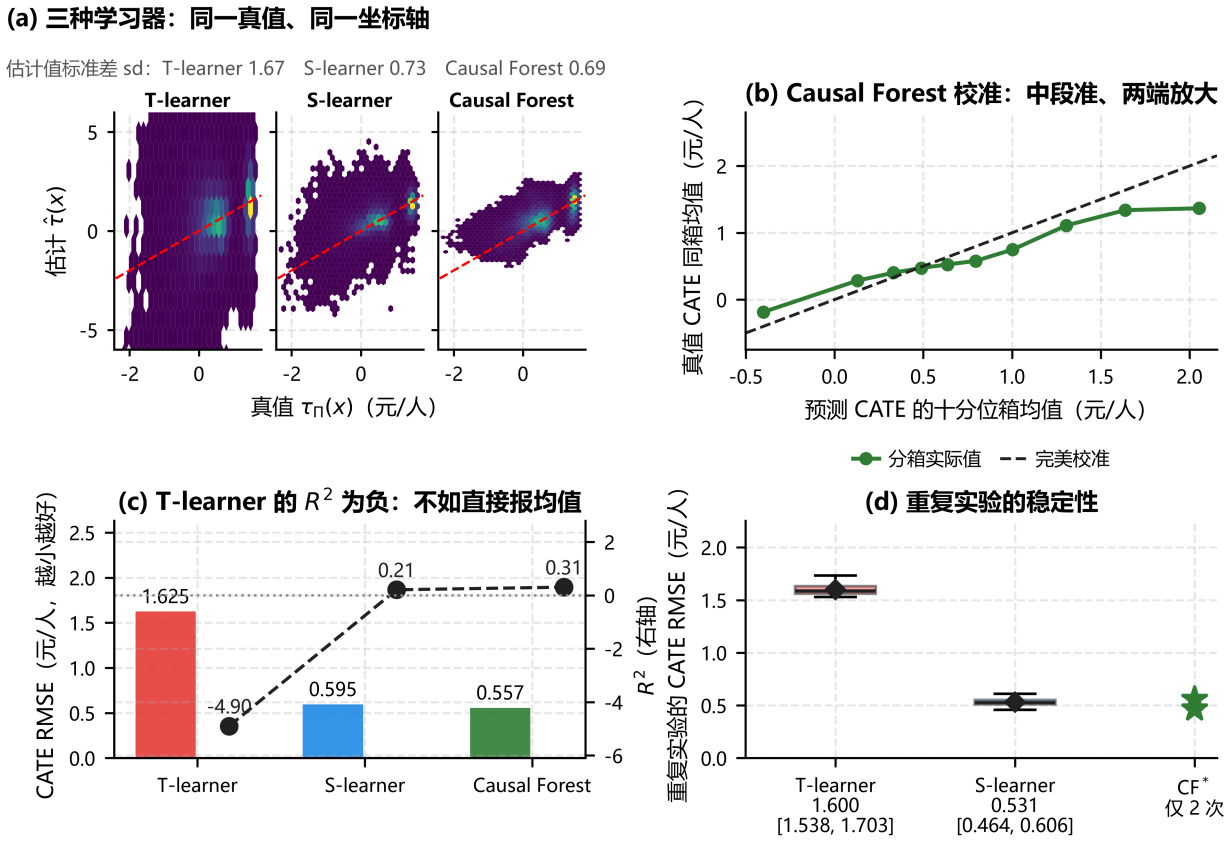


图 5　三种异质性学习器：同一真值下的还原能力、校准、精度与稳定性

表 7　六种策略在同一测试集（6 万人）、同一预算下的表现（增量价值 = 实现值 $\pi_1 - \pi_0$；人均选中效应 = 解析 $\mathbb{E}[\tau]$；方括号为 95% CI）

策略	选中人数	实际成本（元）	增量价值（元/人）	人均选中效应（解析）	每元回报	占真值贪心解
不发券	0	0	0.000	—	—	0%
全量发券	60,000	50,210	0.611 [0.553-0.670]	0.664	0.730 [0.661-0.800]	超预算 5 倍
随机（预算 B）	12,000	10,042	0.122 ± 0.011（200 种子）	0.662	0.730 [0.610-0.859]	30% [25-36]
定向-贪心	15,985	10,042	0.349 [0.318-0.384]	1.349	2.085 [1.909-2.290]	86% [82-91]
定向-背包	15,985	10,042	0.349 [0.318-0.384]	1.349	2.085 [1.909-2.290]	86% [82-91]
真值贪心解（近似最优）	16,970	10,042	0.405 [0.369-0.446]	1.431	2.420 [2.218-2.672]	100%

表 7 的增量价值按实现值 $\pi_1 - \pi_0$ 计算，为 0.349；解析口径为人均选中效应乘覆盖率，即 $1.349 \times 15{,}985/60{,}000 = 0.359$。两者相差 3.0%，小于该行 bootstrap 95% CI 的半宽 0.033。随机行是 200 个种子的均值 ± 标准差，其余行是测试集 500 次 bootstrap 百分位。“真值贪心解”用真值 τ 做贪心再加 1-2 交换，是启发式解；它的上界由 LP 松弛给出。

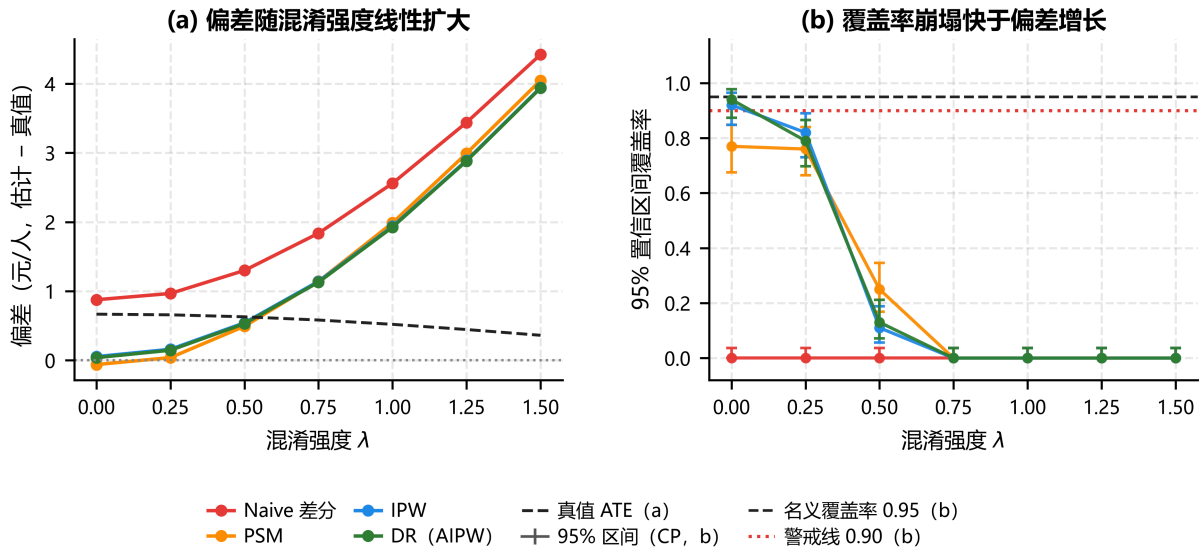


图 6 观察性识别的失效边界：偏差与覆盖率随混淆强度变化

4 讨论

4.1 结果解释

主指标与样本量约束者分离，H1 成立。利润是首要指标，却不是样本量的约束者。87% 的用户利润为 0，标准差只有 11.08 元。检出 0.5 元/人比检出 1 个百分点转化更省样本，7,709 对 14,749。零膨胀把方差压得很低，这是“多数用户不买”的结构性特征。主指标与设计约束指标因此要分开写。翻转临界 0.36 元/人标出了这条边界的位置。

策略价值对 RMSE 的弹性很小，H3 成立。T-learner 的 RMSE 是 Causal Forest 的 2.9 倍，1.625 对 0.557；增量策略价值只低 11.3%，0.571 对 0.644。原因是策略只消费 τ 的符号与排序。对真值施加常数平移使 RMSE=5，排序指标仍全为 1。Causal Forest 的 RMSE 优势来自更小的方差。把 RMSE 分解为偏差平方加误差方差：CF 的偏差为 +0.134，比 S-learner 的 +0.104 更大；误差方差为 0.293，比 S 的 0.344 小 15%。它赢在稳定，不在准。另一面是过度投放：CF 的非负策略选中 89.6% 的用户，真值非负比例只有 86.0%。策略价值最高时，预算效率未必最高。

覆盖率崩塌快于偏差，H2 成立。$\lambda = 0.25$ 时，IPW 与 DR 的偏差只有真值的 1/4，覆盖率却已从 0.92/0.94 跌到 0.82/0.79。区间宽度按零偏差校准。偏差一旦超过标准误的一半量级，覆盖率就开始系统性偏离名义水平，而偏差的绝对值仍可能显得很小。PSM 在 $\lambda = 0$ 时已经不合格，覆盖率 0.77，上界 0.85。它的标准误忽略了对照被重复匹配，问题出在区间本身，与混淆无关。点估计几乎无偏，区间仍可能完全不可用。

平衡性诊断全绿与无偏无关。这个结果与双稳健估计的前提直接相关：至少有一个模型正确[5]。$\lambda = 0.5$ 时，IPW 把 7 个特征的标准化均值差全部压到 0.0038 以下，同一份数据上的偏差却是 +0.542 元/人，达到真值的 81%。倾向得分只能平衡 X 中存在的变量。U 不在 X 中，倾向得分对它们无能为力[3]。双稳健估计也没有提供额外保护。$\lambda \geq 0.5$ 后，DR 与 IPW 的差不足 0.02 元，因为 U 同时进入两个模型，“至少一个模型正确”的前提不成立[4]。

背包与贪心结果相同，原因是规模，不是程序缺陷。全规模下，贪心达到线性松弛上界的 99.9999%。“大量小件”背包的交换论证保证差距不超过单件最大价值。降规模后，精确 DP 因成本离散化反而低 0.30%。只有 3 件物品的反例里，贪心损失 33%。背包的主要价值是用 LP 上界证明贪心已经足够，并处理少量大额件。

4.2 原因分析

各条主线的失效模式指向同一个结构性原因：目标量与实际决策量不是同一个泛函。转化率是均值，利润是重尾零膨胀变量，策略价值是依赖排序的泛函。用均值的直觉设计样本量，用 RMSE 的直觉评价

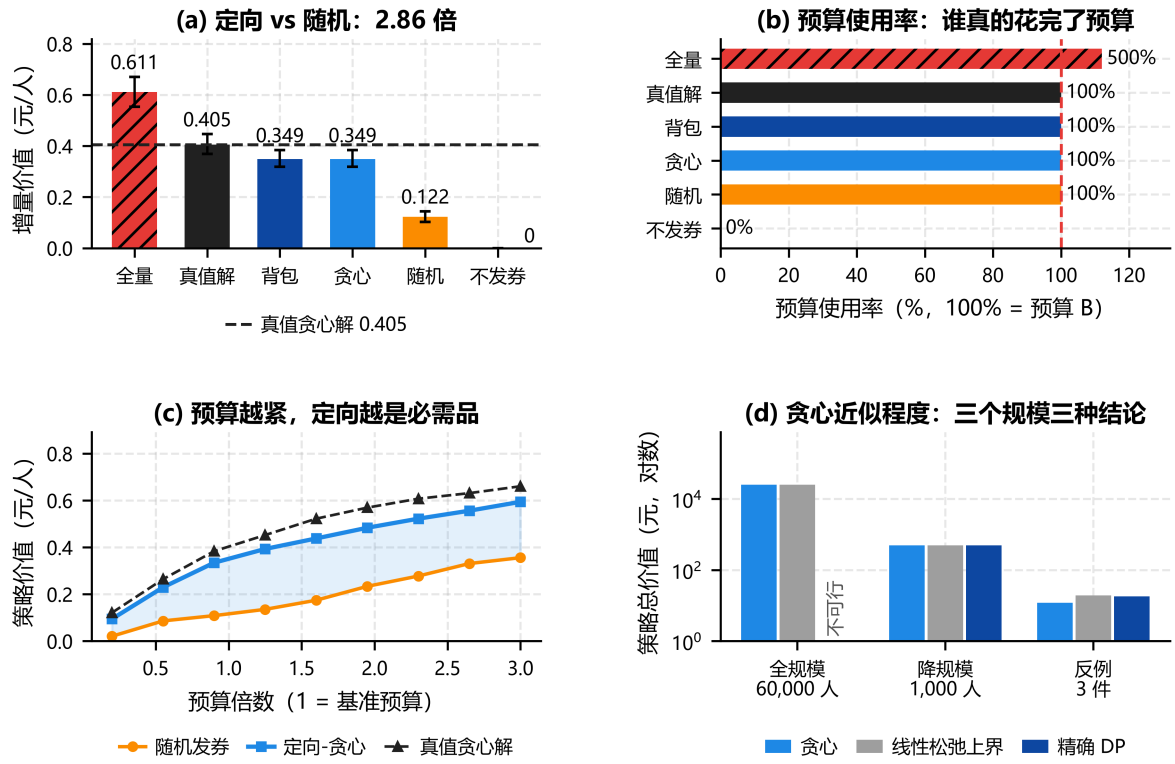


图 7 预算约束下的策略价值：六策略对比、预算使用率、预算敏感性与贪心近似程度

策略，用平衡性判断无偏，都会在某个环节失配。第二个原因是不确定性被点估计掩盖。护栏功效为 0.198 时，“通过”几乎不携带信息。R=20 的覆盖率格子标准误高达 0.05～0.10，不足以判定失效；R=100 并配 Clopper–Pearson 区间才够。第三个原因是口径不统一。真值贪心解被误称为“上界”，绝对口径与增量口径混用，都会让数字正确而结论错误。

4.3 理论与实践意义

理论上的贡献是把偏差从不可观测量变成可核对量，并给出可移植的边界结论：约束者分离、覆盖率先崩、平衡性诊断不构成无偏证据。这些结论不依赖本文的具体参数，属于零膨胀重尾目标、区间校准与可观测平衡的一般性质。

实践上给出可执行的决策规则与置信区间。定向发券每元回报 2.08 元（1.91–2.29），占真值贪心解 86%（82%–91%），在四参数各取 ±20% 的 12 个单元里方向稳定。观察性结论也有操作阈值：$\lambda \geq 0.25$ 即不可信。对运营侧的一句话是：预算越紧，定向越是必需品。最紧预算下，定向相对随机为 4.55 倍。

4.4 局限性

模拟不能替代真实数据的经验。DGP 的共单调耦合让个体效应集中在转化增量与券成本上，真实世界的效应异质性更复杂。统计上，护栏功效只有 0.198；CATE 重复 20 次，Causal Forest 只有 2 次；λ 扫描的样本为 2 万，覆盖率标准误约 0.04，已用 Clopper–Pearson 区间显式吸收。实现上，“背包”实际是贪心加局部改进；DR 未做交叉拟合，若改用 DML 或交叉拟合，需要样本分割与正交矩条件[9]；PSM 的标准误忽略对照复用；缺失按 MAR 处理。设定上，未做面额与人群的联合优化，面额固定为 10 元；未建模溢出与长期效应；策略学习只用到 $\hat{\tau}$ 的符号与排序，未采用 Athey–Wager 式的直接策略优化目标函数[8]，预算极紧时可能不是最优规则。结论在以下情况失效。网络溢出破坏 SUTVA，定向收益会被夸大。长期效应使 30 天窗口内的增量只是时间平移。退款在 30 天后集中爆发，利润成熟窗口不足。核销率被低估 20%，实际超支约 25%。面额与效应的曲线形状不同时，“每元回报 2.08”的绝对值失效，排序结论仍成立。

5 结论

5.1 主要发现

双指标设计在 20 万用户、重复 200 次下无偏，区间也得到校准。ITT 偏差为 +0.002 元/人，覆盖率 0.950，六个单次估计的 95% 区间全部覆盖解析真值。定向发券相对随机发券的优势约为 2.9 倍，0.349 对 0.122 元/人。它跨过盈亏平衡线，每元回报 2.085 元，95% CI 1.909–2.290，达到真值贪心解的 86%（82%–91%）。观察性调整的失效边界比直觉更早：$\lambda = 0.25$ 时，IPW 与 DR 的覆盖率已降至 0.82/0.79，而此时可观测特征已全部平衡，SMD<0.004。界值型护栏针对退款率非劣效，在本样本量下功效只有 0.198，“通过” 不能当作安全证据。

5.2 研究问题的回答

RQ1 的答案是能。定向策略每元回报 2.085 元，CI 下界 1.909，大于 1，且显著高于随机发券的 0.730。RQ2 的答案是能给出阈值，但必须用区间判定。$\lambda = 0$ 时只有 IPW 与 DR 可用；$\lambda \geq 0.25$ 起三者全部不可信，CP 区间上界也低于 0.90；$\lambda \geq 0.5$ 时必须回到实验设计。RQ3 的答案是不能互相替代。RMSE 相差 2.9 倍时，策略价值只差 11.3%。平移常数使 RMSE=5，排序仍然全对。Causal Forest 的 RMSE 优势来自方差，不来自偏差。H1 到 H3 在本文参数下均成立。

建议把 “是否发券、发给谁” 写成品利润预算约束下的选择问题。报告不确定性，给出区间、种子分布与 CP 区间，不只报点估计。平衡性诊断只能当作必要条件。混淆强度无法排除时，用实验设计解决，不要依赖更强的调整方法。

5.3 展望：模型遗漏了什么、如何深化、用什么方法

模拟器假定 SUTVA 成立、用户之间没有相互影响，而定向发券在社群内会产生干扰。它只观测 30 天利润窗口，无法区分真实增量与需求提前。用户被当作静态个体，没有浏览、加购、首单、复购之间的状态转移。模型没有时间维度的反事实趋势，因此识别不了动态效应。未观测混淆的动态变化也没有建模，λ 被当作一次性、静态的参数。

若要考虑这些因素，时间维度需要新增 L4 面板层，干预前后各 30 天。空间维度需要把随机化单位从用户改为社群或城市，并定义 exposure mapping。时间窗需要延长到 90～180 天，并建模留存曲线。状态维度需要把用户状态空间定义为浏览、加购、首单、复购，并先检验马尔可夫性。

方法上，时间维度可用双重差分、事件研究或合成控制。所需条件里，未受干预的对照组与可检验的平行趋势都不满足，因此这部分不做。补齐需要两期面板、城市级整群随机与概率尺度的平行趋势，并用事件研究图逐期检验。空间维度用网络溢出、exposure mapping、整群随机与两阶段随机化。时间窗维度用长期 LTV、留存曲线与生存分析。状态维度用马尔可夫链、状态转移矩阵或隐马尔可夫模型。

这些方法本身可行，限制在数据：现有数据做不出可信的因果结论。DID 需要两期面板与未受干预的对照城市；网络溢出需要社群级随机化与 exposure 定义；LTV 需要 90～180 天的真实观测；马尔可夫链需要以月计的多期状态面板。现有数据是单期、用户级随机、30 天窗口、无状态序列，支撑不了其中任何一项。硬做只会把假设当成结论。

参考文献

[1] Imbens G W, Rubin D B. Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction[M]. Cambridge University Press, 2015.

[2] Angrist J D, Pischke J S. Mostly Harmless Econometrics: An Empiricist's Companion[M]. Princeton University Press, 2009.

[3] Rosenbaum P R, Rubin D B. The central role of the propensity score in observational studies for causal effects[J]. Biometrika, 1983, 70(1): 41-55.

[4] Robins J M, Rotnitzky A, Zhao L P. Estimation of regression coefficients when some regressors are not always observed[J]. Journal of the American Statistical Association, 1994, 89(427): 846-866.

[5] Bang H, Robins J M. Doubly robust estimation in missing data and causal inference models[J]. Biometrics, 2005, 61(4): 962-973.

[6] Künzel S R, Sekhon J S, Bickel P J, Yu B. Metalearners for estimating heterogeneous treatment effects using machine learning[J]. Proceedings of the National Academy of Sciences, 2019, 116(10): 4156-4165.

[7] Wager S, Athey S. Estimation and inference of heterogeneous treatment effects using random forests[J]. Journal of the American Statistical Association, 2018, 113(523): 1228-1242.

[8] Athey S, Wager S. Policy learning with observational data[J]. Econometrica, 2021, 89(1): 133-161.

[9] Chernozhukov V, Chetverikov D, Demirer M, et al. Double/debiased machine learning for treatment and structural parameters[J]. The Econometrics Journal, 2018, 21(1): C1-C68.

[10] Kohavi R, Tang D, Xu Y. Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing[M]. Cambridge University Press, 2020.

[11] Hillstrom K. The MineThatData e-mail analytics and data mining challenge[DS]. 2008.

[12] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 2019, 38(11): 2074-2102.

附录 A　关键参数表

（表中参数名为简写；业务含义见 “业务依据” 列。）

表 A1　关键参数表（取值与其业务依据）

参数	取值	业务依据
`baseline_conversion`	0.10	加购未支付用户历史首单转化率（行业 8%～12% 的中值）
`coupon_max_effect`	0.15	券对转化率的最大提升（概率尺度上限，硬约束 $p_0 + \tau \leq 1$）
`coupon_face_values`	5 / 10 / 15 / 20 元	平台现行券档位；参考面额取 10 元，饱和曲线尺度 12.0
`redemption_rate`	0.55	券核销率（同类券历史核销率 40%～70%）
`refund_rate`	0.075	类目历史退款率（5%～10%），同时是护栏指标基线
`goods_cost_ratio`	0.68	商品成本率（毛利率 25%～40% 对应成本率 60%～75%）
`fulfill_cost_mean`	5.0 元/单	配送 + 仓储 + 包材；不可回收，退款后仍发生
`aov_mean`	120 元	加购未支付用户首单客单价
`refundable_goods_ratio`	0.85	退款后可回收商品成本比例；退款手续费率 0.01
`convert_days / profit_days`	7 / 30 天	转化观察窗与利润成熟窗；两窗口必须分开且等长（R2）
`mde.conversion_abs`	1 个百分点	0.10→0.11 的相对提升 10%，低于此不足以支撑一次改版
`mde.profit_per_user`	0.5 元/人	= 总预算 100,000 元 / 20 万合格用户的盈亏平衡尺度
`mde.profit_sd_assumed`	11.08 元	实测 sd(人均净贡献利润)（含复购路径，87% 为 0）
`coverage_target`	0.20	试点投放覆盖 20% 合格用户；实际预算 $B = 0.20 \sum_i c_i$
`repeat.prob / value_ratio`	0.05 / 0.55	30 天窗口内复购率 4%～6% 的中值；复购客单价为首单的 55%

附录 B　复现方式与可复现性等级

B.1 可复现性等级

数据为按明确参数生成的合成数据，随机种子固定为 20240101。同一种子可以重建同一份数据。全部数值结果、表与图由同一套计算流程产出；正文中的每个数字都能在结果表中追溯。复现性方面，随机流完全确定；主结果逐位可重建；少数浮点汇总列存在 10^{-15} 量级的差异，原因是浮点累加顺序不同。复现流程产生 64 个产物文件，其中结果表 43 张、图 7 张。

B.2 数据与图表说明

全部数据由已知的数据生成过程产生，是合成数据，不是真实企业数据。图 1 至图 7 与表 1 至表 7、表 A1、表 C1 的数据来源与计算口径见表 B1。数据来源一列使用结果表的中性名称，不指向具体文件。

表 B1　图 1–7 与表 1–7、表 A1、表 C1 的数据来源与计算口径

编号	内容	数据来源	关键口径
图 1	技术路线	研究设计框架	八个环节，不含估计结果
图 2	数据层证据	数据层描述统计表、质量校验表	20 万用户；双窗口；渠道加权缺失
图 3	实验设计	样本量、AA、护栏与重复实验表	样本量；假阳性率；单侧 95% 上界；200 次重复
图 4	ITT 与利润分解	ITT 估计表、利润分解表	L0–L2；两个指标；95% CI 对解析真值
图 5	异质性学习器	学习器评估表	6 万人；RMSE、排序、策略价值、regret
图 6	观察性失效边界	混淆强度扫描汇总表	7 个 λ 点；100 次重复；CP 区间
图 7	策略价值	六策略对比表、预算敏感性表	6 万人；$B = 10{,}042$ 元；500 次 bootstrap
表 1	深度对照	研究设计对照表	四个维度、三个信号
表 2	分层数据生成过程	数据生成过程设计表	L0–L3；每层放松一条假设
表 3	样本量与 ITT	样本量设计表、ITT 估计表	n=200,000；L0–L2；95% CI 对真值
表 4	学习器表现	学习器评估表	6 万人；CF 2 次、T/S 20 次
表 5	观察性偏差	混淆强度扫描汇总表	100 次重复；元/人
表 6	覆盖率	混淆强度扫描汇总表	100 次重复；CP 区间
表 7	六策略	六策略对比表	6 万人；$B = 10{,}042$ 元；500 次 bootstrap
表 A1	关键参数	参数配置表	业务参数取值与依据
表 C1	数据字典	数据模型说明表	五张关系表字段与口径
表 B1	本表	图表来源汇总	图与表的数据来源

附录 C　数据字典与 SQL 对象清单

表 C1　五张关系表的关键字段与口径

表（行数）	关键字段与口径
`users`（200,000）	user_id 主键、is_new、reg_date、channel、hist_gmv、cart_value_at_assign（脏数据层注入 MNAR 缺失）、browse_depth_7d
`user_events`（1,201,121）	user_id、event_type（page_view / add_to_cart）、event_time（统计口径）、sku_id、ts_ingested（受上报延迟影响，不作统计）
`coupon_assignment`（200,000）	exp_id、user_id（每用户仅一行）、group、coupon_value、assign_time（两窗口共同起点）
`orders`（26,471）	order_id、user_id、order_time、pay_amount、refund_amount、goods_cost、fulfill_cost、coupon_used、coupon_value、refunded、refund_time；退款单保留 2,053 行、复购第二单 1,256 行
`user_outcomes`（400,000）	user_id、window_type（convert_7d / profit_30d）、converted、gmv、net_profit（7 天为 NULL）、refunded

6 个视图分别承担五项成本分列、逐单净贡献利润、用户级利润、订单窗口归属、7 天转化结果与 30 天利润结果。R3 由逐单净贡献利润视图保证，券成本只减一次；R1 由用户级利润视图保证，以分配表为驱动表做左连接，未下单记 0，多单求和；R2 由两个结果视图保证，分别对应 7 天转化窗口与 30 天利润成熟窗口。

19 条命名查询分三组：口径派生 5 条（事件去重、浏览深度、逐单利润、用户级利润、双窗口合并）；业务看板 5 条（分组 ITT、ITT 差值、渠道漏斗、新老客对比、日汇总）；质量闸门 9 条（重复上报、孤儿订单、重复分配、窗口完整性、转化窗口利润为空、退款单保留、对照组持券、事件越界、分流比例）。闸门与数据库测试跑同一批数据，违反即抛错。