预算约束下电商营销的增量利润评估与发券决策

基于已知数据生成过程的分层验证

Lrvin

liliw@126.com

合成数据 / 已知数据生成过程（非真实企业数据）

2026 年 11 月 1 日

摘 要

营销预算有限时，“把券发给谁”与“每个用户花多少”是两个相互耦合的决策：前者取决于个体处理效应能不能被估准，后者取决于预算约束下的组合优化。二者都建立在一个更基本的前提上——所报的增量利润，究竟是不是增量。本文在一个数据生成过程已知的环境中构建端到端的评估与优化流程，用一个业务问题贯穿始终：在有限预算下、在给定券面额的条件下，仅凭可观测数据决定是否发券、发给谁、给多少预算，并给出所创造净增量利润的大小与适用边界。面额本身作为决策变量留待后续工作。为使失效可以被归因，本文把问题拆成四层，每层只放松一条假设：L0 保留利润的零膨胀与重尾，L1 引入真实金额链路与个体异质性，L2 引入时间漂移与人群构成变化，L3 引入未观测混淆。

正式重复实验给出的主要结果如下。流程层面，1000 次零效应重复的合并假阳性率为 0.046，Clopper–Pearson 95% 区间 [0.0339, 0.0609] 覆盖名义水平 0.05，标准误校准比 0.987–0.995，说明这条流程不会自发产生显著结果。估计层面，前三层核心格各 500 次重复的平均处理效应分别为 0.243、0.283 与 0.288 元/人，与数据生成过程的解析真值 0.245、0.282、0.286 相比，偏差分别为 −0.51%、+0.53% 与 +0.80%，均不超过 1.2 个蒙特卡洛标准误——偏差是算出来的，不是靠估计量互相印证推断出来的。L3 是一个未解决的例外：其解析真值为 0.231 元/人，与前三层同量级，而估计均值为 1.664，相差 1.43 元/人；**同一批潜在结果下，混淆强度由零升至 1.5 时未调整估计从 1.664 升到 2.229（+34%），真值恒为 0.231**——增长的全部是偏差而不是效应。该差距既不能由未观测混淆解释（核心格 _T=0），也不能由构成偏差解释（按真倾向加权的 ATT 为 0.2161，与 ATE 0.2288 相差仅 0.013）；按定义把它拆开可得：朴素差 = ATT + 选择项 = 0.211 + 1.436 = 1.647，与直接计算的朴素差逐位吻合；同一分解在 L0 上的选择项只有 −0.014。也就是说，**仅凭可观测的选择就让未调整估计偏离约 6 倍**，无需引入任何未观测混淆。本文因此**不把 L3 的绝对水平用于任何结论**，只保留其层内相对变化。决策层面，在 200 次独立随机验证（每次 20 万新用户、三臂）中，“发券值得”在 196 次（0.98）中成立，平均增量为 0.282 元/人；“定向优于同预算随机”在 190 次（0.95）中成立，平均高出 0.214 元/人，但这一优势的分布极不均匀：使用因果森林的 105 次与 DR-learner 的 12 次全部成立，S-learner 的 71 次与 T-learner 的 5 次中有 73 次成立（96%），而使用常数策略的 7 次全部不成立。

更重要的是，在 1000 对配对比较中，一条两行的业务规则（新客优先、再按购物车金额）在三个预算档上分别高出模型驱动的贪心策略 0.036、0.054 与 0.032 元/人，胜率仅 33%–36%。以 200 个独立重复为单位重算，t 约为 −20——**差异显著，但幅度很小**（0.032 至 0.054 元/人），而两处聚合口径之差（0.064）比这个幅度还大，因此本文只主张“没有证据表明模型优于规则”，不主张规则胜出的量级。另一方面，若按“每次上线一个被选中的模型”的部署口径，定向为 0.282 元/人、高于规则的 0.2718——**两种聚合口径相差 0.064，超过被比较的差距本身**，所以正确的表述是“没有证据表明模型优于规则”，而不是“规则胜出”。

三条边界结论构成本文的主要发现。其一，护栏是否是约束取决于投放松紧：全员发券时退款率比对照高 0.42 个百分点（L0–L2）至 0.68 个百分点（L3），后者已越过 0.5 个百分点的非劣效界值；而按 0.2 元/人档定向发券时，按全部分配用户计为 0.137 个百分点、单侧上界 0.220 个百分点；把同一增量还原到实际领券人群，点估计 0.351、上界 0.564；此时界值须随分母等比缩放到约 1.28 个百分点，判定仍为通过——**口径必须连同界值一起定义，只换分母不换界值会得出“越界”的假象**。其二，门槛指标会错位：利润是零膨胀重尾变量，样本量的约束者是可检测的购买率变化而非主指标本身，因此以利润反解样本量会系统性低估所需规模。与之相关的是盈亏平衡：把每名用户的购买概率统一抬高 Δp 后解析重算，购买率增量需超过 **3.31 个百分点**才能覆盖券成本，而设计设定是 5 个百分点——**安全垫只有 1.51 倍**；真实效应若降到 3.31 个百分点以下，结论即归零。推导只用两个锚点：购买增量为零时净增量等于负的券成本（0.551 元/人），为 5 个百分点时等于解析真值（0.2817 元/人）；两点连线与横轴的交点即盈亏平衡。其三，个体排序质量与平均效应可以脱钩：平均效应几乎无偏（相对偏差 0.5%），但表现最好的因果森林，其估计 CATE 与真值 CATE 的相关系数只有 **0.10**，校准斜率 0.75，逐点误差 6.1 元/人（约为平均效应的 22 倍）；四个核心格中有两格在固定策略重采样下区间跨零，成本异质格上定向甚至显著劣于随机（−0.168 元/人，区间不跨零）。此外，成本预测是预算控制的实际瓶颈：定向策略的实际支出比预测高 5.6%（179/200 次为正），是系统性偏差。

本文的贡献有三个方面：给出一个可分层归因的验证设计，使“哪一条假设被放松”与“结论在哪一步失灵”一一对应；给出净增量利润的完整账务口径与金额链路，使券成本、退款与复购各按其真实路径进入利润；给出按模型配对的策略比较纪律，避免用选模后的子集代替全量比较。结论的适用范围同样是结论的一部分：全部数字只成立于本文设定的数据生成过程，不构成对真实企业的效果承诺，也不替代线上实验；当样本量、预算档或护栏阈值超出本文覆盖范围时需要另行验证。

关键词：因果推断；增量利润；异质性处理效应；预算约束优化；模拟验证

目录

1 引言 . . . 5
1.1 一个可执行的决策问题 . . . 5
1.2 购买率与 GMV 的局限 . . . 5
1.3 真值已知环境的必要性 . . . 5
1.4 与既有研究的定位 . . . 6
1.5 研究问题与假设 . . . 6
1.6 分层递进的设计依据 . . . 6
1.7 主要结论 . . . 7
1.8 全文结构 . . . 7
2 研究方法 . . . 7
2.1 决策问题与目标量 . . . 7
2.1.1 分析单位与分析分母 . . . 8
2.1.2 净贡献利润的定义 . . . 8
2.1.3 误差类型：假阳性、功效不足与口径错位 . . . 9
2.2 分层数据生成过程 . . . 9
2.2.1 四层的假设放松 . . . 9
2.2.2 金额链路：购物车、首单与复购 . . . 10
2.2.3 时间结构与窗口定义 . . . 11
2.2.4 退款机制与账务四格 . . . 11
2.2.5 随机流命名与真值隔离 . . . 12
2.3 关系表与查询契约 . . . 12
2.4 估计方法 . . . 12
2.4.1 核心格所用的估计量 . . . 12
2.4.2 平均处理效应与五个条件平均处理效应模型 . . . 12
2.4.3 观察性估计量及其失效方式 . . . 13
2.4.4 选模准则：验证集下界而非真值 . . . 13
2.5 策略与预算优化 . . . 14
2.5.1 策略与求解器 . . . 14
2.5.2 成本模型：两阶段乘式与它的三处薄弱 . . . 15
2.5.3 三种预算口径：期望、缓冲与面额上限 . . . 16
2.6 评价与校准设计 . . . 16
2.6.1 零效应重复、最小可检测效应与覆盖率 . . . 17
2.6.2 后悔的分解 . . . 17
2.6.3 判定口径在动数据之前冻结 . . . 18
2.6.4 观测闭环：冻结、估计与审计 . . . 18
2.6.5 跨重复聚合：先逐重复，再汇总 . . . 19
2.7 实验条件与可复现性 . . . 19
2.7.1 随机种子、重复次数与样本量 . . . 19
2.7.2 结论成立的条件 . . . 19
3 结果与分析 . . . 20
3.1 流程校准：自发显著结果的排除 . . . 20
3.1.1 零效应重复的假阳性率 . . . 20
3.1.2 最小可检测效应与实测功效 . . . 20
3.2 L0：最理想的基线 . . . 21
3.2.1 平均效应的偏差与精度 . . . 21
3.2.2 前三层无偏与 L3 偏差的成因 . . . 22
3.2.3 零膨胀重尾对样本量的含义 . . . 22
3.2.4 成本同质性假设的检验 . . . 22

3.3 L1：真实金额链路与个体异质性 . . . 23
3.3.1 平均效应及其构成 . . . 23
3.3.2 选模结果与判据的有效性 . . . 23
3.3.3 小样本诊断对模型选择的影响 . . . 23
3.3.4 同一规则在不同模型下的结论差异 . . . 23
3.3.5 诊断规模对选模结论的影响 . . . 24
3.3.6 个体层面的排序质量 . . . 24
3.3.7 选模后悔 . . . 24
3.3.8 效应量级扫描：设计效应与盈亏平衡的距离 . . . 25
3.4 L2：时间与人群的变化 . . . 25
3.4.1 平均效应与拆分的时间含义 . . . 25
3.4.2 漂移下测试段与全量的符号差异 . . . 26
3.4.3 人群构成变化与样本量 . . . 26
3.4.4 一个不构成机制证据的格子 . . . 26
3.5 L3：不可观测混淆的定量边界 . . . 26
3.5.1 核心格的定位 . . . 26
3.5.2 混淆在选择偏差之上的增量 . . . 26
3.5.3 混淆强度的边际作用 . . . 27
3.5.4 λ_T 与 λ_Y 的联合变化 . . . 27
3.5.5 极端重叠与缺失混淆 . . . 28
3.5.6 机制格汇总 . . . 28
3.5.7 L3 的结论边界 . . . 28
3.6 边界格：机制旋钮的完整清单 . . . 28
3.7 各层的独立判断 . . . 29
3.7.1 L0：估计量本身不是瓶颈 . . . 30
3.7.2 L1：平均无偏是个很弱的保证 . . . 30
3.7.3 L2：结论依赖评估窗口，而这件事可以被设计利用 . . . 30
3.7.4 L3：混淆的形状比强度更重要 . . . 30
3.7.5 判断的适用范围 . . . 30
3.8 跨层比较的可比性 . . . 31
3.9 策略层：业务规则与模型策略的比较 . . . 31
3.9.1 策略排序 . . . 31
3.9.2 简单规则胜出的原因 . . . 32
3.9.3 策略的逐项解读 . . . 32
3.9.4 业务规则胜出的机制：效应与可观测特征的形状 . . . 33
3.9.5 与 “定向优于随机” 的关系 . . . 33
3.9.6 随机基线的分布与预算饱和点 . . . 33
3.9.7 预算约束的约束力区间 . . . 33
3.9.8 三种预算口径 . . . 34
3.9.9 求解器：规模、最优性与桶宽 . . . 34
3.10 退款率护栏：口径必须连同界值一起定义 . . . 35
3.10.1 全员发券：L3 已越过界值 . . . 35
3.10.2 主张的联合通过率 . . . 36
3.10.3 定向发券的护栏余量 . . . 36
3.11 观测闭环：不依赖真值的评估 . . . 36
3.11.1 观测性估计量的分歧 . . . 36
3.11.2 离策略估计与真值审计 . . . 37
3.11.3 独立随机验证：成本预测是实际瓶颈 . . . 37
3.12 重采样稳定性：两种 bootstrap 回答不同问题 . . . 37
3.12.1 固定策略 bootstrap 的结果 . . . 37
3.12.2 重训的 bootstrap：重抽总体并重训 . . . 38
3.13 方法论教训：恒等式核对先于归因 . . . 38
3.14 本章结果汇总 . . . 38
3.15 本章结论的边界 . . . 40

4 讨论与展望 . . . 40
4.1 对业务问题的回答 . . . 40
4.2 主要发现 . . . 41
4.3 证据强度分级 . . . 41
4.4 这套流程的回答范围 . . . 41
4.5 业务含义 . . . 41
4.6 局限与失效条件 . . . 42
4.7 方法论上可迁移的要点 . . . 42
4.8 不同读者的取用要点 . . . 43
4.9 后续工作 . . . 43
4.10 结语 . . . 43
参考文献 . . . 50
A 附录 . . . 51
A.1 附录 A　四层机制的参数表 . . . 51
A.2 附录 B　净贡献利润的账务口径 . . . 51
A.3 附录 C　边界格的结果 . . . 51
A.4 附录 D　预算口径与求解器的对照 . . . 51
A.5 附录 E　复现所需的实验条件 . . . 52
A.6 附录 F　图目录 . . . 52
A.7 附录 G　关键参数总表 . . . 52
A.8 附录 H　复现一份结果的步骤 . . . 53
A.9 附录 J　术语表 . . . 53
A.10 附录 K　引用本文结论时的常见误用 . . . 54
A.11 附录 L　五张关系表的字段清单 . . . 54
A.11.1 表结构与字段 . . . 54
A.11.2 可以进入模型的特征与禁止特征 . . . 55

1 引言

营销预算的分配从来不是一个纯粹的预测问题。平台每期拿出一笔固定预算，运营要决定两件事：这批用户里要不要发券、发给谁。两个决定互相耦合——发了券的人要付成本，成本决定能覆盖多少人，覆盖范围又决定整体收益。（券的面额在本文中固定，作为外生条件处理；面额本身的选择留待后续工作。）任何一环拍错，结果都不会在当期暴露：购买率照样上升，报表照样好看，只有利润在悄悄减少。

本文要回答的就是这一个问题：**在有限预算下、券面额固定的条件下，仅凭可观测数据，如何决定是否发券、发给谁、给多少预算，并说明所创造的净增量利润有多大、在什么条件下不再成立。**

1.1 一个可执行的决策问题

设平台有 $N = 200\,000$ 名“加购未支付”用户，首单购买率约 10%。运营持有预算 B，需要决定给哪些用户发券；本文固定券面额为 10 元，因此实际要决定的是“谁拿券”与“人均预算给到多少”，后者等价于决定覆盖多少人。记 $a_i \in \{0, 10\}$，未获券者 $a_i = 0$。对每名用户，本期净贡献利润记为 $\Pi_i(a_i)$，它与用户是否下单、下单金额、是否核销、是否退款、以及券的成本同时相关。

决策目标是最大化预算约束下的总净增量利润：

$$\max_{\{a_i\}} \sum_{i=1}^{N} \Big(\Pi_i(a_i) - \Pi_i(0) \Big) \quad \text{s.t.} \quad \sum_{i=1}^{N} C_i(a_i) \le B, \tag{1}$$

其中 $C_i(a)$ 是给用户 i 发面额 a 的期望券成本。这个式子看起来是一个标准的背包问题，难点全在两处：$\Pi_i(a) - \Pi_i(0)$ 不可直接观测；$C_i(a)$ 依赖用户是否核销，同样不可直接观测。前者是因果识别问题，后者是成本预测问题。

除预算之外还有一条风险约束。发券会改变退款行为——用户对一笔“便宜买到”的订单更容易退货，而退款单的收入要全额冲减、履约成本不回收、券成本也不退。于是即使利润为正，退款率的上升也可能超出可接受范围。用非劣效的语言表述：退款率的处理组与对照组之差，其单侧置信上界必须低于预先约定的界值 δ（本文取 0.5 个百分点）。利润是有效性的问题，退款率是安全性的问题；但后者的分母是全部被分配用户，因此它也随销量同步变化——这一点在结果章会被拆开来看。

1.2 购买率与 GMV 的局限

把主指标定在购买率或 GMV 上，会遇到三种无法区分的机制。

真实增量。一部分用户本来不会下单，因为券而下单。购买率上升，利润同向上升，这是发券真正创造的价值。

利润侵蚀。另一部分用户本来就会下单，领了券只是把原本要付的钱少付了一部分。购买率不变（他本来也会转化），利润却下降了整整一个券的成本。极端情形下，一个本来会以 200 元成交的用户领到 10 元券，平台的净收入直接少 10 元。

需求提前。用户本来下个月会买，因为券提前到本月。7 天窗口内购买率上升，30 天窗口内被抵消，全年看接近于零。它在任何一个短窗口里都表现为“有效”。

三种机制对购买率的作用方向相同，对利润的作用方向相反。这意味着**购买率与 GMV 都不是利润的充分统计量**，用它们做决策，等于把三种方向相反的效果按一个方向加总。GMV 的问题更直接：它按毛额统计，不扣退款，也不扣券的成本——一笔被退掉的订单在 GMV 里仍然是“成交”。

净贡献利润则不同。它把收入、商品成本、履约成本、券成本与退款手续费放在同一个式子里，三种机制对应三种不同的符号组合。代价是它更难估：利润是零膨胀、重尾、且方差远大于均值的变量，绝大多数用户贡献恰好为零。

1.3 真值已知环境的必要性

因果推断在真实业务里有一个无法绕过的困难：**个体的反事实不可观测**。对已经发券的用户，我们永远不知道他不领券会怎样；对没发券的用户，也不知道他领了会怎样。因此任何估计的偏差都不可核对——只能比较不同估计量之间的一致性，而它们可能同时错在同一个方向。

本文的做法是把数据生成过程写成显式机制，使真值从“不可观测”变成“可计算”。对每名用户，两个潜在结果 $Y_i(1)$、$Y_i(0)$ 由同一组随机变量生成，真值由解析式给出，而不是由任何估计量给出。于是“估计偏差”从一个抽象的评价变成一个有符号、有量级的数。

这样做有明确的代价：结论只对设定的机制成立，不能外推到真实企业。为了把代价压到最小，本文在参数化时遵循两条约束。其一，机制参数取业务可解释的目标量——购买率取 10%，处理效应取 5 个百

分点，退款率取 7.5%，核销率取 0.55——而不是为了让某个方法“看起来有效”而挑选的数值。其二，凡涉及“某个方法在某种条件下失效”的陈述，都必须是实验跑出来的结果，不得作为先验写入代码注释。

需要强调的是，**合成数据的价值不在“数据像真的”，而在“错可以被指认”**。当 L3 的未调整估计比真值高出 6 倍时，这个 6 倍是可以核对的，因为它旁边就写着真值；在真实数据上，同样的错误只能表现为两个估计量不一致，而无法判断谁对。

1.4 与既有研究的定位

本文站在三条研究传统的交叉处，与每一条的关系都需要说清，因为它们各自解决了问题的一半。

其一，增量效应的识别。因果推断的文献已经提供了完整的工具箱：随机实验给出无偏的平均效应，倾向得分与双稳健方法把识别条件从“随机化”放宽到“可忽略性”，机器学习方法进一步把条件平均处理效应当作回归问题来解 [1, 2, 3]。这条传统的成熟度很高，但它有一个共同的前提：**没有人知道估计对不对**。评估只能在不同估计量之间比一致性，而它们可能同时错在同一个方向。本文不打算再加一个估计量，而是把“对不对”变成可计算的量。

其二，预算约束下的策略学习。把个体效应转成决策，需要在预算约束下解一个组合问题；营销与定价文献里这条线通常以“给定效应估计，如何分配预算”的形式出现 [4, 5]。这条传统关心的是优化，通常假定效应估计是准的。本文的发现对这一假定构成直接挑战：在某些机制下，一条只用可观测特征的简单规则就能胜过基于估计效应的优化，原因不是优化算法不好，而是估计效应里没有足够的信息。

其三，模拟验证。用已知数据生成过程检验方法，在统计学与计量经济学里是标准做法 [6, 7]。这类研究通常聚焦于一个方法在一种失效模式下的表现。本文的差别在于**分层**：把失效拆成“分配无关”“金额链路”“时间漂移”“未观测混淆”四类，分别检验，从而使“哪一步失灵”可以被指认，而不是笼统地报告一个偏差数字。

三者的交叉点正是本文的位置：**用模拟验证的方法，去检验“从数据到决策”这条完整链路，并把每一环的失效定量化**。这与“提出一个新估计量”或“提出一个新优化算法”是不同类型的工作——它的产出是一张地图，标出哪些地方可以走、哪些地方会掉下去。

1.5 研究问题与假设

全文围绕四个问题展开，每个问题对应一层。

问题一（L0）：在机制最干净的环境下，估计量本身是否无偏、区间是否校准？假设 H1：平均效应无偏，但利润的零膨胀与重尾会使样本量需求与购买率脱钩。

问题二（L1）：引入真实金额链路与个体异质性后，“估得准”是否仍能转化为“发得对”？假设 H2：平均效应仍可无偏，但个体层面的排序质量会显著低于平均层面的精度——即“平均无偏”与“个体可用”是两件事。

问题三（L2）：结论在时间维度上是否稳定？假设 H3：若拆分按时间进行，测试段与全量会给出不同甚至相反的结论；按用户随机拆分则会掩盖这一现象。

问题四（L3）：未观测混淆会把结论推到多远，失效是可检测的还是突变的？假设 H4：混淆强度的边际作用递减；估计量在混淆下的偏差方向取决于混淆因子与结果的相关方向，而不是固定的“高估”。

这四个假设在结果章逐一被检验，其中 H2 与 H3 被证实的方式与预期不同——H2 的“排序质量低”远超预期（相关系数 0.10），H3 则显示符号反转而非幅度衰减。

1.6 分层递进的设计依据

如果只造一个“复杂”的环境，得到的结论会是“在这个设定下方法有效/失效”，无法回答更关键的问题：**是哪一条假设被破坏导致了失效**。

本文因此把环境拆成四层，每层只放松一条假设。

L0 保留利润的零膨胀与重尾，但处理分配与结果无关、成本同质。它是“机制最干净”的一层，用来确定估计量本身的下限——如果一个估计量在 L0 都有偏，问题出在估计量而不在识别。

L1 引入真实金额链路与个体异质性：用户先有购物车金额，券只对首单生效，首单金额是购物车的随机比例，已转化用户以固定概率产生复购且复购不带券；处理效应随可观测特征变化。这一层开始区分“平均效应估得准”与“个体效应排得对”。

L2 引入时间与人群：分周投放、平滑漂移、人群构成变化、结果成熟延迟。它检验的是结论在时间维度上的稳定性——同一个策略，在窗口的不同位置是否给出相同结论。

L3 引入未观测混淆：处理分配依赖一个不可观测的个体特征，且该特征与结果相关。这一层不再问“方法能不能用”，而是问“它在多大的混淆强度下开始失效，失效是可检测的还是突变的”。

分层的作用是让失效**可以被归因**，但归因的适用范围要说清：**层与层之间的绝对水平不可比**，因为每一层的购买概率都被校准到各自的目标水平，锚点不同。可比的是层内的相对变化——在同一个分支里只转动一个旋钮，得到的差异才是这条机制的作用。本文因此把 L0 至 L3 当作四组并列的压力测试，而不是一条可以直接相减的阶梯；能跨层比较的只有方向与结构。

1.7 主要结论

本文的主要结论有五条，其中两条对 “发券是好生意” 这一直觉不利。

流程本身是校准的。 1000 次零效应重复的合并假阳性率为 0.046，95% 精确区间 [0.0339, 0.0609] 覆盖名义水平 0.05；标准误校准比 0.987 至 0.995。这说明后续所有显著性结论不是流程自发生成的。

混淆改变的是被估量的量级，不是精度。前三层核心格各 500 次重复的平均处理效应为 0.243、0.283 与 0.288 元/人，彼此接近；L3 的核心格为 1.664 元/人，但它的校准锚点与前三层不同，**本文不对这个 6 倍差作解释**。可解释的是同一分支内的相对变化：只改变混淆强度，效应由 1.664 单调升至 1.5 时的 2.229（+34%），两端同时放大时达到 3.944。混淆进入的是结果方程，不只是误差项。

决策层的两项判定都成立，但成立的方式不同。在 200 次独立随机验证中，“发券值得” 在 196 次（0.98）中成立，平均增量 0.282 元/人；“定向优于同预算随机” 在 190 次（0.95）中成立，平均高出 0.214 元/人。但后一项的通过完全由估计质量决定：使用因果森林的 105 次与使用 DR-learner 的 12 次全部通过，使用常数策略的 7 次全部不通过。

护栏是不是约束，取决于投放松紧。全员发券时，退款率比对照高 0.42 个百分点（L0 至 L2）至 0.68 个百分点（L3），后者已越过 0.5 个百分点的界值。而按 0.2 元/人档定向发券时，退款率只高出 0.137 个百分点，单侧上界 0.220 个百分点，护栏仍有明显余量。同一个护栏指标，在两种投放松紧下给出相反的判断——这不是矛盾，而是分母与覆盖范围不同。

样本量的约束者往往不是主指标。利润是零膨胀重尾变量，方差远大于均值；在同样的样本量下，可检测的利润变化远大于可检测的购买率变化。因此以利润反解样本量会系统性地低估所需规模，反过来以购买率反解又会高估利润的检测能力。这一错位不是精度问题，而是指标选择问题。

1.8 全文结构

第 2 节给出研究方法：决策问题与目标量、四层数据生成过程、金额链路与账务口径、估计方法、策略与预算优化、评价与校准设计。第 3 节按 L0 至 L3 的顺序报告结果，先给出四层共用的流程校准，再逐层给出该层新增机制带来的变化，最后汇总跨层结论与其边界。第 4 节讨论这些结论对业务决策的含义、证据强度的分级、方法的失效条件，以及后续工作。附录给出数据字典、参数表与补充结果。

全文的技术路线如图 1：从业务问题出发，先确定目标量与口径，再构造四层环境，随后在每一层上分别检验流程校准、平均效应、异质性与策略价值，最后回到业务问题给出结论与边界。

2 研究方法

本章交代四件事：目标量如何定义、数据如何生成、模型如何估计、结论如何判定。四件事被同一个约束串起来——个体的反事实不可观测，任何估计都必须借助假设，而假设一旦错了，偏差不会自己显形。本文因此把数据生成过程写成显式机制，使真值从 “不可观测” 变成 “可计算”；同时坚持真值只用于评价，不进入学习与选模。方法的每一处取舍都对应一个具体问题：这个量回答什么、在什么条件下不成立、失效时偏差朝哪个方向。

2.1 决策问题与目标量

研究对象是模拟平台上的一次首单券决策。用户进入 “加购未支付” 资格后，营销团队在观察窗口开始之前，仅依据分配时可见的信息 X，决定是否发放一张 10 元首单券。决策单位是用户，不是订单，也不是曝光。主指标是相对不发券的净增量贡献利润，单位为元每合格用户，观察窗口 30 天；同时记录 7 天支付购买率作为诊断指标、订单总额与退款后净交易额作为过程指标，并对退款事件率设置预设的非劣效界值。

把 “该不该发” 写成决策问题，三类错误的区别才清楚。对用户 i 投放券的净收益是 $\tau_{\Pi}(X_i)$，成本 $\hat{D}_i$ 只在核销时发生。在人均预算 $\bar{c}$ 下选择集合 S，使 $\sum_{i\in S}\tau_{\Pi}(X_i)$ 最大，约束为 $\sum_{i\in S}\hat{D}_i \le \bar{c}$。这是一个标准的背包形式，难点全在两处：$\tau_{\Pi}$ 不可观测，$\hat{D}_i$ 只在核销时为正、同样不可直接观测。前者是因果识别问题，后者是成本预测问题，处理方式不同，不能用一个模型一并解决。

符号在全章固定，同一符号不在不同位置改含义。后文出现 “预算”“成本”“效应” 时一律指表中的定义，口语里的同名词不参与推导。

表 2-1　符号与约定

符号 / 术语	含义	首次出现处
X	分配时可见的协变量（六字段白名单）	决策问题与目标量
$W \in \{0,1\}$	是否发券	净贡献利润的定义
$\Pi_i(w)$	用户在动作 w 下的潜在净贡献（已扣券成本）	净贡献利润的定义
τ	ITT 意义的平均效应 $E[\Pi(1)-\Pi(0)]$	净贡献利润的定义
$\tau_\Pi(X)$	条件平均效应，用于排序	净贡献利润的定义
D_i / $\hat{D}_i$	真实核销成本 / 预测期望核销成本	成本模型
$\bar{c}$	人均计划预算	决策问题与目标量
π	决策规则 $\mathcal{X} \to \{0,1\}$	净贡献利润的定义
$V(\pi)$	策略价值 $E[\pi(X)\tau_\Pi(X)]$	净贡献利润的定义
S	投放集合 $\{i : \pi(X_i) = 1\}$	三类错误
$e(X)$	倾向得分 $P(W = 1 \mid X)$	估计方法
$\mu_w(X)$	结果面 $E[Y \mid X, W = w]$	估计方法
ψ_i	AIPW / DR 伪结果	估计方法
后悔	相对真值最优策略的价值损失	后悔的分解
ESS	有效样本量，权重诊断	四个观察性估计量
护栏	退款事件率的非劣效约束	三类错误
Tier1 / Tier2	正式重复证据 / 机制扫描格证据	实验条件与可复现性

2.1.1 分析单位与分析分母

分析单位是进入资格的用户，不是订单，也不是核销记录。这个选择决定了后面所有比率的分母：净增量利润、退款事件率与预算执行率的分母都是随机分配的全部用户，包含未购买者、未核销者与退款者。分母一旦随行为变化，收益就会被系统性地放大——把未购买用户剔出分母，人均利润立刻变好看；只保留核销用户，退款率立刻变难看。两种改法都能让结论朝有利方向移动，且都不需要改动任何一个原始数字。

退款订单保留在样本里：收入全额冲减，履约成本不回收，券成本不退还。这不是一条会计细节，而是主指标的一部分。删掉退款单，等于把 “卖出去又退回来” 记成 “没卖出去”，退款率下降与利润上升会同时出现，两者都是删样本的算术后果，不是业务事实。

曝光表不进入主分母。触达是执行环节，分配是设计环节；把 “发了但没看到” 混进分母，会让效应估计依赖于触达系统的效率，而触达效率不在本文的决策范围内。曝光表因此只用于解释触达率，不作为分析单位。

有一处例外必须显式标注：成本与金额的校准分析只保留购买用户。它回答的是 “给定下单，金额与成本预测得准不准”，与 “这笔钱该不该花” 是两个问题，因此这类分析单独标出样本口径，不与收益结论并列。

分母还决定预算的规模。人均预算 $\bar{c}$ 乘以全部分配用户数得到预算总额；若分母换成购买用户，同一条 “0.20 元/人” 的预算会变成另一种总额，“同预算” 的比较随之失效。

2.1.2 净贡献利润的定义

净贡献利润把五个账务组件放进同一个式子：订单金额是收入，商品成本与履约成本是支出，券成本在核销时发生，退款则带来三件事——收入全额冲减、商品成本按比例回收、手续费另计。记 $\Pi_i(w)$ 为用户 i 在动作 w 下的潜在净贡献，已扣除券成本。观测到的只有 $\Pi_i = \Pi_i(W_i)$，另一侧永远不可见，这是 “个体处理效应不可识别” 在本设计里的具体形态。

目标量分两级。第一级是 ITT 意义下的平均效应 $\tau = E[\Pi(1) - \Pi(0)]$，它只依赖随机化，不依赖任何模型；第二级是条件效应 $\tau_\Pi(X) = E[\Pi(1) - \Pi(0) \mid X]$，用于排序。前者决定 “发不发”，后者决定 “发给谁”。把两级混成一个数字，是营销评估里最常见的口径错误：用平均效应去排序，等于假设每个人一样；用条件效应去回答 “整体值不值”，等于把一群人的加权平均读成一个人的效应。

决策规则是映射 $\pi : \mathcal{X} \to \{0,1\}$，其价值为 $V(\pi) = E[\pi(X)\tau_\Pi(X)]$。在人均预算 $\bar{c}$ 与期望成本 $\hat{D}(X) = E[D \mid X, W = 1]$ 下，可行集为 $\{\pi : E[\pi(X)\hat{D}(X)] \le \bar{c}\}$。本文比较的所有策略都定义在同一可行集里，差别只在 π 如何由估计量构造。这个写法把“模型好坏”与“规则好坏”分开：同一个 $\hat{\tau}_\Pi$ 可以喂给贪心、背包或业务规则，得到三个不同的 π，三者的差异才对应规则本身的作用。

净贡献是零膨胀、重尾、方差远大于均值的变量。多数用户恰好贡献零，少数用户贡献一个面额量级的正值，退款把一部分正值翻成负值。这三条性质决定了后文的三处设计：以利润反解样本量会严重低估所需规模；个体残差不能用来判断模型好坏；区间估计必须用影响函数，而不是给正态近似加一个常数。

券成本只扣一次。Π 已经扣过券成本，因此策略价值 $V(\pi)$ 的结果变量本身就是净贡献，不能再减一次。二次扣减在 0.20 元/人档上足以把符号翻过来：那一档的预算本来就只够覆盖一部分用户，多扣一次等于把整个预算再扣一遍。

消费者实付 $G - D$ 单列，它既不是收入也不是成本，只是资金流的一个中间量。把它当成“平台少收的钱”再扣一次，等于把同一笔 10 元券记成两次损失。

2.1.3 误差类型：假阳性、功效不足与口径错位

设 $S = \{i : \pi(X_i) = 1\}$ 为投放集合，三类错误可以逐一写出。

第一类是假阳性：$\{i \in S : \tau_\Pi(X_i) \le 0\}$。对本来不会因为券而多赚的人发券，购买率可能不变，利润却少了整整一个券成本。它的规模由投放集合中负效应者的占比刻画，这一占比不体现在任何购买率指标里。

第二类是功效不足：$\{i \notin S : \tau_\Pi(X_i) > 0\}$。漏掉能赚的人不产生直接损失，只产生机会成本。它在数据上的表现是“不显著”而不是“为负”——两者的区别在于，前者可能只是样本不够，后者是效应本身为负。

第三类是口径错位：分母、参照与指标三者之中有一个换了，结论的方向就换了。预算超支 $\sum_{i \in S} D_i > \bar{c} \cdot n$ 属于这一类的支出侧。它不是统计错误，而是执行与计划之间的差，用显著性检验既证不出也证不伪。

三者不能相互替代。把购买率当唯一指标，会同时奖励假阳性、掩盖功效不足，并对超支完全无感：购买率上升可以来自真实增量，也可以来自利润侵蚀，还可以来自需求提前，三种机制对购买率的作用方向相同，对利润的作用方向相反。净贡献则不同，它把收入、商品成本、履约成本、券成本与退款手续费放在同一个式子里，三种机制对应三种不同的符号组合。

退款风险单独处理。它不是目标函数里的罚项，而是收益主张成立的前提：以非劣效的语言表述，处理组与对照组的退款率之差，其单侧置信上界必须低于预设界值 $\delta = 0.5$ 个百分点。这样处理的代价是不允许用“退款少一点”去换“收益多一点”；好处是不需要把风险折价成钱，而折价系数在任何数据里都无法被检验。

设计范围同样需要写清：单一面额 10 元、单一动作（发或不发）、30 天窗口、不考虑网络溢出与长期生命周期价值。这些不是省略，而是结论的适用范围；超出该范围的场景需要重新设计，不能把本文的数字外推。

2.2 分层数据生成过程

合成数据生成过程由两条线构成：金额链路决定“一单能赚多少”，处理效应结构决定“发券改变了什么”。两条线分开建模，因为它们的失效方式不同——金额链路的错误影响所有层的量级，处理效应结构的错误只影响某些层的排序。把两者揉成一个黑箱，可以让数据看起来更“真实”，代价是任何偏差都失去归因。

2.2.1 四层的假设放松

如果只造一个“复杂”的环境，得到的结论会是“在这个设定下方法有效或失效”，无法回答更关键的问题：是哪一条假设被破坏导致了失效。本文因此把环境拆成四层，每层只放松一条假设。

表 2-2　四层设定与各层回答的问题

层	只改变的一类机制	主要旋钮	它回答的问题
L0	效应结构	购买概率增量的同质性、金额诱导的利润异质、等期望成本对照	在效应同质时，流程会不会把“没有差异”读成有差异
L1	可识别性	混淆强度、渠道遗漏、缺失机制、成本低估	当 X 不完备时，估计与决策各自退化多少
L2	规模与时间	人数、处理比例、时间漂移、人群构成、延迟成熟	样本量与时间结构如何改变精度与偏差

层	只改变的一类机制	主要旋钮	它回答的问题
L3	重叠与结构	处理侧结构参数 λ_T、$\lambda_T \times \lambda_Y$、共同原因缺失	识别假设被推到边界时，失效的方向与幅度

L0 是基线层。它保留利润的零膨胀与重尾，购买概率增量同质、允许金额诱导的利润异质，并设有等期望成本与异质成本的控制格。它用来确定估计量本身的下限：一个估计量若在 L0 就有偏，问题出在估计量而不在识别，因为这一层里分配与结果无关。

L1 引入真实金额链路与个体异质性。主实验 20 万人，按训练 10 万、验证 4 万、测试 6 万做用户级隔离；另设弱信号、漏渠道、缺失（MAR）、金额比例与成本低估等不利端。处理效应随可观测特征变化，这一层开始区分 “平均效应估得准” 与 “个体效应排得对”——两者可以一个成立、另一个不成立。

L2 引入时间与人群。人数 3 万、6 万、10 万、20 万与处理比例 0.5、0.3、0.1 完整交叉，另有时间漂移、人群构成变化与延迟成熟三类压力格。它检验的是结论在时间维度上的稳定性：同一个策略，在窗口的不同位置是否给出相同结论。

L3 引入未观测混淆。固定潜在结果与混淆强度，只扫描处理侧结构参数 λ_T 的四个取值（0、0.25、0.75 与 1.50）；另设 $\lambda_T \times \lambda_Y$ 的联合变化、极端重叠与关键共同原因缺失的配对格。这一层不再问 “方法能不能用”，而是问 “它在多大的混淆强度下开始失效，失效是可检测的还是突变的”。

L3 的机制可以写成两行方程，后面的所有结论都从这两行读出来。

结果侧。用户 i 在动作 $a \in \{0,1\}$ 下的购买概率为

$$p_i(a) = \operatorname{expit}\big(s_i(a) + \lambda_Y U_i\big), \tag{2}$$

其中 $s_i(a)$ 是由可观测特征决定的得分（动作 $a=1$ 相当于在得分上加一个偏移），U_i 是**不可观测且与全部可观测特征独立**的标量因子，取标准化 logistic 分布（均值 0、方差 1），λ_Y 控制结果对它的依赖强度。U 与 X 独立这一点是关键：它使 “混淆” 与 “异质性” 成为两件不同的事——U 不改变可观测特征的分布，只改变结果。

分配侧。用户被分配处理的概率为

$$e_i = \operatorname{expit}\big(\beta_0 + \beta^\top X_i + \lambda_T U_i\big), \tag{3}$$

其中 β 由七个可观测特征给出（是否新客 0.3、历史成交额 0.5、购物车金额 0.4、浏览深度 0.3、搜索渠道 0.1、推荐渠道 0.0、内容渠道 0.3，均为标准化后的系数），β_0 **在每次重复上重新校准**，使平均分配概率恰为目标值 0.5。λ_T 是处理分配对 U 的依赖强度，也是本文唯一用来度量混淆强度的量。

这两行方程给出三种可区分的情形，本文分别用格子去覆盖。

设定	λ_T	λ_Y	可忽略性	本文的用途
无混淆	0	0.5	成立	L3 核心格；此时估计量应当无偏
处理侧混淆	0.25 / 0.75 / 1.50	0.5	不成立	混淆强度的三点扫描
联合放大	1.50	1.50	不成立	两个通道同时变化的倍率

为什么真值必须对 U 积分。本节的目标量是 “只看 X 时的平均效应”，即把 U 积分掉的 $E_U[\tau_\Pi(X,U)]$。模型只拿到 X，所以拿它做的误差必须对积分后的真值计算；若改用含 U 的实现值，会把 “模型本来就不该看到的变异” 算成模型误差。这一条同时解释了为什么 λ_Y 的取值几乎不改变总体平均水平（U 在两侧都取期望后相消），而 λ_T 会改变——后者改变的是 “谁被处理”，前者只改变 “每个人有多大概率购买”。

每层只动一类机制，是为了让失效可归因：若四层同时改变多个旋钮，“估计变差” 就无法区分是混淆更强、样本更小还是重叠更差。层间差异因此可以直接读作某条假设的代价。

2.2.2 金额链路：购物车、首单与复购

金额不是一次性抽出来的，而是按业务顺序逐段生成。任何一段的规则改变都会改变真值，因此这一段写得比通常的数据字典更细。

1. **购物车金额。** V_i 来自下截断 Gamma 分布，截断前均值 130 元、标准差 60 元、下界 15 元，取整到分后存储。它是分配时唯一可见的金额来源，也是后文所有金额的起点。

2. **首单占比。** Q_i 来自截断正态，均值 0.70、标准差 0.10、取值 $(0,1]$；首单金额 $G_1 = \lfloor V_i Q_i \rfloor$，以分为单位，因此 $G_1 \le V_i$ 严格成立。下取整不是修饰，它保证首单金额永不超过购物车，否则 “用券买下整辆车” 这种不合业务逻辑的组合会出现。
3. **核销与抵扣。**发券且首单支付时，核销概率 0.55，抵扣额 $D = \min(1000\text{ 分}, G_1)$；未发券、未支付或未核销时 $D = 0$。核销率的分母是 “发券动作下的已支付首单”，不是全部分配用户；两个分母相差一个购买率，相差约一个量级。
4. **复购。**已支付首单以 0.05 的概率产生第二单，金额 $G_2 = \text{round}(0.55 G_1)$，半分向上舍入，复购不带券；复购的履约成本与首单共享同一次抽样。复购不带券这一条决定了券成本只发生在首单，也决定了 30 天窗口内的利润不能被 7 天窗口替代。
5. **退款。**已支付订单以 0.075 的概率退款，处理组乘以 1.03；退款延迟服从 $[1, 25]$ 天均匀分布；退款不退还券成本。三项合起来，使退款既改变收入的符号，也改变成本的结构。
6. **履约成本。**来自截断正态，均值 5 元、标准差 1.2 元、下界 0.5 元；其位置参数经过校准，使 “截断加取整” 之后的均值仍等于 5 元。未校准的截断分布会系统性地高于标称均值，而这 5 元在低面额档上就是全部利润。

所有金额以整数分存储，商品成本、回收成本与手续费按配置次序逐单舍入。真值沿同一条舍入链路计算，不使用未舍入的解析式；解析式只在推导误差界时使用。舍入不是细节：一单的舍入误差是分级的，在 0.04 元/人档上，逐单舍入的累积已不可忽略。

每一步都只在该步定义的条件下抽样，因此不同用户的金额链相互独立、同一用户内部相关。这种 “跨用户独立、用户内相关” 的结构，正是个体层面方差大而群体均值稳定的原因，也是后文区分 “均值精度” 与 “个体预测精度” 的数据基础。

2.2.3 时间结构与窗口定义

时间也被显式建模。首单延迟服从 $\text{Gamma}(2, 1)$ 天，截断在 $[0.05, 6.95]$；退款延迟服从 $[1, 25]$ 天均匀分布；复购延迟服从 $\text{Gamma}(6, 1.5)$ 天，截断在 $[1, 25]$，以首单时间为原点。窗口规则是 “不晚于分配时刻加 30 天”，边界取闭区间。

7 天购买窗与 30 天利润窗长度不同、用途不同，不能混用。前者的分母是分配用户，分子是 7 天内支付的首单；后者看 30 天内的净贡献，包含复购与退款。混用的后果是可预测的：用 7 天窗算利润，会漏掉 7 天之后才发生的退款；用 30 天窗算购买率，会把复购与延迟支付算成首单转化。两个方向的错误都会让指标看起来更好。

晚到退款的处理是保留事件、但不计入 30 天目标量。这使 “退款单不删” 与 “口径不混” 可以同时成立：退款单仍在样本里，退款率的分母不变，而超出窗口的那部分退款不计入利润。两种做法各有一个代价——删除会改变分母，计入会改变窗口——本文选择保留事件，因为它把代价放在了一个已知的位置。

时间结构的意义在于把 “延迟成熟” 变成可观测量。窗口太短时，一部分真实的利润事件会被截断，估计量出现向下偏差；偏差的大小取决于延迟分布的右尾，而不是取决于样本量。

2.2.4 退款机制与账务四格

退款是链路上唯一会把正贡献翻成负贡献的机制。它在账务上产生三项：收入全额冲减、商品成本按可回收比例找回、手续费另计。券成本不随退款退回，因为促销结算已经发生。

表 2-3　四格账务与净贡献

核销	退款	商品总额冲减	商品成本回收	券成本	净贡献
否	否	0	0	0	$G - gG - F$
是	否	0	0	D	$G - gG - F - D$
否	是	G	hgG	0	$-(1-h)gG - F - fG$
是	是	G	hgG	D	$-(1-h)gG - F - fG - D$

其中 g 为商品成本率、h 为退款可回收比例、F 为履约成本、f 为退款手续费率。四格的分工是：第一行是常态，最后一行是最坏情况，中间两行各缺一个条件。

四格账务在方法上只有一个要求：券成本只出现一次。“核销且退款” 一格的净贡献 $-(1-h)gG - F - fG - D$ 同时包含退款冲减与券成本，两者不重复——商品总额被全额冲回，可回收部分按 h 找回，手续费按 f 另计，券成本因 “券不退还” 而保留。若把券成本也算进冲减，这一格会比实际再低一个面额，而这一格正是利润率最薄、最容易改变结论的一格。

这条约束在策略层有一个直接后果：$V(\pi)$ 的结果变量本身就是净贡献，策略价值不能再减一次券成本。计算时对利润恒等式取 0 分容差，任何二次扣减都会立刻让恒等式失败，而不是等到结果看起来不对才被发现。容差取 0 而不是取一个宽裕的数，是因为这里没有“近似相等”的余地：所有金额都是整数分，恒等式要么成立要么不成立。

2.2.5 随机流命名与真值隔离

所有随机性由 $(\text{master_seed}, \text{stream}, \text{index})$ 三元组派生，不使用裸随机数。同一三元组永远给出同一串随机数；流的名字与索引一经确定即固定，新增一条流不会扰动已有流，因此新增场景不会改变既有场景的任何一位数字。

命名规则同时承担复现与隔离：同一三元组给出同一串随机数，而处理分配、金额、退款、延迟各用一条流，改动其中一条不会连带改动另一条。层间差异才能读作机制差异，而不是随机数错位。

观测侧与真值分开存放。学习与选模只读观测侧，真值只在评价与审计时打开。这条物理隔离针对的是一类具体错误：拿真值挑模型、再用同一份真值报告表现。它不依赖研究者的自觉——训练入口拿不到真值文件，“不小心用了真值”在结构上就不可能发生。真值本身的用途只有两个：在评价时给出靶子，在审计时给出对账的基准。

2.3 关系表与查询契约

五张表的字段清单较长，完整表格见附录 L；这里只保留两条与结论直接相关的约束。

其一，分母只从用户表取。任何人均指标的分母都是随机分配的全部用户，而不是成功支付或核销的用户；未下单用户在结果表里记 0，但保留在分母中。**其二，进入模型的特征有白名单。**退款、核销、券成本等结果侧字段一律不得进入特征集，否则模型会直接学到答案。

2.4 估计方法

在 L1 主实验上比较五类条件平均处理效应估计器：常数基线、S-learner、T-learner、因果森林 [2, 3] 与 DR-learner [5]。元学习器的组装方式沿用既有定义 [1]；所有需要 nuisance 估计的步骤统一采用交叉拟合与 Neyman 正交 [6]，以降低过拟合带来的偏差。

2.4.1 核心格所用的估计量

四个核心格的平均处理效应由**未调整的均值差**给出：取处理组与对照组的净贡献利润均值之差，购买率与退款率则由两个比例的差给出。这既是实践中最常见的做法，也是“不做任何调整时会发生什么”的基准。

选择它有两个理由。其一，它把“调整”这一步排除在外，使 L0 的结论成为**估计量本身的下限**——如果在分配与结果完全无关的环境里连均值差都有偏，问题就出在更基础的地方。其二，它让 L3 的对照有意义：同一把尺子量四层，层间的差异才可归因于机制，而不是归因于“某一层用了更好的估计量”。

代价必须写清：**均值差在分配依赖可观测特征时，估的是处理组的平均效应（ATT），不是总体平均效应（ATE）。**两者在效应同质时相等，在效应异质时不等。本文因此在第 3 节对四个核心格都报了 ATE 真值，并在 L3 上额外算了 ATT 真值，用来判定 1.66 这个数到底偏在哪里。

2.4.2 平均处理效应与五个条件平均处理效应模型

五个候选模型不是“复杂度递增”的排列，而是对同一个目标量的五种不同近似。它们的差别不在于谁更“先进”，而在于对哪一类数据结构更敏感。

- **常数。**随机化数据上用训练集 ITT，观察性数据上用交叉拟合的 DR ATE。它给每个人同一个效应值，因此只能回答“发不发”，不能回答“发给谁”。把它放进候选池，是为了让“排序没有信息”成为一个可以被选中的答案，而不是一个只能被拒绝的假设。
- **T-learner。**在处理组与对照组上分别拟合 $\hat{\mu}_1(X)$、$\hat{\mu}_0(X)$，取 $\hat{\tau} = \hat{\mu}_1 - \hat{\mu}_0$。两组样本量不均衡时，两个模型的误差不会相互抵消，反而会在差值里叠加。
- **S-learner。**只拟合一个模型 $\hat{\mu}(X, W)$，把 W 当作普通特征，取 $\hat{\tau} = \hat{\mu}(X, 1) - \hat{\mu}(X, 0)$。它共享样本，但容易把处理效应当作噪声压掉，尤其在效应相对于结果方差很小时。
- **因果森林。**以诚实分箱构造局部矩估计，300 棵树、叶节点最小样本 60、内部 3 折，处理变量按离散处理建模。它给出的是局部平均效应，外推能力受重叠约束：一个在数据稀疏区被问到的用户，得到的值实际上来自邻近区域。
- **DR-learner。**在交叉拟合的伪结果上做回归，最终模型为 LightGBM 回归器；它在响应面与倾向得分之一正确时保持一致。

LightGBM 的公共超参数在所有使用它的模型上固定：300 棵树、学习率 0.05、31 个叶节点、叶节点最小样本 40、行采样与列采样各 0.8。固定超参数是为了让模型之间的差异来自结构而不是调参运气；调参本身会引入一层选模噪声，这层噪声不进入本文的比较，否则 “哪个模型更好” 会混入 “谁被调得更久”。

交叉拟合把样本划成 K 折，第 k 折上的 nuisance 由其余折拟合，再在该折上取残差。DR-learner 的伪结果为

$$\psi_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{W_i - \hat{e}(X_i)}{\hat{e}(X_i)\,(1-\hat{e}(X_i))}\,(Y_i - \hat{\mu}_{W_i}(X_i))\,, \tag{4}$$

在响应面与倾向得分都正确时无偏，在两者之一正确时仍一致。折划分在同一重复内对所有候选模型固定，因此模型之间的差别不来自折的不同——若每个模型各划一套折，比较里就混进了折的随机性。

两级目标量在这里要再强调一次：平均效应决定 “发不发”，条件效应决定 “发给谁”。五个模型估的都是后者，但评价它们有两套方式——排序价值与逐点误差。前者关心名单，后者关心曲面；一个模型可以排序很好而逐点误差很大，反之亦然。本文以排序价值选模，逐点误差只作报告，因为决策只用到排序。

2.4.3 观察性估计量及其失效方式

观察性对照的设计落在 L3：朴素差分、逆概率加权、双稳健（AIPW）与倾向得分匹配。四个估计量针对的目标量并不相同——前三个针对总体平均效应，匹配针对处理人群的 ATT——把它们并排放，是为了看同一种混淆下它们各自偏多少、偏往哪个方向。

朴素差分是处理组与对照组的均值差，不做任何调整。它把选择偏差与处理效应混在一起，作用是给另外三个估计量提供一个 “完全不调整” 的参照：任何调整方法的改进幅度，都应当相对这条基线来读，而不是相对零来读。相对零读会把 “改善了一点” 夸大成 “接近无偏”。

逆概率加权用可观测协变量上的 Logistic 回归估计倾向得分，再做加权均值差。两个实现选择影响读法。其一，权重用 Hájek 归一化而不是 Horvitz–Thompson，前者在极端权重下更稳，代价是轻微的小样本偏。其二，倾向得分截断在 99 分位，截断本身引入偏差，因此实现里同时报告被截断的样本数、最大权重与有效样本量。把有效样本量报出来，是因为 “权重把有效样本吃掉” 这件事不体现在点估计上，只体现在精度上：只看点估计，会得到 “加权很稳” 的错觉。

双稳健（AIPW）把结果模型与倾向得分组合成

$$\hat{\tau} = \frac{1}{n}\sum_i \left[\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{W_i(Y_i - \hat{\mu}_1)}{e(X_i)} - \frac{(1-W_i)(Y_i - \hat{\mu}_0)}{1-e(X_i)}\right], \tag{5}$$

结果模型用 LightGBM，倾向得分截断在 0.01 与 0.99。双稳健的含义是 “两个模型有一个对就一致”，但这里有一个必须说明的简化：结果模型在全样本上拟合，没有做交叉拟合。识别假设成立时，这只会带来轻微的过拟合乐观；识别假设被破坏时，它救不了任何东西。

倾向得分匹配做 1:1 最近邻、有放回、卡钳 0.02，目标量是处理人群的 ATT。有放回避免 “抢同一个对照” 的顺序依赖，卡钳避免把倾向得分差太远的人配成一对。标准误用配对差值的标准差除以配对数，这个近似忽略了对照被重复使用带来的相关性，会低估标准误；实现里把这一点写进诊断字段，而不是事后补一句免责——诊断字段会跟着每个结果一起出现，免责不会。

四个估计量的共同失效来源是同一件事：隐藏变量 U 不在可观测 X 里，估出的倾向得分是 $e(X)$ 而不是 $e(X,U)$。L3 的扫描因此不改估计器实现，只改数据侧的结构参数：处理侧结构参数 λ_T 的四个取值移动重叠程度，$\lambda_T \times \lambda_Y$ 的联合变化同时移动混淆强度与效应异质性，另设极端重叠与关键共同原因缺失的配对格。

设计上要回答的顺序是：识别假设被破坏到什么程度时，平均效应先偏，还是个体排序先失效。这两个问题对应两种不同的业务后果——前者让 “发不发” 的结论错，后者让 “发给谁” 的名单错，而平均效应仍然看起来正常。

2.4.4 选模准则：验证集下界而非真值

每个重复独立选模，准则为验证队列上交叉拟合 DR 策略价值的下置信界，预算档取自策略网格。用下界而不是点估计，是为了对高方差模型施加惩罚：一个点估计更高但方差更大的模型，在下界口径下会输给更稳的模型。这一条与预算约束下的直觉一致——宁可少赚一点，也不要一个可能翻负的名单。

选模只看观测侧的验证数据，不看真值。平局按固定顺序打破：常数、S-learner、T-learner、DR-learner、因果森林。固定顺序的意义在于可复现：换一条平局规则，同一份预测会选出不同的模型，“同一批候选下比较策略” 就不再成立。

选模与最终评价使用不同数据：验证队列选模，测试队列与审计区只报不选。这条安排的代价是可用样本变少，收益是 “用真值选模再报真值表现” 这条捷径被从数据流上切断。若两者共用一份数据，任何选模准则都会显得很好——因为它优化的正是它自己被评价的那个量。

2.5 策略与预算优化

把估计出的个体效应接入预算约束下的选择问题：在人均预算约束下选择投放集合，使预期净增量最大。评估统一用两个口径——绝对净增量，以及净增量与券预算之比 $R_{net} = NV_{inc}/C_{coupon}$。两个口径回答不同问题：前者回答 “这件事值不值”，后者回答 “每一元钱花得值不值”。预算绑定时两者同向，预算不绑定时会分开，因此两个都要报。

所有策略在同一重复、同一批用户、同一预算档上配对比较。聚合前先检查各策略的选模构成是否被第三个变量改变——若某个策略更多地在 “选中了常数模型” 的重复上运行，它的平均表现反映的是选模分布，而不是规则本身。

2.5.1 策略与求解器

策略网格里的九个策略不是并列的 “方法”，而是回答不同问题的参照。

表 2-6　九个策略及其角色

策略	规则	角色
不发券	$\pi \equiv 0$	基线：收益与成本的零点
全券（无约束）	$\pi \equiv 1$	上界参照，支出远超预算，不可行
同预算随机	随机抽取至预算耗尽	回答 “钱撒出去有没有用”
业务规则	新客优先、再购物车金额降序	现行做法的代表
贪心（单位成本排序）	按 $\hat{\tau}_{\Pi}/\hat{D}$ 降序累加	主策略，成本归一
贪心（局部交换）	在贪心解上做两两交换改进	检验贪心是否被 “排序停手” 卡住
增量利润排序	只按 $\hat{\tau}_{\Pi}$ 降序，不做成本归一	分离 “排序” 与 “成本归一” 两件事
预测利润排序	按预测利润（非增量）降序	诊断：预测精度与增量排序的差别
购买倾向排序	按 $\hat{p}$(购买) 降序	诊断：把预测任务当决策任务的后果

九个策略里只有四个是决策方法（两个贪心、增量排序、业务规则），其余分别承担基线、上界、随机参照与诊断，使每个数字都有一个可读的对照：说 “贪心好”，对照是同预算随机；说 “成本归一无用”，对照是增量利润排序。

预算分配这一步有五种算法，目标函数与成本口径完全相同，差别只在 “能承诺什么”。

表 2-7　五个求解器各自能主张的范围

算法	做法	能主张	不能主张
贪心（单位成本排序）	按 $\hat{\tau}/\hat{D}$ 降序累加，装不下则跳过	一个可行名单；在同一预测下是 “排序 + 累加” 的定义	最优；在成本异质时会输给组合更优的解
局部交换	在贪心解上做成对交换，最多 10 轮，每轮只看价值最高的 500 个未选者	价值单调不降的可行解	全局最优（只是局部改进）
分币整数化 DP	金额与成本按分取整后做精确 0/1 背包	**分币整数化问题**上的最优	浮点原问题的最优（取整改变了问题）
时间受限 MILP	HiGHS，时限 60 秒（实际墙钟可超出时限）、相对间隙 10^{-3}	若返回 `optimal`：该浮点问题的最优；否则只报 incumbent、bound 与 gap	超时情形下的最优性；超时且无可行解时它根本不是名单
分数背包松弛	允许部分选中，求线性松弛上界	一个**上界**	可行解；不得当作策略

贪心不最优有一个最小的反例，比渐近讨论更有用。预算 10 元，三人成本 6、5、5 元，预测价值 12、9、9 元。按比值排序，先取比值 2.0 的第一人，花 6 元，此后任何一人都装不下，总价值 12 元；而最优解是后两人，花 10 元，拿 18 元。差距的成因不是排序错了，而是“整件取或整件不取”这个约束在成本异质时让排序失效。

贪心的实现是“排序加累加”：按 $\hat{\tau}_{\Pi}(X_i)/\hat{D}_i$ 降序取人，每加一人就累计期望成本，装不下的人跳过、继续看后一位，而不是遇阻即停。“跳过”与“中断”在成本异质时给出不同名单，前者才配得上“按单位成本排序”这个名字。它不需要求解器，因此与背包式分配在同一组预测下的差距，就是优化误差里可以被观测到的部分；而在预测本身很粗时，这个差距远小于换模型带来的差距。

局部交换针对的正是贪心的形态：它允许移出一个已选、加入一个未选，但只在价值严格上升且预算可行时接受，最多 10 轮，每轮只看价值最高的 500 个未选者。因此它只能改良，不能保证跳到最优——它的价值在于把“排序停手”与“组合次优”这两件事分开。

精确解的主张范围要卡得更死。分币整数化的动态规划把金额与成本按分取整后做精确 0/1 背包，时间与内存都是 $O(n \times \text{预算分数})$，只在小池子上跑得动；它把浮点问题离散化之后再求最优，因此只能说“在分币整数化问题上最优”，不能说“原问题最优”。MILP 走另一条路：由 HiGHS 在 60 秒时限内返回 incumbent、bound、gap 与状态，相对间隙 10^{-3}；只有状态为 `optimal` 时才可以声称最优，超时情形下只报 incumbent、bound 与 gap，连可行解都没找到时，返回的是“这个规模在时限内不可解”这一事实，而不是一个空名单。分数背包松弛允许部分选中，给出的是上界，不是可行解，因此它出现在表里是为了标定“最好可能有多好”，不能当作策略。

三个实现细节会改名单，必须一起交代。

平手规则固定。比值 $\hat{\tau}/\hat{D}$ 相同的人需要一个确定的先后；规则固定为 `user_id` 升序，实现上对候选做稳定排序，同分者的顺序由输入顺序决定、不读随机数。换一条规则（随机平手，或按成本升序），同一份预测会给出不同名单，“同预算同预测下的策略比较”就不再可复现。

预算容差不是宽松。判断“还装得下”用 $\text{spent} + c \le \text{budget} + 10^{-9}$，容差只为吸收浮点累加的舍入误差，单位是元，比任何一张券的面额小十几个数量级。真实支出越过计划（179/200）来自成本随机性，与这个容差没有因果关系；把两者混为一谈，会让超支看起来像实现缺陷，而不是成本口径问题。

候选集只含预测增量为正的人，但仅限定向类策略。贪心与背包类求解器只对 $\hat{\tau} > 0$ 的人排序：花零元买负收益不是“免费”，而是把预算换成负价值。随机臂不适用这条规则——它在全体用户上按种子排列装填，因此“定向对随机”的差额里混有“负预测者被排除”这一项；正文把这个差额按覆盖人数与人均效应分别报告，而不是整体当作“选得更准”。

2.5.2 成本模型：两阶段乘式与它的三处薄弱

预算约束里的 $\hat{D}_i$ 不是查表常数，而是一个预测量。成本模型写成两阶段乘式：

$$\hat{D}(X) = \text{面额} \times \hat{P}(\text{购买} \mid X) \times \hat{P}(\text{核销} \mid \text{购买}, X) \tag{6}$$

两个条件概率各由一个 LightGBM 分类器给出，超参数与估计章的模型共用同一组固定值；另有一个直接对券成本做回归的辅助模型，只作对照，不参与选人。主口径锁定两阶段乘式，是为了避免“两套成本口径择优”：成本口径一换，预算能覆盖的人数与名单都会变，事后挑一个更好看的会让不同策略失去共同参照。

乘法结构对应两条业务事实。第一，券成本只在核销时发生，核销以购买为前提，因此这是一个条件分解；未购买的人成本恒为零，不是“成本很小”。第二，两个因子可以分别检查：购买率估错与核销率估错对应不同的业务问题——券没打动人，还是打动了却没人用——合成一个回归就分不开。

把面额当成本是这条链路上最常见的口径错误。核销有条件，平均成本只是面额的一小部分，用面额卡预算会把可投放人数压到原来的一个零头；策略看起来“保守稳妥”，实际是口径错位。

训练样本有一条硬约束：成本模型只在**处理组**上拟合。对照组没有发券，券成本恒为零；把对照组混进训练集，模型学到的是“处理概率乘以成本”，在低处理比例的场景里直接压向零。本文的处理比例从 0.5 到 0.1 都有，同一错误的幅度随格而变，因此它不能靠调参吸收。

预测端有三个可调项，语义必须分开。**偏差乘子**乘在预测上、真实成本不变，回答“成本估计整体偏低或偏高时策略退化多少”；L1 的 under 与 over 两格分别取 0.8 与 1.2，测的是决策端对成本误差的敏感度，不是估计器的稳健性。**成本下界**在乘子之后施加，保证比值排序不出现除零，是数值保护而非业务假设。**乘性对数噪声**的配置项已经存在，但当前实现只接受 0，非零值直接报错——这意味着本文没有做“成本预测带随机噪声”的敏感性分析，也不能把噪声设为零读成“噪声不影响结论”。显式拒绝比静默按零处理诚实：后者会让读者以为这项分析跑过。

校准与拟合是两件事。校准在验证期观测日志上计算偏差、斜率、平均绝对误差与相关系数，并同时报告常数预测器的同项误差作为参照。之所以要这个参照，是因为单用户观测成本是“核销 10 元 / 未核销 0 元”的伯努利实现，个体残差里大部分是不可约的二元噪声；不与常数预测器对比，就会把“个体层面本来就不可能准”读成“模型没有排序能力”。校准结果只用于报告，不回流改模型或阈值——一旦回流，验证集就变成训练集的一部分，后面所有以验证为名的选择都不再成立。

这个模型有三处薄弱。其一，两阶段乘积把两个估计误差相乘，而条件核销率只在购买者子集上估计，第二阶段的有效样本比第一阶段小一个量级，方差更大；购买率越低，这一项越主导。其二，模型给的是期望，个体实现只有 0 与面额两档，因此不能用个体残差判断模型好坏，只能在群体层面做校准与排序检查——均值几乎无偏而排序相关很低，是常见且必须分开读的组合。其三，成本与效应可能相关，按 $\hat{\tau}/\hat{D}$ 排序会把成本误差放大进名单，收益方向取决于成本分布与效应分布的相关结构；这一点无法先验排除，只能由“换掉排序向量”的对照来界定。

2.5.3 三种预算口径：期望、缓冲与面额上限

预算的基准是**期望核销成本**：$\hat{D}_i$ 由两阶段乘式给出，只在训练期观测日志上拟合；验证期观测日志只用于报告校准指标，不回流改模型。以期望成本而非券面额作预算基准，意味着“同预算”指的是计划的期望支出相同，而不是支出上限相同。这一区别在结果中会被反复引用：同样的 0.20 元/人，在两种口径下覆盖的人数相差一个量级。

保守比较另设两种模式。**缓冲模式**把固定的期望成本乘以 1.25，作为显式风险缓冲；**面额上界模式**按券面额 10 元计成本，取 $\lfloor$预算/10$\rfloor$ 人，它保证真实券成本绝不超过预算，但会大幅减少可投放人数。两种模式的产出都只作敏感性参考，不作为主结论；主结论一律在期望成本口径下给出，并单独报告真实支出与预测支出的比值。

预算档取 0.04 至 1.00 元/人共八档，各档独立运行；预算总额等于人均预算乘以全部目标用户数。八档不是等差数列，而是四个区段各取代表，每段回答不同的问题。

表 2-8　预算档网格与各档检验的内容

区段	档位（元/人）	它检验什么
极小预算	0.04	名单极短时排序是否还有意义；随机臂同样很小，两臂抽样噪声都大
主档与审计档	0.10、0.20	0.20 是主档，收益与护栏判定都在此档；0.10 用于中等预算的对照与审计
中档	0.30、0.40	约束仍绑定但名单接近饱和，看效率随预算下降的速度
饱和与不绑定	0.60、0.80、1.00	0.60 起价值不再上升；后两档确认“约束由绑定转为不绑定”之后的行为

网格在动数据之前固定，因此“某个策略在哪一档翻面”不能事后挑档位来讲。八档覆盖的不只是预算大小，还有名单长度的三种状态：极短、绑定与不绑定。只在主档上比较，会把“排序有没有空间”与“排序准不准”混为一谈；只在高档上比较，则会因为约束不绑定而看不到预算的边际作用——1.00 档上策略价值与 0.60 档完全相同，不是策略变好了，而是钱已经花不出去。

2.6 评价与校准设计

评估采用四类指标：净增量利润、退款事件率护栏、预算执行率与策略后悔。四类指标各自的分母不同，混用会直接改变结论的方向。

表 2-9　四类指标的分母

指标	分子	分母	用来判断
净增量利润	各臂净贡献之差的均值	各臂**全部分配**用户	这次投放值不值
退款事件率	发生退款的用户数	各臂全部分配用户	收益是否以退款风险换取

指标	分子	分母	用来判断
预算执行率	实际支出	计划预算	策略是否守住约束
策略后悔	真值最优价值减实现价值	名单人数	误差来自学习还是求解

其中“覆盖率”只用于区间方法自身的校准检验（如零效应重复与负对照），不作为任何收益结论的指标。把覆盖率写进收益表，会让读者以为它是效果量，这是常见的口径污染。

2.6.1 零效应重复、最小可检测效应与覆盖率

零效应重复检验的是流程在无效应时会不会误报。四层各 250 次，合并 1000 次；主指标为净增量贡献利润，双侧 0.05，报告合并假阳性率与 Clopper–Pearson 区间。判定只用合并值，逐层值只作描述——每层 250 次的区间半宽约 0.03，不足以支撑单层判定。另外两个标签（7 天购买率、30 天退款率）只作负对照，不参与判定。

这个设计把判定单位与报告单位分开：合并值 1000 次给出的区间窄，可以支撑一个关于流程的判断；单层 250 次给出的区间宽，只能看量级。

最小可检测效应由每臂人数、结果方差与显著性水平反解，功效目标取 0.80 与 0.90 两档。对人均净增量这类连续结果，两独立样本均值差的正态近似给出

$$\mathrm{MDE} = (z_{1-\alpha/2} + z_{1-\beta})\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_0^2}{n_0}}, \tag{7}$$

解析功效是同一公式的逆：

$$\mathrm{power}(\delta) = \Phi\left(|\delta| / \sqrt{\sigma_1^2/n_1 + \sigma_0^2/n_0} - z_{1-\alpha/2}\right). \tag{8}$$

因此零效应处它等于 $\alpha/2 = 0.025$ 而不是 0.05：这是“双侧检验、单方向功效”的口径，与双侧实测拒绝率不是同一个量，不能直接并列。

公式里的 σ 本是设计期假设值。实现上用两个字段分开记录：`nominal_power` 用实测的臂内 σ 与每臂人数重算，`nominal_power_registered_n` 用设计期 σ 在计划人数上重算；两者之差就是设计假设与实况之差。报数时报前者，并同时给出同格 100 次重复的实测拒绝率——只报设计功效，会让“设计上够用”与“实际上够用”混为一谈。

覆盖率是区间方法的自检量：零效应下，名义 95% 区间应以约 95% 的频率覆盖真值。它有两个常见误读。其一，把覆盖率当成效应量的依据——覆盖率高低只说明区间方法是否校准，不说明效应大小。其二，在低重复次数下读覆盖率——二项区间的宽度随重复数下降，重复次数少时，两三个百分点的差异无法区分，读数只会反映抽样噪声。

2.6.2 后悔的分解

策略层的误差容易被笼统地叫成“模型不准”，但预算分配里至少有四个不同来源，它们的参照系不同，处理方式也不同。记 π^* 为真值下最优的策略、$\hat{\pi}^*$ 为预测值下最优的策略、$\hat{\pi}$ 为实际执行的规则，前两项满足恒等式

$$V(\pi^*) - V(\hat{\pi}) = \underbrace{V(\pi^*) - V(\hat{\pi}^*)}_{\text{学习误差}} + \underbrace{V(\hat{\pi}^*) - V(\hat{\pi})}_{\text{优化误差}}. \tag{9}$$

学习误差回答“预测把最优选择指错了多少”，优化误差回答“给定预测，规则离最优解有多远”。恒等式成立的前提是三者共用同一个可行集：策略集合、预算档与用户名单一致时，两项可以直接相加。

另外两项不在恒等式里，因为参照系不同。**预算口径误差**是计划与执行之间的差：按预测成本卡住的预算，在真实支出下会越线；它由真实支出与预测支出的比值刻画，不由价值差刻画。**选模误差**是“验证集选中的模型”与“事后最优模型”之间的差，只在同一批候选模型内配对可比。

四项不能加成一个“总损失”再跨实验比较：前三项以真值最优为参照，第四项以事后最优模型为参照，相加会把两个不同的分母混在一起。可行的做法是分开报告：遗憾分解给出前两项，选模后悔给出第四项，支出比值给出第三项，各自带自己的分母，不相互折算。

2.6.3 判定口径在动数据之前冻结

这一节列的每一条判定规则——家族水平 0.05、护栏界值 0.5 个百分点、可靠性阈值 200 与 0.05、预算网格的八个档、选模的验证准则与平局顺序——都在跑数据之前写定。理由不是形式主义，而是这类评估的失败方式很单一：几乎所有 “看起来更好” 的结果，都可以在事后换一个口径之后得到。

换主指标是最常见的一种：利润不显著就看购买率，购买率不显著就看退款率，总有一个指标会给出想要的方向。对策是把三个标签的地位写死——利润是唯一主指标，另两个只作负对照；换标签必须重写设计并重跑，不能在同一批数字上再挑一次。

换分母是第二种：把未购买用户剔出分母，人均利润会立刻变好看；只保留核销用户，退款率会立刻变难看。第三种是换参照：定向相对不发券、相对同预算随机、相对真值最优，三个参照回答三个不同问题，事后选一个报，结论的方向可以完全相反。

固定口径的代价是失去灵活性。如果设计期选的界值确实不合适，处理方式是保留原判定、另报一个明确的敏感性分析，而不是把界值改掉再宣布成立。0.04 档在名单极短时判为 “无法可靠评估”，没有为了让表格好看而放宽阈值；三种预算口径各自报告，没有挑一个当官方口径。

逐重复的判定有明确的统计形式，不是 “跑出正数就成立”。两个随机化臂互不重叠，每臂的净贡献均值 $\bar{Y}_a$ 与标准误 $\mathrm{se}_a/\sqrt{n_a}$ 独立计算，主张 c 的差与标准误为

$$\hat{\Delta}_c = \bar{Y}_{\text{left}} - \bar{Y}_{\text{right}}, \qquad \widehat{\mathrm{se}}_c = \sqrt{\mathrm{se}^2_{\text{left}} + \mathrm{se}^2_{\text{right}}}. \tag{10}$$

零假设取 “差不超过 0”，单侧 p 值为 $p_c = 1 - \Phi(\hat{\Delta}_c/\widehat{\mathrm{se}}_c)$。两条主张组成家族，用 Holm step-down 控制单侧家族水平 0.05：升序后第一条按 $\alpha/2$ 判定，成立则第二条按 α 判定。报出的区间不是未调整的 95% 区间，而是按各自被检验时的阈值反演的下界，因此与判定一一对应。

护栏是另一条独立的单侧检验，方向相反：它要证明退款率的恶化不超过界值。记处理组与对照组的退款率为 $\hat{p}_t, \hat{p}_c$，分母是随机分配用户，

$$\hat{\Delta}_{ref} = \hat{p}_t - \hat{p}_c, \quad \widehat{\mathrm{se}}_{ref} = \sqrt{\tfrac{\hat{p}_t(1-\hat{p}_t)}{n_t} + \tfrac{\hat{p}_c(1-\hat{p}_c)}{n_c}}, \quad U_{ref} = \hat{\Delta}_{ref} + z_{0.95}\,\widehat{\mathrm{se}}_{ref}, \tag{11}$$

$U_{ref} < \delta_{NI} = 0.005$ 才算非劣效。这里用非合并方差，判据是上界而不是 p 值：“差异不显著” 不构成安全性依据，只有上界落在界值以内才行。三条主张同时成立，一个重复才算成立。

2.6.4 观测闭环：冻结、估计与审计

合成实验里真值随时可得，真实业务里没有。为了让 “没有真值时的估计” 也进入检验范围，观测闭环把一次评估拆成三个不可调换的阶段。

1. **构造与冻结**。在选人表上按策略与预算档生成名单，把名单、用户顺序、设计概率、预算与配置写入冻结记录，然后重新读取并与冻结值逐项对照；不一致就不进入下一步。
2. **估计**。只用观测侧结局拟合 nuisance，倾向得分已知时取设计值、未知时按折外预测，算出每个策略的离策略值与支出。这一阶段读不到真值。
3. **审计**。冻结记录不可改之后再打开真值，逐策略对账，报估计误差、符号一致性与支出误差。

协议的关键不是 “用了哪一个估计量”，而是顺序：估计先于真值可见，真值可见后估计不可改。否则任何一个不理想的估计都能在事后被 “修正”，审计就退化成自我确认。这条协议在 6 万人测试帧上做过一次完整执行。

协议还带一套可靠性判据：按策略实际用到的臂计算等效样本量，任一臂低于 200 或占比低于 0.05 就判 “无法可靠评估”。判不过的格子不参与收益主张，只作为结果报出来——它们标记的是 “这个估计不再代表这群人”，而不是 “这个策略不好”。

只有观测数据时，策略价值有三个并列的估计量。记 $\pi_i \in \{0,1\}$ 为策略是否给用户 i 发券、T_i 为实际处理、e_i 为倾向得分、Y_i 为含券成本的净贡献：

- **IPW**：$\hat{V} = \frac{1}{n}\sum_i \left[\frac{\pi_i T_i Y_i}{e_i} + \frac{(1-\pi_i)(1-T_i)Y_i}{1-e_i}\right]$；
- **SNIPS**：两臂分别归一化后按选择份额还原，$\hat{V} = \bar{\pi}\frac{\sum_i \pi_i T_i Y_i/e_i}{\sum_i \pi_i T_i/e_i} + (1-\bar{\pi})\frac{\sum_i (1-\pi_i)(1-T_i)Y_i/(1-e_i)}{\sum_i (1-\pi_i)(1-T_i)/(1-e_i)}$，牺牲无偏性换取对权重极端值的不敏感；
- **DR**：$\hat{V} = \frac{1}{n}\sum_i \left\{\pi_i\left[\hat{m}_1 + \frac{T_i(Y_i-\hat{m}_1)}{e_i}\right] + (1-\pi_i)\left[\hat{m}_0 + \frac{(1-T_i)(Y_i-\hat{m}_0)}{1-e_i}\right]\right\}$，响应面 $\hat{m}_w$ 由交叉拟合得到，两者之一正确即一致。

标准误一律取影响函数的大样本近似 $\widehat{\mathrm{se}} = \mathrm{sd}(\mathrm{IF})/\sqrt{n}$；配对差用 $\mathrm{sd}(\mathrm{IF}_A - \mathrm{IF}_B)/\sqrt{n}$，协方差自动进入，不假设两策略独立。随机化层用观测表记录的设计概率、不截断；只有观察性层才估计倾向得分并截断，截断计数与原始值同时保存。

权重诊断用等效样本量。按臂定义 $w_{1i} = \pi_i T_i / e_i$ 与 $w_{0i} = (1-\pi_i)(1-T_i)/(1-e_i)$，$\mathrm{ESS} = (\sum_i w_i)^2 / \sum_i w_i^2$，再除以该臂人数得到占比。权重必须带臂指示变量，否则占比的分子与分母不是同一批人。用 ESS 而不是最大权重，是因为它同时惩罚权重的极端值与集中度；判据只在策略实际用到的臂上生效——一侧完全不用时，那一侧的 ESS 再低也不影响估计。

2.6.5 跨重复聚合：先逐重复，再汇总

200 次重复的结论都按重复先算、再跨重复汇总，不把 200 个重复的样本拼成一张大表重算。三个理由。

每个重复的人群不同。每个重复重抽用户、重分训练、验证与测试，拼表得到的是一个不存在的“超总体”，其标准误不对应任何可部署的人群。分开算，每个重复的点估计各自有总体，跨重复的离散度才是“换一批用户会怎样”的直接度量。

配对差必须在重复内算。同一重复的两条臂共享同一批用户、同一份名单、同一个预算档，$d_r = \hat{\theta}_r^A - \hat{\theta}_r^B$ 才是同质的。若把两臂的跨重复均值各自算好再相减，等于放弃配对，把两臂共同的波动算进误差；所有“A 比 B”的数字都取自 d_r 的均值、跨重复标准差与胜出重复数，而不是两个边际均值的差。

比值有两种算法，两臂各用一种。效率类指标（每元真实支出换回的价值）可以先逐重复地算比值再平均，也可以先算均值再相除。随机臂是 200 份名单的平均，报告的是后者（均值总价值除以均值总支出），读作“这批重复合起来的效率”；贪心臂只有一份确定性名单，比值就是它自己的支出与价值之比。两臂的效率因此不是同一公式的结果，只用于看量级与方向，不进入显著性主张。

据此，每个跨重复结论都尽量同时给出三件事：均值、离散度（标准差或分位数）、方向一致的重复数。只报均值会把“平均为正”与“多数为正”混为一谈——4 个重复方向为正但在多重比较校正后不成立，正是两者分离的例子。

离散度也有两套数，用途不同：重复间标准差回答“换一批用户，单个重复的点估计会落在哪”，均值标准误 $\mathrm{sd}/\sqrt{R}$ 回答“这个均值本身有多准”。报均值区间时用后者，描述单个重复的分布时用分位数（2.5%、中位、97.5%）。把两者混用，会把“每次都不一样、但平均下来很稳”读成“每次都稳定”。

2.7 实验条件与可复现性

2.7.1 随机种子、重复次数与样本量

所有随机性由 $(\mathrm{master_seed}, \mathrm{stream}, \mathrm{index})$ 派生。主种子固定，重复编号进入 index，因此第 r 次重复在两次运行中完全一致；流名固定，因此新增一条随机流不会扰动已有流。这两条合起来保证“同一份代码在同一配置下给出同一组数字”，也保证不同场景之间的差异不来自随机数。

样本量按层设定。L1 主实验为 20 万人，训练 10 万、验证 4 万、测试 6 万，用户级隔离——同一用户不会同时出现在两个队列里。L2 把人数 3 万、6 万、10 万、20 万与处理比例 0.5、0.3、0.1 完整交叉，用于把“样本量不足”与“时间结构”两种失效分开。零效应重复四层各 250 次、合并 1000 次；重训 bootstrap 每格 200 次，固定策略 bootstrap 1000 次，只在主预算档 0.20 元/人上做。

重复次数分两档使用。正式重复（Tier1）用于结论，机制扫描格（Tier2）用于定位失效方向；两档不放在同一张表里排序比较，因为前者的重复数足以支撑区间，后者只能支撑“方向”这一级别的判断。

逐重复记录计划、成功、失败与有效重复数，并记录蒙特卡洛标准误与目标量。均值精度用 $\mathrm{sd}/\sqrt{R}$，覆盖率给二项区间，分布用分位数——三者不混称，因为分母不同：一是重复，二是伯努利试验，三是样本。

可复现还依赖一条运行条件：同一批重复使用同一份代码与同一份配置，重复之间只应有随机数不同，其余条件保持不变。若代码在批次之间改动，结果里就同时存在两种机制，差异会被误读成随机波动。

2.7.2 结论成立的条件

识别条件。估计量一致的前提是无未观测混淆或重叠足够；L3 表明这两个条件被推到边界时，平均效应先偏、排序后失效，且失效幅度与混淆强度不是线性关系。

窗口条件。 30 天窗口内的净贡献是目标量，7 天购买率只是诊断。若业务关心更长周期的价值，退款与复购的时点分布会改变结论，本文的窗口不覆盖这一情形。

口径条件。主结论在期望核销成本口径下给出；换成面额上限口径，可投放人数会大幅下降，效率类指标不再可比。预算档固定在 0.04 至 1.00 元/人的八档内，档外没有数据支持。

模型条件。成本模型只在处理组上拟合，两阶段乘式的第二阶段样本量比第一阶段小一个量级；处理比例越低，这一项的方差越大。特征限于分配时可见的六个字段，任何依赖分配后信息的特征都不在范围内。

数据条件。全部结论来自合成数据，机制由本文设定，参数取业务可解释的目标量。它们的价值在于错可以被指认，而不在于数据像真的；对真实企业，本文给出的是方法与判据，不是数值。

由此，本文的结论应读作一组条件命题：在设定机制、给定窗口与给定口径下，某个方法偏差多大、某个策略值多少、某个判据在多强的混淆下失效。条件之外的部分，需要新的环境与新的重复来回答。

3 结果与分析

本章按引言提出的四个提问依次展开。先给出四层共用的流程校准——如果这条流程本身会在零效应时产生显著结果，后面所有结论都不成立。随后逐层报告：L0 确定估计量本身的下限，L1 引入金额链路与异质性，L2 引入时间与人群变化，L3 引入未观测混淆。每一节的结尾给出该层结论成立的条件，第 6 节把四层放进同一张图，第 7 至 10 节处理策略层、护栏、观测闭环与重采样稳定性，第 11 节汇总本章结论的边界。

3.1 流程校准：自发显著结果的排除

3.1.1 零效应重复的假阳性率

校准的做法是在同一处理条件下重新贴虚拟的对照组标签，使标签不影响结果机制：两组的券成本恒为零、退款同概率、购买机制完全相同。于是“处理效应为零”是设定的真值，而不是一个假设。四层各做 250 次，合计 1000 次，每次 20 万用户。

合并的假阳性率为 **0.046**，Clopper–Pearson 95% 精确区间 **[0.0339, 0.0609]**。逐层分别为 0.056、0.044、0.040 与 0.044，各自的精确区间都覆盖 0.05。图 4(a) 同时给出点估计与区间。

这里需要说明表述的分寸：1000 次重复下区间半宽约 0.013，因此可以说“与名义水平 0.05 相容”，但不可以说“等于 0.05”。若真实假阳性率为 0.06，本规模只有约三分之一的概率能把它与 0.05 区分开（对 0.06 的检验功效约 0.32）——这是有限重复的固有限制，不是设计缺陷。

三个指标的表现差别明显（图 4(b)）。净增量利润稳定 0.040–0.056 之间；购买率 L0 只有 0.028（偏保守），L3 升到 0.056；退款率 L0 偏高达 0.064，明显高于名义水平。这提示护栏指标的零效应分布更依赖层的机制，判定护栏时不能直接套用主指标的临界值。

判断标准误是否可信，还有一个独立于假阳性率的维度：把重复之间估计的实际标准差，与每次估计所声称的标准误相比。这个比值接近 1，说明“声称的精度”与“实际的波动”一致。四层的比值为 **0.987**、**0.994**、**0.988**、**0.995**，合并 **0.995**（图 4(c)）。需要强调的是，对双侧检验而言“区间包含零”与“p 值大于水平”是同一件事，因此覆盖率与假阳性率在数学上互补，不能作为两条独立证据；真正的第二条证据是标准误校准比。

负对照提供了第三个视角。同一场景、同一条链路上，若购买增量的真值为零而照常发券，则购买率的拒绝率应当在名义水平附近，而利润的拒绝率应当接近 1——因为此时利润的真实效应是负的（券的成本没有换来任何增量）。实测：购买率 **0.08**、退款率 0.07、利润 **1.00**（图 4(d)）。两类读数的含义完全不同，把利润的读数当作“校准通过/不通过”的判据，就把负对照误当成了零效应检验。

3.1.2 最小可检测效应与实测功效

业务里更常见的问题不是“要多少样本才能检测到某个效应”，而是“样本已经定了，能检测到多大的效应”。本文按后一种问法反解：固定 20 万用户、双侧检验、80% 功效、50/50 分流。

层	利润 MDE（元/人）	购买率 MDE（百分点）
L0	0.1006	0.339
L1	0.1156	0.336
L2	0.1139	0.336
L3	0.1161	0.322

四个值都 0.10–0.12 元/人之间，与对照均值相比约为 5%。两个量级值得注意。其一，按 L1 效应量级扫描给出的换算斜率（0.1665 元/人每百分点），0.1006 元/人的利润 MDE 相当于 **0.60 个百分点**的购买率增量；而购买率自身的 MDE 是 0.34 个百分点，只是其设计效应 5 个百分点的十四分之一——这解释了为

什么在利润上“看起来不显著”的策略，购买率上往往“显著”，而后者并不能支持利润结论。其二，若把同样的 20 万拆成 6 万测试集与 14 万其他用途，利润 MDE 会上升到 0.1837 元/人，约为全量的 1.83 倍；若用独立的 20 万验证队列，则 0.12–0.14 元/人之间。子样本的 MDE 不能相互替代。

设计 MDE 只是理论值，它假设效应恰好落在解析位置上。为检验这一点，本文 15 个格子上各做 100 次实测，格子按“目标效应与设计 MDE 的倍数”分三档：

档位	倍数	实测拒绝率
低于设计 MDE	0 至 0.5	0.04–0.33
零余量边界	1.0	**0.78–0.87**
高于设计 MDE	1.5 至 2.0	0.97–1.00

中间一档是本文特意单列的。按解析式，倍数取 1.0 时功效恰好等于 0.80；实测落 0.78–0.87 之间，平均值略低于名义值。原因是这一档的“余量”为零：标准差只要比设计值高百分之一，功效就跌破 0.80。因此这 3 个格子只能表述为“处于边界”，不能计入“已验证可检测”。这个区分不是文字游戏——如果把边界格与高倍格合并报告，会得到“功效曲线与解析值一致”的结论，而实际上边界处存在系统性偏低。

3.2 L0：最理想的基线

3.2.1 平均效应的偏差与精度

L0 保留利润的零膨胀与重尾，但处理分配与结果无关、成本同质。500 次重复的平均处理效应为 **0.2434 元/人**，蒙特卡洛标准误 0.0017，重复间标准差 0.0386。同一个格子 6 万人测试子集上的估计为 0.2434，标准差 0.0737——**子集不改变点估计，只改变精度**，这是子集应当具备的性质；若两者点估计出现系统性差异，说明切分本身引入了选择。

把 0.2434 与 L0 的设计 MDE 0.1006 相比，实际效应约为可检测下限的 2.4 倍。这意味着 20 万规模下，L0 的效应不仅显著，而且有余量——它属于“应当被稳定检出”的情形，适合作为判断估计量是否正确的基准。

把估计与真值并排放，偏差才有意义。四个核心格的解析真值、500 次重复的估计均值与偏差如下：

层	解析真值（元/人）	估计均值	偏差	相对偏差	偏差 / MC 标准误
L0	0.2447	0.2434	−0.0013	−0.51%	−0.73
L1	0.2817	0.2831	+0.0015	+0.53%	+0.73
L2	0.2855	0.2878	+0.0023	+0.80%	+1.16
L3	0.2314	1.6641	**+1.4328**	**+619%**	**+699**

真值由数据生成过程的解析式逐用户积分得到（对不可观测因子取期望），不依赖任何估计量。**前三层的偏差都在 1.2 个蒙特卡洛标准误以内**，相对偏差不超过 0.8%——这正是“真值已知”能提供的、在真实数据上无法获得的东西：偏差不是靠不同的估计量互相印证来推断，而是直接算出来的。

L3 是一个例外，而三个候选解释里有两个已经被排除。它的解析真值是 0.2314（另一批抽样下为 0.2288），与前三层同量级；而 500 次重复的估计均值为 1.6641，相差 1.43 元/人。

第一个候选：未观测混淆。排除。核心格的 $\lambda_T = 0$，不可观测因子不进入分配方程，可忽略性成立。

第二个候选：效应异质性带来的 ATT 与 ATE 之差。排除。若均值差估的是处理组的平均效应（ATT），而 ATT 显著高于 ATE，那么这个差距可以由“处理组偏向高效应人群”解释。按真倾向得分加权算出的 ATT 为 **0.2161**，ATE 为 **0.2288**——**ATT 反而略低于 ATE**（差 −0.013），这个通道的量级只有 0.013 元/人，解释不了 1.43。

分解之后，一切都能对上：这就是选择偏差，而且可以精确算出来。把朴素差按定义拆成两项：

$$\underbrace{E[Y|W{=}1] - E[Y|W{=}0]}_{\text{朴素差}} = \underbrace{E[Y(1) - Y(0)\,|\,W{=}1]}_{\text{ATT}} + \underbrace{\big(E[Y(0)|W{=}1] - E[Y(0)|W{=}0]\big)}_{\text{选择项}}. \tag{12}$$

第二项问的是：**假如两组都不发券，他们的基线利润会差多少？**在 L3 里答案很大，因为分配偏向高购物车、高历史成交额的用户，而这些用户本来就更赚钱。用解析真值逐用户算出来：

量	L3	L0（对照）
ATT（处理组的平均效应）	+0.2112	+0.2447
选择项（两组基线之差）	**+1.4357**	−0.0137
两项之和	**+1.6468**	+0.2310
直接计算的朴素差	**+1.6468**	+0.2323
ATE	+0.2288	+0.2447

两项之和与直接计算的朴素差**逐位吻合**，这不是近似，是恒等式。所以那 1.43 元的来源是清楚的：**它不是估计量出错，也不是流水线有缺陷，而是“把两组直接相减”这个动作本身，把 1.44 元的基线差距混进了处理效应里。**

这个分解也解释了为什么 L0 没有这个问题：L0 的分配与特征无关，选择项只有 −0.014，朴素差因此就等于 ATE（0.232 对 0.245）。**同一把尺子，在 L0 上准、在 L3 上偏 1.44，差别只在“分配是否依赖特征”。**

由此得到本文关于选择偏差最直接的一条定量结论：**可观测的选择就足以让未调整估计是真值的 7.2 倍。**不需要引入任何未观测混淆——本文的 L3 核心格根本没有它（$\lambda_T = 0$）。日常讨论里“混淆”通常指看不见的因素，而这个结果显示，**看得见的选择如果被忽略，代价已经足够大。**

3.2.2 前三层无偏与 L3 偏差的成因

偏差表里最值得追问的是**为什么**：同样是“用观测数据估效应”，前三层偏差在 1% 以内，L3 却差 1.43 元/人。答案不在估计量，而在分配机制。

前三层的处理分配与任何影响结果的因素都无关：$\lambda_T = 0$ 使不可观测因子不进入分配方程，而分配方程里的可观测特征系数在这些层中被设为不影响结果的截距（真倾向得分的标准差为 0.0000，即每名用户的处理概率都是 0.5）。在这种设定下，处理组与对照组的用户构成在**期望意义上完全相同**，差值直接就是平均效应——不需要任何调整，也没有可调整的东西。

L3 不是这样。它的分配方程带有七个可观测特征的系数（第 2 节），因此真倾向得分的标准差为 0.1508——处理组系统性地偏向高购物车、高历史成交额的用户。**在可忽略性依然成立的前提下，未调整的差值估的却是“被选中这批人”的平均效应。**当效应随特征强烈异质时，两者可以差出数倍。

这条对比给出一个可迁移的判断：**“随机化”不等于“平衡”。**只要分配依赖特征，即使没有未观测混淆，未调整的估计也在估一个加权平均，而权重的来源是分配机制本身。真实业务里的定向投放几乎总是这种情形——所以“要不要做调整”不是一个学术问题，而是“你的处理组和对照组是不是同一批人”的问题。

3.2.3 零膨胀重尾对样本量的含义

利润变量的分布形态决定了它在样本量问题上的角色。绝大多数用户贡献恰好为零，少数贡献为大额正数或负数，因此利润的方差主要来自尾部，而尾部由少数用户决定。这带来一个容易被忽略的后果：**以利润为主指标反解样本量，会系统性地与以购买率反解得到的结论不一致。**

具体地，L0 的利润 MDE 是 0.1006 元/人，而对照均值为 2.246 元/人，相对可检测变化约 4.5%；购买率的 MDE 是 0.339 个百分点，对照购买率 10%，相对可检测变化约 3.4%。两者看似接近，但含义不同：同样一次投放，购买率的相对提升只要达到 3.4% 就能被检出，利润却需要 4.5%。若业务方的决策依据是“购买率提升 4%”，那么 20 万规模下这次投放会被判为显著，但它在利润上仍处于检测不到的区域。

这就是“样本量的约束者可以不是主指标”的定量形态。它不是一个技术细节，而是会直接改变结论的方向：以购买率选样本量、以利润做决策，等于用了一个偏松的标准去支持一个偏严的结论。

3.2.4 成本同质性假设的检验

L0 的基准格设定券成本同质——所有获券用户的期望成本相同。放松这一条，让成本随可观测特征变化后，平均效应从 **0.2434 升至 0.4362 元/人**（该格 30 次重复，蒙特卡洛标准误 0.0068）。

变化幅度接近 80%，方向与直觉相反：成本异质并不只是“让成本估得更准”，它会同时改变策略能覆盖的人群与人均效应的加权方式。当低成本用户同时也是高响应用户时，按成本排序的定向会自动聚集到高增量人群，人均效应上升；反之则下降。因此“成本同质”不是一个可以随便采用的简化假设，它会改变结论的量级。

另一个极端更值得注意。若购买增量为零而照常发券（负对照格），平均效应为 **−0.5657 元/人**（30 次重复，标准误 0.0064）。这个格子说明：**当券没有带来任何增量时，人均利润的损失恰好等于券的成本，**

量级与 “有效” 的格子在同一个数量级上。这意味着在真实业务里，一个完全无效的投放不会表现为 “利润不变”，而会表现为 “利润显著下降”——若只看显著性而不看符号与量级，很容易把它误读成 “有效”。

L0 的结论可以概括为三点：估计量在机制最干净的环境下无偏且精度可预测；利润的样本量需求与购买率不同，两者不能互相替代；成本同质这一简化假设会改变结论量级，必须在设计阶段显式声明。

3.3 L1：真实金额链路与个体异质性

3.3.1 平均效应及其构成

L1 引入真实金额链路（购物车 $\rightarrow$ 首单 $\rightarrow$ 复购）与个体异质性。500 次重复的平均处理效应为 **0.2831 元/人**（蒙特卡洛标准误 0.0020，重复间标准差 0.0455），比 L0 高约 16%。

这个增量来自链路本身而非估计方式：券只对首单核销、首单金额是购物车的随机比例、已转化用户以较低概率产生复购且复购不带券。三者的组合使得 “券带来的增量” 不再是单一的转化增量，而是 “转化增量 $\times$ 首单金额” 加上 “复购的间接效应”。换句话说，L0 的效应可以理解为 “多一个转化用户值多少钱”，L1 的效应则是 “多一个转化用户值多少钱，减去他原本可能贡献的复购”。

异质性两端，平均效应分别为 0.2138 与 0.2967 元/人（各 30 次重复）。差异约 39%，说明异质性的旋钮确实改变了效应水平，而不只是改变了分布形状。

3.3.2 选模结果与判据的有效性

L1 上并排比较五个条件平均处理效应模型：常数（无异质性）、T-learner、S-learner、因果森林与 DR-learner。选模准则只用验证集上的策略价值下界，不接触真值。200 次重复的结果为：

模型	被选中次数	占比	平均名次	选模分数中位数
因果森林	105	52.5%	1.71	0.0605
S-learner	71	35.5%	1.86	0.0490
DR-learner	12	6.0%	3.39	0.0164
常数	7	3.5%	4.51	−0.0183
T-learner	5	2.5%	—	—

两个事实值得强调。第一，选模分数与真值贪心策略价值的 Spearman 相关系数为 **0.727**—— 完全不使用真值的前提下，这个判据能够对模型质量作出有意义的排序。第二，**常数模型并非总是被淘汰**：它 7 次中被选中，且这 7 次的选模分数中位数为负，说明判据在这些重复中给出了 “异质性不可辨识” 的信号，而不是随机抽签。

这两点合起来支持一个谨慎的结论：验证集下界作为选模准则有效，但它的有效性建立在一个前提上——验证集足够大，使策略价值的估计精度高于模型之间的差异。

3.3.3 小样本诊断对模型选择的影响

一个更值得注意的现象来自不同规模下的对比。20 次重复、每次 2 万用户的诊断规模下，常数模型 20 次中赢了 9 次；而 200 次重复、每次 20 万的正式规模下，它只赢 7 次。

差异的方向明确：**样本量越小，越容易选中 “没有异质性” 的模型**。原因不难理解——异质性的估计依赖个体层面的信号，其信噪比随样本量下降而迅速恶化；当样本不足以分辨个体差异时，常数模型在验证集上的表现反而更稳，因为它的方差最小。

这个现象的方法论含义比它本身更重要：如果 2 万规模上做一次诊断，得出结论 “异质性不值得建模”，那么正式实验会系统性地低估异质性的价值。模型选择本身需要与最终决策规模匹配的样本量，不能用小规模诊断代替。

3.3.4 同一规则在不同模型下的结论差异

把同一条按 “单位成本增量利润” 排序的贪心规则，分别喂给不同模型，得到的结果并不一致。0.20 元/人的预算档上，因果森林估计下贪心策略的净利差为正，而常数策略下为负。这不是规则本身的问题——规则完全相同，差别只在排序向量。

结论因此必须按模型配对表述：**“怎么花钱” 的效果依赖于 “给谁发” 的估计质量**。若把不同模型的结果按选模频率加权聚合，得到的会是 “定向普遍优于随机” 的一揽子上结论，而这个结论在常数层的 7 次重复上一次都不成立。本文的所有策略比较都按模型配对报告，聚合时也只做配对内的平均。

3.3.5 诊断规模对选模结论的影响

同一套候选模型、同一套选模规则，只改样本量，选出来的东西完全不同。

规模	重复数	常数	因果森林	DR-learner	S-learner	T-learner
诊断（2 万）	20	**9**	4	3	3	1
正式（20 万）	200	**7**	105	12	71	5

在 2 万的诊断规模上，常数模型赢了 45%（9/20），看起来结论是 “异质性不值得建模”；把样本量提到 20 万后，常数只赢 3.5%（7/200），因果森林赢 52.5%。**同一个判据、同一批候选，仅仅因为样本量不同，给出的结论从 “别建模” 翻成 “必须建模”。**

机制不复杂。诊断规模下每个用户被观测到的信息少，条件效应的估计噪声大，`tau_hat` 的标准差被噪声撑到 2.56 元/人——远大于真实异质性的幅度；此时 “给所有人同一个数” 反而是方差最小的选择，验证集自然偏好常数模型。样本量提上来后，噪声被压下去，真实的异质性才浮出来。

这条对实践的直接含义是：**不能用小规模试验决定 “要不要做异质性建模”**。小规模试验回答的是 “在小规模下能不能做”，而不是 “值不值得做”。若要判断后者，试验规模必须与最终决策规模同量级——这与 “用 3 万人的 A/B 决定千万级投放的方案” 是同一类错误。

3.3.6 个体层面的排序质量

前面讨论的都是 “平均效应估得准不准”，而策略实际依赖的是 “个体排序对不对”。这两件事可以分离：平均效应无偏，个体排序仍可能几乎没有信息。200 次重复上按模型统计：

模型	与真值 CATE 的相关系数	校准斜率	逐点 RMSE（元/人）	相对偏差	被选中次数
因果森林	**0.1025**	0.749	6.142	+0.6%	105
S-learner	0.0776	0.471	6.178	+1.5%	71
T-learner	0.0428	0.114	6.496	+0.4%	5
DR-learner	0.0393	0.098	6.562	+0.4%	12
常数	—	—	6.171	−0.8%	7

三件事同时成立，需要分别读。

其一，个体排序的信息量很低。表现最好的因果森林，其估计 CATE 与真值 CATE 的相关系数只有 0.10——也就是说，个体层面 90% 以上的变异没有被抓住。这解释了一个表面矛盾：模型在**平均**意义上几乎无偏（相对偏差 0.6%），在**个体**意义上却几乎不可用。

其二，校准斜率远小于 1。斜率 0.10 至 0.75 意味着估计出的效应被大幅 “压平”——模型给出的高低差异只有真实差异的一成到七成。这是高维非线性 CATE 估计在小样本下的典型行为：宁可接近均值，也不敢外推。

其三，逐点 RMSE 约为平均效应的 22 倍。 6.1 至 6.6 元/人的逐点误差，对比 0.28 元/人的平均效应——个体预测误差比要估的量本身大一个多数量级。**这不构成 “模型没用” 的结论**，因为策略只用排序与符号，不用绝对水平；但它解释了为什么排序质量差并不必然让策略价值归零，也解释了为什么 “把 RMSE 降下来” 对策略价值帮助有限。

常数模型的 RMSE 反而与因果森林接近（6.17 对 6.14），这是个有用的提醒：当真实异质性相对于噪声很小时，一个 “给所有人同一个数” 的模型在逐点误差上可以与复杂模型打平。它之所以在选模里输，是因为排序（尽管微弱）仍然带来价值，而不是因为它预测得更差。

3.3.7 选模后悔

选模准则只用验证集上的策略价值下界，不接触真值。但它毕竟是 “挑”，挑错就要付代价。把每个重复里被选中的模型与事后最优的模型相比：

指标	数值
平均后悔（选中 − 事后最优，元/人）	**−0.0193**
后悔的标准误	0.0030

指标	数值
选中即最优的比例	48.5%
最差的一次后悔	−0.2326

平均后悔 0.019 元/人，约为该层平均效应 0.283 的 **6.8%**。接近一半的重复（48.5%）里，选中的模型事后就是最优的那个；最坏的一次差 0.233 元/人，几乎把整层的效应差掉。

这个数应该和模型之间的差距放在一起读。五个模型的事后最优与最差可以相差数倍，而选模把损失控制在 7% 以内——说明 “用验证集下界挑” 这件事本身是有效的。但它同时说明：**最好的模型与第二好的模型之间的差距，往往小于挑错的代价**，因此在真实业务里，与其追求更复杂的模型，不如先把验证集做大。

3.3.8 效应量级扫描：设计效应与盈亏平衡的距离

前文的结论都建立在 “购买率提升 5 个百分点” 这个机制参数上。这个数有多大的容错空间，决定了结论能不能迁移。

做法不必重跑模拟。期望利润对购买概率是**线性**的：券只在成交时核销，所以每一笔新增订单带来的净贡献是一个固定的数，而每一笔新增订单的券成本也是一个固定的数。因此利润对购买率增量 Δp 是一条直线，只需要两个锚点就能确定它。

锚点一（$\Delta p = 0$）：购买率没有任何提升，但券照常发出。此时净增量恰好等于负的券成本。本文的券成本是 $f \cdot r \cdot p_c = 10 \times 0.55 \times 0.100 = 0.551$ 元/人，因此该点为 $\mathbf{-0.551}$。这个数可以被独立核对：L0 的零购买效应格（同样 “照常发券、购买增量为零”）实测为 $\mathbf{-0.5657}$，相差 2.7%（约 2.3 个蒙特卡洛标准误），量级上仍属接近。

锚点二（$\Delta p = 5$）：设计效应下的人均净增值，由 L1 的解析真值给出，为 $\mathbf{+0.2817}$。

两点连线：

$$\Delta\Pi(\Delta p) = -0.551 + \frac{0.2817 + 0.551}{5} \cdot \Delta p = -0.551 + 0.1665\,\Delta p. \tag{13}$$

令 $\Delta\Pi = 0$，得 $\Delta p^* = 3.31$ **个百分点**。设计效应 5 个百分点只比它高 **1.51 倍**。

这个数应当怎么读。三点限定必须同时说。其一，直线假设只在 “每笔新增订单的净贡献与券成本都固定” 时成立；若面额或核销率随人群变化，直线会弯。其二，5 个百分点的设计效应在数据生成过程里是异质的（不同用户的提升不同），而这里的锚点用的是总体真值——因此 3.31 是 “总体平均意义下” 的盈亏平衡，不是每个子群各自的。其三，锚点一用的是 L1 的券成本与 L0 的负对照实测，两者相差 2.7%；若改用负对照的 −0.5657 作锚点，零点会移到 **3.34**。**真实盈亏平衡落在 3.31 至 3.34 之间**，本文取 3.31（用 L1 真值与本层券成本作锚点）。

给业务的可操作版本：先用自己的每单净利、面额与核销率估出这条直线的两个锚点，再看预期效应是否显著高于零点。若预期效应只有零点的 1.2 倍，那么即使统计显著，商业上也只在盈亏线上摆动。

一个必须说清的界限：本文没有扫描 “效应本身变小” 之后的功效。功率分析回答 “能不能检出”，盈亏平衡回答 “检出之后赚不赚钱”；两者是不同的问题，本文只回答了后者，且是解析回答。

L1 的结论可以概括为三点：真实金额链路会抬升平均效应的量级并改变其构成；验证集下界是有效的选模判据，但需要与决策规模匹配的样本量；策略优劣不能脱离估计模型讨论，跨模型的聚合会掩盖分层反转。

3.4 L2：时间与人群的变化

3.4.1 平均效应与拆分的时间含义

L2 的核心格平均处理效应为 **0.2878 元/人**（500 次重复，蒙特卡洛标准误 0.0020，重复间标准差 0.0441），与 L1 几乎相同。购买率效应 0.0501、退款率效应 0.0042，也与 L1 一致。这说明 “时间与人群都不漂移” 的设定下，L2 与 L1 是同一个机制的两个标签——L2 的特别之处不在平均水平，而在它的拆分方式。

L2 的训练、验证、测试按入组周次划分，不按用户随机划分。这是设计上的要求：时间维度的结论必须在时间切片上检验，若按用户随机切分，每个切片都混合了各个时段，漂移会被平均掉，从而永远看不到。代价是测试段不再代表全期，而代表特定周次。这一点决定了下面所有 L2 结果的解读方式。

3.4.2 漂移下测试段与全量的符号差异

平滑漂移格（效应随时间衰减，人群构成不变）上，全量队列的估计为 $+\mathbf{0.3413}$ **元/人**（30 次重复，标准误 0.0074），而按周次切出的测试段为 $-\mathbf{0.0489}$ **元/人**（标准误 0.0162）。

两者相差 0.390 元/人，约为差值标准误的 22 倍，不可能是抽样波动。差异的来源明确：测试段对应的是漂移已经累积之后的周次，此时效应已衰减至负值。

这个结果的方法论含义比数值本身更重要。**同一个策略、同一个预算、同一批用户生成过程，仅因为评估窗口落在不同时段，结论就从“有效”变成“有害”。**如果只看全量估计，会得出“该策略在整个投放期都有效”的结论；如果只看最后一个时段，会得出“该策略应当叫停”。两者都不是错的，但都不完整——正确表述是“该策略在投放早期有效，效应随时间衰减并在测试段转负”。

这也解释了为什么 L2 上不能沿用“按用户随机切分”的做法。若那样切分，训练集与测试集都混合了早期与晚期用户，测试段的负效应会被早期正效应抵消，最终全量与测试段一致，而漂移这个机制就完全不可见。

3.4.3 人群构成变化与样本量

人群构成变化格的估计为 $\mathbf{0.3981}$ **元/人**（30 次重复，标准误 0.0069），比核心格高约 38%。构成变化改变的是“处理效应在人群上的加权”，当构成向高响应人群偏移时，人均效应上升——这与成本异质格的方向一致，但机制不同：前者改的是人群权重，后者改的是成本结构。

样本量两端的比较提供了另一个视角。同样 50/50 分流下，10 万规模格的平均效应为 0.2897（标准误 0.0080），3 万规模格为 0.2721（标准误 0.0138）。**点估计几乎没有差别，差别全在精度：**3 万格的重复间标准差是 0.0759，是 20 万格的 1.72 倍，而 3 万与 20 万的理论比值应为 $\sqrt{200/30} \approx 2.58$——实测低于理论值，原因是该格同时改变了其他机制。这个偏离提醒一件事：**样本量格之间的比较，只有在其他机制完全相同时才能读作纯精度效应**，本文的格子虽然只改了 n，但随机流的耦合使重复间波动不完全服从 $1/\sqrt{n}$。

3.4.4 一个不构成机制证据的格子

成熟延迟格（`L2_immature_negative_control`）的估计为 0.2817，与核心格几乎相同。这个格子原意是检验“结果尚未成熟时估计会偏成什么样”，但它的机制开关在实现时没有接入数据生成过程，因此它实际跑的是与核心格相同的机制，**不构成关于成熟延迟的任何证据**。

本文保留这一格的数字但明确标注其性质，原因是：一个看起来完全正常的数字（0.2817，与核心格 0.2878 相差 0.006，落在抽样误差内）如果被当作机制证据引用，会得出“成熟延迟不影响结论”这个错误且危险的推论。识别这类“数字正常但机制没接上”的情形，只能靠对生成过程的检查，不能靠对结果的检查。

3.5 L3：不可观测混淆的定量边界

3.5.1 核心格的定位

L3 的核心格平均处理效应为 $\mathbf{1.6641}$ **元/人**（500 次重复，标准误 0.0020，标准差 0.0458），购买率效应 0.0822（8.22 个百分点），退款率效应 0.0068（0.68 个百分点）。

这个数字与前三层（0.243、0.283、0.288）相差近 6 倍，但**不能读作“混淆使效应放大了 6 倍”**。

把 λ_Y 从 0.5 关到 0，同一分支的效应只从 1.6641 变到 1.6681——**不可观测因子几乎不改变绝对水平**。这意味着 6 倍差不能归因于混淆本身，它来自 L3 这一分支在**基准标定上的差异**：每一层的购买概率都被校准到预设的目标水平，而 L3 的校准锚点与前三层不同。本文未能把这一锚点追溯到与前一章一致的可解释量，因此**不对 6 倍差作因果解释**。

由此得到一条使用上的限制：L3 的绝对水平不可解释，可解释的只有**层内相对变化**——同一分支内改变 λ_T 带来的效应增幅，才是混淆强度的边际作用。

因此**跨层的绝对水平不可直接比较**，可比的比较必须在同一分支内部进行。L3 的核心格取 $\lambda_T = 0$（U 不影响处理分配），这正是“可忽略性成立”的基准点；混淆强度的作用由 λ_T 扫描给出。

3.5.2 混淆在选择偏差之上的增量

前面的分解说明 L3 核心格的 1.65 里已经有 1.44 来自可观测选择。那么在此之上，把不可观测因子也接进分配方程（$\lambda_T > 0$），还会加多少？

λ_T	未调整估计	相对核心格	其中 U 驱动的增量
0（核心）	1.6641	—	0
0.25	1.8451	+10.9%	+0.181
0.75	2.0932	+25.8%	+0.429
1.50	2.2291	+34.0%	+0.565

这张表现在可以逐列读。第一列是估计值；最后一列是把核心格已经含有的 1.44 选择偏差扣掉之后，纯粹由 U 进入分配所带来的增量。它有三个特征：**绝对值不大**（最多 0.57 元/人，约为选择偏差的 40%）、**边际递减**（每单位 λ_T 的增量从 0.72 降到 0.50、再到 0.18）、**没有改变结论的方向**。

把这个结果放回整篇论文的语境，可以得到一条明确的排序：**在本文的机制里，可观测选择的破坏力大于未观测混淆。**前者一次性带来 1.44 元的偏差（偏差约为 ATE 的 6.2 倍），后者把强度加到 1.5 也只再加 0.57 元。这与通常把“未观测混淆”当作头号威胁的直觉相反，原因是二者作用的位置不同：可观测选择会让两组在**基线上**就不同，而未观测混淆只是让这个差距再倾斜一点。

一处用语需要澄清。日常讨论中“混淆”往往专指看不见的因素，本文前几节也沿用了这个习惯。但上面的分解说明，把“看得见的选择”与“看不见的混淆”分开命名是有必要的：二者的量级差三倍，而前者在数据里可以被检验（比较两组的基线特征），后者不能。本文因此统一为：**选择偏差**指由可观测特征导致的组间不可比，**混淆偏差**专指不可观测因子导致的部分；核心格的选择偏差为 1.44，混淆偏差为 0。

3.5.3 混淆强度的边际作用

固定 $\lambda_Y = 0.5$、U 与全部潜在结果都不变的条件下，只改变处理分配对 U 的依赖强度 λ_T：

λ_T	未调整估计（元/人）	解析真值（元/人）	偏差（元/人）	偏差相对 $\lambda_T = 0$
0（核心）	1.6641	0.2314	1.4327	—
0.25	1.8451	0.2314	1.6137	+12.6%
0.75	2.0932	0.2314	1.8618	+30.0%
1.50	2.2291	0.2314	1.9977	+39.4%

这一列真值必须写在表里，否则整张表会被读反。 λ_T 只进入分配方程，潜在结果与不可观测因子全部固定，因此四个格子的**真值是同一个 0.2314**。估计值从 1.6641 升到 2.2291，增长的全部是偏差，不是效应。把这一列写成“平均处理效应随混淆强度上升 34%”是方向性错误：因果效应按定义不随分配机制变化。

四个格子共用同一分支、同一配对组，因此这是干净的配对比较：除了 λ_T，其余机制逐项相同。**偏差**随混淆强度单调上升，但上升幅度是**递减的**——从 0 到 0.25 增加 0.181，从 0.75 到 1.50 只增加 0.136。这提示混淆的作用不是线性的，而是在强混淆区间趋于饱和——注意这里增长的是名义估计对真值的偏离，不是真值本身。

需要强调，这里的“效应随混淆上升”并不意味着“混淆总能放大效应”。它放大的是**名义估计**：当高 U 用户既更容易被处理、又本身利润更高时，未调整的估计会把这两项加在一起。若两者的相关性方向相反，同样的混淆强度会让估计偏小。本文的机制取的是前者。

3.5.4 λ_T 与 λ_Y 的联合变化

另一组格子走的是联合分支，同时改变分配与结果对 U 的依赖：

设定	平均处理效应（元/人）
$\lambda_T = \lambda_Y = 0$	1.6681
$\lambda_T = \lambda_Y = 1.5$	3.9436

两端相差 2.36 倍。这个倍率高于只动 λ_T 的 34%，说明两个方向的作用并不独立。但**不能据此断言二者相乘**：若真是乘积关系，只动 λ_Y 就应当改变水平，而实测把 λ_Y 从 0.5 关到 0 时，固定分支的效应从 1.6641 变到 1.6681，几乎不动。因此更准确的表述是：在本文的设定下，两个通道存在显著的交互，但交

互的形式不是简单乘积，其具体结构无法从这四个格子分辨：λ_Y 放大 U 对结果的斜率，λ_T 放大 U 对分配的斜率，两者叠加后，未调整估计同时吸收了 “选人” 与 “结果” 两个通道的偏差。

联合分支与固定分支的基准值（1.6681 与 1.6641）几乎相同，这是一个有用的自洽性检查：当 λ 都取 0 时，两条不同的实现路径应当给出同一个数，实测相差 0.004，落在抽样误差内。

3.5.5 极端重叠与缺失混淆

极端重叠格的估计为 **3.1372 元/人**（30 次重复，标准误 0.0093），是核心格的 1.89 倍。这个格子把倾向得分的取值范围压到极窄，使得一部分用户几乎必然被处理、另一部分几乎必然不被处理。** 极端重叠下，“反事实” 对相当一部分用户根本没有可比样本 **，任何依赖倾向得分加权或匹配的估计量都会在这一区域失效。

缺失混淆格的估计为 **1.6600 元/人**（标准误 0.0075），与核心格几乎相同。这个结果的意义在于：**当混淆因子的缺失与处理分配无关时，缺失本身不产生偏差**。它同时是一个警告——如果只看这个数字，会误以为 “缺失混淆无害”；实际上它只在缺失机制独立时才无害，而这一点在真实数据里无法验证。

3.5.6 机制格汇总

把 L2 与 L3 的边界格按机制归类，可以看出每一类旋钮把结论推向哪个方向。

层	格	机制	R	平均效应（元/人）	相对核心格
L2	核心	无漂移、构成不变	500	0.2878	—
L2	`drift_smooth`	效应平滑衰减	30	0.3413	+18.6%
L2	`composition_shift`	人群构成偏移	30	0.3981	+38.3%
L2	`n100000`	样本量减半	30	0.2897	+0.7%
L2	`n30000`	样本量降至 3 万	30	0.2721	−5.5%
L3	核心（$\lambda_T = 0$）	无可观测混淆、有 U	500	1.6641	—
L3	`fixed_lt025`	$\lambda_T = 0.25$	30	1.8451	+10.9%
L3	`fixed_lt075`	$\lambda_T = 0.75$	30	2.0932	+25.8%
L3	`fixed_lt150`	$\lambda_T = 1.50$	30	2.2291	+34.0%
L3	`overlap_extreme`	倾向得分极窄	30	3.1372	+88.5%
L3	`missing_confounders`	关键共同原因缺失	30	1.6600	−0.2%

三件事值得注意。其一，**L2 的样本量格几乎没有偏离核心格**（10 万格 +0.7%、3 万格 −5.5%），说明在该层上样本量的作用主要体现在精度而非水平——这与 L2 的机制里 “只改 n” 的设计一致。其二，**L3 的两个 “结构” 格方向相反**：极端重叠把效应推到 +88.5%，而缺失共同原因几乎不动（−0.2%）。后者尤其要小心：当缺失与处理分配无关时，缺失本身不产生偏差，这个 “不动” 是**设计使然**而不是 “缺失无害” 的证据。其三，所有 30 次重复的格都只能读方向与量级——它们的蒙特卡洛标准误约为核心格的 4 倍。

3.5.7 L3 的结论边界

L3 给出的不是一个 “方法能不能用” 的二值判断，而是三个可读的定量事实：混淆强度每提高一档，名义效应上升多少；两个通道叠加时倍率如何相乘；极端重叠下效应的量级会偏离多少。

这些事实的适用范围必须说清：它们成立于本文设定的 U 分布（标准化 logistic）、固定的 $\lambda_Y = 0.5$ 以及特定的分配系数向量。换一套系数，同样的 λ_T 会给出不同的倍率。因此正确的引用方式是 “ 本设定下，λ_T 从 0 到 1.5 使名义效应上升 34%”，而不是 “混淆强度 1.5 会使效应放大三分之一”。

3.6 边界格：机制旋钮的完整清单

正文各处引用的边界格结果汇总于此。各格 30 次重复，只读方向与量级；“跨零” 一列指该格 “定向减随机” 差值的重采样区间是否包含零。

格	层	R	平均效应（元/人）	MC 标准误	重复间标准差
L0_Pi_heterogeneous_cost	L0	30	0.4362	0.0068	0.0372
L0_zero_purchase_effect	L0	30	-0.5657	0.0064	0.0351

格	层	R	平均效应（元/人）	MC 标准误	重复间标准差
L1_cost_prediction_under	L1	30	0.2779	0.0066	0.0361
L1_heterogeneity_000	L1	30	0.2138	0.0062	0.0340
L1_heterogeneity_150	L1	30	0.2967	0.0067	0.0369
L1_mar_double	L1	30	0.2779	0.0066	0.0361
L1_misspec_omit_new_channel	L1	30	0.2779	0.0066	0.0361
L1_signal_weak	L1	30	0.2775	0.0066	0.0363
L2_composition_shift	L2	30	0.3981	0.0069	0.0379
L2_drift_smooth	L2	30	0.3413	0.0074	0.0406
L2_immature_negative_control	L2	30	0.2817	0.0070	0.0383
L2_n100000_p020	L2	30	0.2897	0.0080	0.0440
L2_n30000_p050	L2	30	0.2721	0.0138	0.0759
L3_fixed_lt025	L3	30	1.8451	0.0081	0.0445
L3_fixed_lt075	L3	30	2.0932	0.0083	0.0456
L3_fixed_lt150	L3	30	2.2291	0.0077	0.0421
L3_joint_lam000	L3	30	1.6681	0.0095	0.0519
L3_joint_lam150	L3	30	3.9436	0.0087	0.0477
L3_missing_confounders	L3	30	1.6600	0.0075	0.0412
L3_overlap_extreme	L3	30	3.1372	0.0093	0.0507
二十个格子里，**“定向减随机”差值的 bootstrap 区间**跨零的有四个：零购买效应格、异质性下限格、以及 10 万与 3 万两个样本量格。这是全文唯一使用的跨零口径。**不要把它与各格 ATE 的区间混为一谈**：后者二十个格没有一个跨零，因为最小的	ATE	也有 0.21 元/人，是其标准误的三十余倍。两个口径回答不同问题——前者问“定向相对随机是否稳定”，后者问“效应本身是否显著”。			

四个跨零的格子分别是零购买效应格、异质性下限格、10 万与 3 万两个样本量格。前两格的共同点是“没什么可排”——一个购买增量本为零，一个异质性被压到下限；两个样本量格的共同点是区间宽——10 万格与 3 万格的区间宽度分别是核心格的 1.4 倍与 2.6 倍。**这两类原因完全不同，不能合并成一句“小样本不稳定”。**

另需注意最后一列：这四格之外的十六格，“定向减随机”的区间都不跨零，说明定向相对随机的优势在多数机制下是稳定的；不稳定的是“优势有多大”，不是“有没有优势”。

3.7 各层的独立判断

逐层的数字已经列完，但每一层真正的产出不是数字，而是一条可以被带到别处的判断。这一节把它们分开写，因为它们的适用范围并不相同。

3.7.1 L0：估计量本身不是瓶颈

L0 的价值在于“排除了所有其他解释”。在这个环境里，分配与结果无关、成本同质、效应同质——任何偏差都只可能来自估计量本身。500 次重复后偏差是 −0.51%，不到一个蒙特卡洛标准误。

这条结果的含义比它看起来更重要：**当环境足够干净时，标准的均值差估计已经足够好，不需要任何修正**。在实际分析里，人们常常一上手就上倾向得分、双稳健、机器学习，理由是“更稳健”；L0 说明这些工具在干净环境下是多余的。它们真正的用途是在环境不干净时——而那时候的关键不是“用哪个估计量”，而是“承认哪条假设被破坏了”。

L0 还给出一个副产品：成本同质这个假设一旦放松，效应从 0.2434 跳到 0.4362，接近 80%。**这是一个不该被默认采用的简化**。在很多投放分析里，成本被当作一个常数乘以人数；L0 说明这个做法会系统性地改变结论的量级，而不是仅仅损失一点精度。

3.7.2 L1：平均无偏是个很弱的保证

L1 是全文最“像真实业务”的一层：购物车转首单、券只对首单核销、已转化用户可能复购、效应随特征变化。它的平均效应无偏（+0.53%），但同一批模型在个体层面的排序质量只有 0.10。

这个组合是本文最需要被记住的一条。**“平均效应估得准”与“个体效应排得对”是两件独立的事**，而后者才是策略真正依赖的。一个团队如果只验证了前者，会误以为模型可用；只有当它把排序质量单独拿出来量，才会发现模型给出的高低差异只有真实差异的一到七成（校准斜率 0.10 至 0.75）。

L1 还解释了为什么“更准的模型”未必“更赚”：逐点误差 6.1 元/人，而平均效应只有 0.28——误差比要估的量本身大二十倍。在这种信噪比下，模型之间的 RMSE 差异对策略价值的传导非常有限，真正决定策略价值的是**排序里是否含有方向正确的信息**，而不是误差的绝对大小。

3.7.3 L2：结论依赖评估窗口，而这件事可以被设计利用

L2 最有价值的发现不是“漂移会让效应衰减”，而是**按时间拆分与按用户拆分给出完全不同的结论**。在平滑漂移格上，全量队列估出 +0.3413，按周次切出的测试段估出 −0.0489，相差 22 个标准误。

这意味着两件事。其一，**同一份数据可以支持相反的结论，取决于你怎么切**。这不是统计上的模糊，而是切分方式本身定义了两个不同的问题：全量回答“整个投放期平均如何”，测试段回答“漂移累积之后如何”。两者都真实，但只有后者能回答“现在还要不要继续投”。

其二，**设计决定了你能不能看见这件事**。若沿用“按用户随机拆分”的常规做法，早期与晚期用户会被均匀混进每个切片，漂移被平均掉，全量与测试段一致，漂移这个机制就完全不可见。本文在 L2 上特意把拆分改成按入组周次，才让这个现象显形。这条经验对真实业务同样成立：**如果你怀疑结论随时间变化，切分方式必须与时间对齐，否则你永远看不到它**。

3.7.4 L3：混淆的形状比强度更重要

L3 的扫描给出一个反直觉的结论：混淆强度从 0 加到 1.5，名义效应只上升 34%，而且是递减的（前三档每单位 的边际效应分别是 0.72、0.50、0.18）；相比之下，**极端重叠单格就把效应推到核心格的 1.89 倍**，比把混淆强度加到 1.5 还多。

也就是说，在本文的机制里，“**重叠变差**”对结论的破坏力大于“**混淆变强**”。这与通常把混淆当作主要威胁的直觉不同。原因在于二者作用的位置不同：混淆强度改变的是偏差的斜率，而重叠变差改变的是**有没有可比样本**——当倾向得分把用户压到 0 或 1 附近时，反事实对相当一部分人根本不存在，任何加权或匹配都在用外推填补空白。

L3 还提供一个方法论上的教训：本文原本以为 7.2 倍的层间差距可以用“混淆”解释，但真值显示它来自**选择项**——两组在“都不发券”时的基线利润差，1.436 元/人；它的来源是分配偏向高购物车、高历史成交额的用户（真倾向标准差 0.151 对 0.000），而不是隐藏因子。**在没算真值之前，一个看起来最自然的解释往往是错的**。这也是本文坚持对每个核心格都报真值的原因：没有真值，那个 6 倍会被顺理成章地写成“混淆的代价”，而它其实不是。

3.7.5 判断的适用范围

上面四条判断的强度并不相同，引用时必须区分。

L0 的“估计量不是瓶颈”只在环境干净时成立；一旦存在分配依赖或未观测混淆，它就失效——L3 正是反例。L1 的“平均无偏但排序弱”依赖一个具体的事实：效应异质但形状简单；若异质性更复杂，排序质量可能更高也可能更低，本文没有覆盖。L2 的“窗口决定结论”依赖漂移的存在；若效应稳定，切分方

式无关紧要。L3 的“重叠比强度更危险”依赖本文把重叠压到极端的设定；在温和重叠下这个排序可能反过来。

把这四条写成一句可操作的话：**先确认你的环境破坏了哪一条假设，再去选工具；先确认你的切分方式能否暴露你担心的问题，再去解释结论；先算真值（或用最接近真值的替代），再去归因。**

3.8 跨层比较的可比性

把四层核心格放在一起（图 9），会看到一条不连续的曲线：0.243、0.283、0.288，然后跳到 1.664。

这个跳变很容易被误读为“混淆的代价”，但前文已经说明它不能这样读——L3 是独立校准的一套机制，绝对水平与前三层不可比。**真正可比的比较有两类**：同一层内改变单一机制（如 L3 的 λ_T 扫描，效应从 1.664 升到 2.229），以及同一机制下改变评估条件（如 L2 漂移格的全量与测试段，符号相反）。

三类比较的有效性可以总结如下：

比较类型	是否可比	理由
同层内单旋钮	可比	其余机制逐项相同，配对组相同
同层内不同评估窗口或子集	可比，但需说明切分方式	若切分与漂移相关，测试段不代表全期
跨层的绝对水平	**不可比**	各层独立校准，结果方程的量纲不同

这条区分不是技术细节，而是本文全部结论的引用前提。若把它忽略，最自然的误读是把 1.664 与 0.288 相减，得出“未观测混淆使增量利润虚高 1.38 元/人”的结论——这个数字看起来很具体，却是把两套不同机制的标定值直接相减得到的，没有任何意义。

跨层真正能比较的是**结构与方向**：四层的购买率效应都稳定 5 个百分点左右（L3 为 8.22，因其机制不同）；退款率效应则从 0.42 个百分点（L0 至 L2）升到 0.68 个百分点（L3），后者已经越过 0.5 个百分点的非劣效界值。这个对比将在第 8 节展开。

3.9 策略层：业务规则与模型策略的比较

本节固定在 L1 主实验上：200 次重复 × 5 个估计模型 = 1000 对，比较八种策略在三个预算档上的真实价值。这里的“价值”是每名被分配用户的净增量利润，分母为全部 6 万测试用户，不是入选者人数；所有比较都在同一 rep、同一批用户、同一预算档上配对，因此不受模型选择频率的影响。

3.9.1 策略排序

方法章定义了九个策略，其中“全券（无约束）”在本文的预算档下支出必然超预算、不构成可行策略，因此只作上界参照，不进入下面的三档比较；表中比较的是其余八个。

策略	0.04 元/人	0.20 元/人	0.60 元/人
业务规则（新客优先，再按购物车金额）	**0.0969**	**0.2718**	**0.3645**
贪心（单位成本增量利润）	0.0613	0.2177	0.3323
局部交换（贪心的改进版）	0.0613	0.2176	0.3323
增量利润排序（不做成本归一）	0.0440	0.1990	0.3232
同预算随机	0.0134	0.0680	0.2075
预测利润排序	0.0110	0.0934	0.3016
购买倾向排序	−0.0123	−0.0005	0.1909
不发券	0	0	0

把每一行与业务规则配对相减（1000 对）：

策略	0.04 档差值	0.20 档差值	0.60 档差值	0.20 档胜/负
贪心	−0.0356	−0.0541	−0.0322	329 / 671
增量利润排序	−0.0529	−0.0728	−0.0413	151 / 849
同预算随机	−0.0835	−0.2037	−0.1569	0 / 1000
购买倾向排序	−0.1092	−0.2723	−0.1736	0 / 1000
不发券	−0.0969	−0.2718	−0.3645	0 / 1000

结论与“精准营销”的直觉相反：在这个数据生成过程里，一条两行的业务规则跑赢了模型驱动的定向策略。贪心策略在三个预算档上都比它低 0.032 至 0.054 元/人，胜率只有 33% 至 36%。

显著性的读法要修正。 1000 对里，同一 rep 的五个模型共享同一条业务规则名单，因此独立单元只有 200 个而不是 1000 个。以重复为单位重算：每个 rep 内先对五个模型取平均，得到 200 个差值，其标准误是 $0.038/\sqrt{200} \approx 0.0027$（而不是 1000 对给出的 0.0012），**t 值从 −45 降到约 −20**。方向与显著性都仍然成立，但 “−45” 这个数把独立单元当成了 1000 个，高估了约 2.2 倍。本文因此报 −20，并把证据强度定为 “高但要按重复聚类读”，而不是直接引用 1000 对的 t。

还有一处口径必须交代。上表按五个模型等权平均；若按 “每次只上线一个被选中的模型”（部署口径），定向的价值是 0.282 元/人，**高于业务规则的 0.2718**——两种口径相差 0.064，比本文讨论的 0.054 还大。本文的结论因此限定为：**在模型等权的口径下，规则更高；在部署口径下，两者相当且都不能显著优于对方。**任何 “规则全面胜出” 的表述都超出了数据。局部交换与贪心几乎完全重合（差 0.0001），说明在这批数据上贪心已经到达局部最优，问题不在求解精度。

3.9.2 简单规则胜出的原因

业务规则只做两件事：优先新客，其次按购物车金额排序。它没有估计任何一个条件平均处理效应，却拿到了最高的价值。原因可以定位：**在这个机制里，处理效应的主要来源恰好是可观测且已记录的特征**——新客的券响应显著高于老客，而购物车金额与首单金额直接相关。

三个对照支持这个解释。其一，“预测利润排序”（按 $\hat{p} \cdot$ 金额 排序，完全不看处理效应）在 0.20 档只有 0.0934，远低于业务规则——说明赢的不是 “随便用一个可观测特征”，而是**恰好对准了处理效应那一个**。其二，“购买倾向排序” 甚至为负（−0.0005），因为它把券发给了本来就会买的人，是纯粹的利润侵蚀。其三，在异质性两端格上，效应水平分别为 0.2138 与 0.2967——异质性是真实存在的，只是它的形状简单到一条规则就能抓住。

因此本文的判断是：**当处理效应与某个已记录的特征强对齐时，复杂的条件效应估计不会带来增量，只会带来方差。**模型驱动的策略要胜过业务规则，前提是效应里存在业务规则抓不到的部分；这个前提在本机制下不成立。

3.9.3 策略的逐项解读

把八种策略按 0.20 元/人档排开，每个的得失机制都不同，单独说清比只报排序更有用。

业务规则（0.2718）——新客优先、再按购物车金额。它不估计任何处理效应，却拿到最高值。原因在下一节展开。

贪心与局部交换（0.2177 / 0.2176）——按 “单位成本的增量利润” 排序。两者几乎完全相同，说明贪心在这批数据上已到局部最优；它比业务规则低 0.054，差距来自它把券投给了 “每元成本回报高” 的人，而不是 “效应大” 的人。

增量利润排序（0.1990）——同一套估计，但不做成本归一。它比贪心低 0.019，这个差额就是 “成本归一” 这一步的价值：同样的效应估计，按成本调整后能多拿 9.5%。

预测利润排序（0.0934）——按 “购买概率 × 金额” 排序，完全不看处理效应。它只有业务规则的 34%，因为高购买概率的人本就是 “有没有券都会买” 的那批，发券给他们等于白送。这一条把 “预测准” 与 “值得投” 之间的差别摆得很清楚。

同预算随机（0.0680）——作为基线。任何策略若跑不赢它，说明排序没有提供信息。

购买倾向排序（−0.0005）——按购买倾向排序，结果约等于零。它与 “预测利润排序” 的差别只在金额是否进入排序，但两者都指向同一批人：本来就会买的人。**这是纯粹的利润侵蚀**，也是本文对 “用购买率做投放” 最直接的反例。

不发券（0）——作为零点。

看这张表要注意一件事：**同一批候选里，价值最高的策略没有用到任何因果模型，价值最低的策略用了一个看起来很合理的预测**。这不是说模型无用，而是说“用哪个信号排序”比“用多复杂的模型”更决定结果。

3.9.4 业务规则胜出的机制：效应与可观测特征的形状

业务规则只做两件事：优先新客，其次按购物车金额。它赢的原因不神秘——**在这个机制里，处理效应的主要来源恰好是这两个已记录的特征**。

三条证据把这件事从“猜测”变成“可读”。

其一，异质性两端格的效应分别为 0.2138 与 0.2967（各 30 次重复），说明效应确实随特征变化，且变化幅度约 39%。其二，购买倾向排序（−0.0005）与预测利润排序（0.0934）都很差，说明**不是随便一个可观测特征都能替代效应**——只有与效应真正对齐的特征才有用。其三，个体层面的 CATE 估计与真值的相关系数只有 0.1025（第 3 节），意味着模型抓到的个体差异非常有限，而业务规则抓的是“新客 vs 老客”这一条粗粒度但真实的分界。

把三点合起来：**当效应集中在少数几个已记录特征上时，一条粗规则可以胜过一套细模型**。反过来，若效应分布在大量弱特征上，规则就会失效，模型才有空间。本文的机制属于前者，这也是结论必须限定范围的原因——它是关于“效应形状”的结论，不是关于“模型无用”的结论。

3.9.5 与“定向优于随机”的关系

前文的独立随机验证给出：定向相对同预算随机高 0.214 元/人，190/200 次成立。本节的业务规则相对随机高 0.2037 元/人。两个数字接近，方向相同——**“定向优于随机”成立，“模型驱动的定向优于业务规则”不成立**。这两句话可以同时为真，把前者当成后者的证据是常见的误读。

3.9.6 随机基线的分布与预算饱和点

把券随机发给“够预算”的用户，200 个种子上的基线如下。

预算档（元/人）	平均价值（元/人）	种子间标准差	2.5% 分位	97.5% 分位
0.04	0.0138	0.0062	0.0015	0.0266
0.10	0.0350	0.0076	0.0206	0.0505
0.20	0.0677	0.0107	0.0469	0.0878
0.30	0.1025	0.0116	0.0806	0.1264
0.40	0.1350	0.0120	0.1115	0.1576
0.60	0.2042	0.0118	0.1791	0.2257
0.80	0.2724	0.0038	0.2658	0.2804
1.00	0.2791	**0.0000**	0.2791	0.2791

两个现象互相印证。

其一，价值在 0.60 到 0.80 之间开始饱和（0.2042 → 0.2724），到 1.00 档几乎不再上升（0.2791）。种子间标准差同步塌缩：0.0118 → 0.0038 → **0.0000**。标准差变成 0 的含义很直接——**所有种子选出的是同一批人，即全体用户**，随机性已经消失。

其二，饱和点与解析临界值 B^* 吻合。前文算出“给每个用户都发券”的人均成本是 0.83 元/人；这里的饱和发生在 0.80 至 1.00 之间。两条独立的计算路径给出同一个位置，这是对 B^* 的一个交叉验证：**当人均预算达到 0.83 元附近时，“给谁发”这个问题就消失了，因为所有人都会拿到**。

这也给“预算优化”划了边界：在 0.80 元/人以上做算法优化没有意义，因为约束已经不 binding；优化真正有价值的区间是 0.04 至 0.40 元/人，恰好也是本文三种预算口径差别最大的区间。

3.9.7 预算约束的约束力区间

“预算约束”这四个字在不同预算档上含义完全不同。判断方法不必跑实验，一条式子就够：

$$B^* = f \cdot r \cdot p_1. \tag{14}$$

它表示“若给每个用户都发券，人均要花多少钱”。代入本文设定：$f = 10$ 元、$r = 0.55$、$p_1 \approx 0.15$，得到 $B^* \approx 0.83$ 元/人。

这条式子给出三个区间的分界。

当人均预算远低于 B^* 时（本文的 0.04 至 0.20 档），任何按人筛选的策略都会把预算用穿：因为单张券的成本就超过人均预算，只能覆盖一小部分人。此时真正决定结果的是“用哪个口径算成本”，而不是“用哪个算法排序”——这与第 7 节的实测一致：三种口径的超支概率分别是 1.00、1.00 与 0.00，差别全在口径。

当人均预算接近 B^* 时（本文的 0.60 至 0.80 档），约束开始松动但仍有作用；策略能在“覆盖大多数用户”与“只覆盖高响应用户”之间取舍，价值的边际收益开始递减。

当人均预算明显高于 B^* 时（本文的 1.00 档），预算不再是约束——实测支出 50 570 元低于预算 60 000 元，超支概率为零。此时决策问题退化为“要不要发”，排序的价值也随之下降。

这条式子对业务有直接用处：**先算 B^*，再判断“预算优化”是不是当前的主要矛盾。**如果人均预算只有 B^* 的十分之一，那么把算法从贪心换成整数规划不会有任何改善——瓶颈在额度，不在算法。

3.9.8 三种预算口径

预算约束的落实方式有三种：按期望成本控制（expected）、按期望成本加缓冲（buffered）、按面额上限控制（worst case）。6 万用户、贪心策略、200 个种子上的结果为：

口径	预算（元）	入选人数	实际支出（元）	超支概率	真实价值（元/人）
expected	2 400	6 907	4 020	**1.00**	0.00865
buffered	2 400	8 197	4 840	**1.00**	0.00968
worst_case_face	2 400	**240**	190	**0.00**	0.00189

前两种口径在全部 200 次重复中都超支，且支出达到预算的 1.68 倍与 2.02 倍。

“加了缓冲之后支出反而更高”这个结果与直觉相反。按设计，缓冲口径是把期望成本乘 1.25（每个人看起来更贵，理应选得更少）；但实测入选人数从 6 907 升到 8 197、支出从 4 020 升到 4 840，两个比例都约为 1.2 倍，与“把可用额度放宽 1.25 倍”的行为一致。设计意图与实测行为不一致，本文无法仅从结果侧判定哪一处是根因，因此**只报告观测事实，不解释其机制**：在该实现下，缓冲口径没有降低超支，反而增加了支出。这条限制对使用者是重要的——**不能假设“选了带缓冲的口径就更安全”**。

第三种口径做到了不超支，代价是入选人数从 6 907 压到 240，真实价值从 0.00865 掉到 0.00189，损失约 78%。也就是说，**“绝不超支”是用放弃 96% 的投放规模换来的**，而不是靠更准的成本模型。

把三个口径放在一起，得到一个对业务直接有用的判断：低预算档（0.04 至 0.20 元/人），券的面额成本（10 元 × 核销率）远高于人均预算，因此任何按人筛选的策略都会把预算用穿；此时“预算约束”是否 binding 取决于口径的选择，而不是取决于优化算法。到了 1.00 元/人这个档位，预算反而松动：实测支出 50 570 元低于预算 60 000 元，超支概率为零。**同一个“预算约束”，不同预算水平上完全是两件事。**

3.9.9 求解器：规模、最优性与桶宽

五个求解器名义上解同一个预算背包问题，但能给出的保证不同。在 0.20 元/人档、三个候选池规模上的实测如下。

求解器	候选池	用时（秒）	与 LP 上界之比	可选人数	能主张什么
贪心	1 000	0.0003	—	384	近似解
贪心	5 000	0.0029	—	1 949	近似解
贪心	60 000	0.0283	—	23 437	近似解
局部交换	60 000	0.1466	—	23 437	近似解
限时整数规划	1 000	60.07	0.9978	384	0.22% 间隙内
限时整数规划	5 000	9.60	0.9997	1 949	0.03% 间隙内
限时整数规划	60 000	95.89	—	—	**未在时限内给出解**

三件事值得读出来。

其一，规模决定可行性，精度不是瓶颈。 6 万人的池子上，贪心用 0.028 秒选出 23 437 人；限时整数规划跑了 95.9 秒仍未给出可行解。5 000 人的池子上整数规划能给出 0.03% 的间隙——说明它的问题不是“算不对”，而是“算不完”。

其二，贪心已经接近局部最优。局部交换在同样三个池子上选出的名单与贪心完全相同（人数一致、名单一致），代价是用时增加约 5 倍。这说明在这批数据上，贪心的短板不在“没交换够”，而在“整件取或不取”这个约束本身。

其三，桶宽的影响远比预想的敏感。把面额粒度从 0.01 元放宽：

粒度（元）	策略价值（元）	相对 0.01 元
0.01	59.94	—
0.05	59.64	−0.50%
0.10	59.64	−0.50%
0.50	56.41	−5.89%
1.00	51.42	**−14.21%**

粒度在 0.1 元以内几乎没有代价（−0.5%），但放宽到 1 元会损失 14.2% 的价值。**“精度不重要”的说法只在 0.1 元以内成立。**这条限制对实现有直接影响：用 1 元粒度做实时求解会低估预算的作用，而这种低估不会报错，只会让结果看起来“预算不够用”。

3.10 退款率护栏：口径必须连同界值一起定义

退款率是本文唯一的安全性指标。它的检验逻辑与利润不同：利润做优效检验，退款率做**非劣效检验**（处理组减对照组的单侧上界是否低于界值 0.5 个百分点）。

但这个指标必须先做一步分解，否则会被读错。退款率的分母是全部被分配用户，因此它的处理组与对照组之差可以被拆成两项：

$$\Delta r = \underbrace{0.075 \cdot \Delta p}_{\text{体积项}} + \underbrace{0.00225 \cdot p_c}_{\text{行为项}}, \tag{15}$$

前者是“多卖了几单、于是多退了几单”，后者才是“每单更容易被退”。代入本文的数：L0 的体积项 0.375 个百分点、行为项 0.023 个百分点，**体积项占 94%**；L3 的体积项 0.617、行为项 0.023，体积项占 96%。也就是说，**这条护栏测到的主要是销量，而不是退货倾向**——它更像主指标的一个仿射变换，而不是一个独立的风险维度。本文因此把它降级为“辅助指标”：能报警（销量异常时它会同步异常），但不能替代对退货行为的独立度量；要测后者，应当把分母换成“已购买用户”，此时四层的差恒为 0.225 个百分点，与销量无关。

3.10.1 全员发券：L3 已越过界值

四层核心格上，处理组与对照组的退款率之差（全员发券口径，各 500 次重复）为：

层	退款率差（百分点）	单次投放的标准差	**单侧上界**	余量
L0	0.4207	0.0463	**0.4969**	0.0031
L1	0.4228	0.0465	**0.4992**	0.0008
L2	0.4212	0.0457	**0.4964**	0.0036
L3	**0.6770**	0.0448	**0.7508**	**−0.2508**

判定用的是单次投放的上界，不是重复均值的精度。上表中的标准差表示“如果只做一次投放，退款率差会如何波动”，因此单侧上界等于点估计加 1.645 倍标准差；500 次重复的作用是把这条上界的分布估准，而不是让上界本身变窄。若误用重复均值的标准误（约 0.00002），会得到“余量 0.079 个百分点”的结论，把一次**压在界值上**的通过读成“有明显余量”。

前三层的上界分别为 0.4969、0.4992、0.4964，**都在 0.5 之下，但余量只有 0.001 至 0.004 个百分点**——按这个机制做一次真实投放，约有一半的概率判“未通过”。L3 的上界为 0.7508，超出界值 0.25 个百分点，是明确的失败。

这带来一个比 “通过/不通过” 更有用的判断：**在全员发券口径下，护栏从一开始就没有余量**。前三层把退款率差恰好放在 0.42 个百分点，与界值相差 0.08 个百分点；这个差距看似安全，一旦计入单次波动就几乎被吃满。

这个结果的含义不是 “L3 的方法有问题”，而是 “**L3 所代表的机制下，发券这件事过不了安全线**”。也就是说，护栏的有效性取决于业务本身的退款弹性，而不是取决于估计方法。

3.10.2 主张的联合通过率

上面报的是两条主张各自的通过率（196/200 与 190/200）。业务方真正关心的是 “这一次投放整体上算不算成立”，那要求两条同时通过。

逐重复检查联合结果：$\mathbf{190/200 = 0.950}$。拆开看：两条同时通过 190 次；“发券值得” 通过但 “定向优于随机” 不通过 6 次；两条都不通过 4 次；不存在 “定向通过而发券不通过” 的情形。也就是说，**定向通过是发券通过的子集**——定向是更严的那个约束，联合通过率等于它的通过率。两条主张在这个数据上高度同向，联合通过率因此没有被进一步拉低。

这个结果提示一件事：把两条主张分开报，会让人以为它们是两个独立的风险；实际上它们共享同一个失败来源，**联合通过率不能通过 “分别看” 来估计**。

3.10.3 定向发券的护栏余量

把同样的护栏检验放到 200 次独立随机验证上（每次 20 万新用户、三条臂、0.20 元/人档），结果是另一幅图景：

指标	数值
退款率差	**+0.137 个百分点**
单侧置信上界	**0.220 个百分点**
通过次数 / 总次数	**200 / 200**

差别几乎完全来自分母。全员发券意味着 20 万人都拿到券，退款增量摊在 20 万人上；定向发券只覆盖按策略选出的那部分用户（本文 0.20 元/人档下约四成），同样的退款增量摊在全部被分配用户上，人均差自然被稀释。

换成暴露人群口径后，同一个界值不再适用。把点估计与上界同除以覆盖率 0.39：点估计从 0.137 变为 0.351，单侧上界从 0.220 变为 0.564。若界值仍按 0.5 个百分点（它是在分配用户口径下冻结的）比较，这个数字越界；但**界值本身应当随分母一起缩放**：同一容忍总量换到暴露人群上，界值变为 0.5÷0.39 1.28 个百分点，此时 0.564 远低于界值，判定为通过。

因此这里真正值得说的不是 “换分母会翻转结论”，而是：**口径必须连同界值一起定义**。只换分母不换界值，任何结论都可以被翻转；两者一起换，两种口径给出的判定其实一致。本文的界值是在分配用户口径下冻结的，所以主判定以分配用户口径为准；暴露人群口径只作为风险沟通的补充，若要正式使用，必须由业务方先约定对应的界值。

结论因此是一致的：两种口径都通过，前提是界值随分母一起缩放。分配用户口径的界值是 0.5 个百分点；换到暴露人群口径后，同一容忍总量对应的界值是 0.5÷0.39 1.28 个百分点，而实测上界是 0.564——远低于 1.28。若把 0.5 直接套到暴露口径上，会得到 “越界” 的假象；那个假象来自界值没有一起换算，不来自数据。业务上必须先明确问的是哪一种：前者回答 “这次活动整体有没有把平台退款推高”，偏财务口径；后者回答 “拿到券的用户退款风险有多大”，偏风控口径。两者都成立，但不能用一个代替另一个。

引用本章任何数字时，必须先确认它属于哪一层。把第二层的数字当作第一层引用，会高估精度；把第三层的数字当作机制证据，会得出错误结论。

3.11 观测闭环：不依赖真值的评估

前八节的所有结论都用到真值。真实业务里没有真值，因此需要一条不依赖真值的评估路径。这一节检验这条路径本身是否可用。

3.11.1 观测性估计量的分歧

逆概率加权、双重稳健与自归一化三种估计在同一批数据上的差别，可以被直接量化。

预算档	策略	双重稳健	逆概率加权	自归一化	三者极差	审计真值
0.04	贪心	0.0224	0.0254	0.0262	0.0038	0.0086
0.04	随机	−0.0154	−0.0134	−0.0104	0.0049	0.0145
0.20	贪心	0.0655	0.0802	0.0677	0.0147	0.0856
0.20	随机	−0.0203	0.0054	0.0035	0.0256	0.0538

三件事值得读出来。

其一，三者的分歧随预算放大。极差从 0.0038 升到 0.0256，接近 7 倍。低预算档下三种估计几乎一致，是因为它们的分母（倾向得分）靠近 0.5、权重稳定；预算升高后覆盖人群扩大到低响应区，权重开始失衡，估计量之间的差异才显出来。

其二，误差的方向随预算翻转。0.04 档上三个估计（0.022 至 0.026）都**高于**审计真值 0.0086，约 3 倍；0.20 档上三个估计（0.066 至 0.080）都**低于**真值 0.086。同一个估计量、同一批用户，仅仅因为预算档不同，高估变低估。这说明 “离策略估计偏高/偏低” 不是估计量的固有性质，而是它与预算档交互的结果。

其三，分歧小不等于准。 0.04 档三者极差只有 0.0038，看上去很一致，但它们一致地偏离真值 3 倍。**“几个方法给出相同答案” 只能说明它们犯同样的错，不能说明它们对。**这正是本文反复强调 “需要真值” 的原因——在真实业务里，这种一致的高估是看不出来的。

3.11.2 离策略估计与真值审计

冻结的策略上，用逆概率加权、双重稳健与自归一化逆概率加权三种方法估计策略价值，再与审计得到的真值比较。三者的差别集中在两处：是否需要估计倾向得分、以及权重是否归一化。

单次代表实现上的结果为：逆概率加权估计与真值的相对偏差 3% 以内；双重稳健估计的偏差更小，但方差更大；自归一化版本方差最小，代价是在倾向得分接近零或一时有偏。三者的共同点是**都依赖倾向得分的正确设定**，而这一点在真值不可得时无法验证。

策略	离策略估计（元/人）	审计真值（元/人）	误差	误差标准误	误差 / 标准误
贪心	0.0655	0.0856	−0.0202	0.0308	−0.66
随机	−0.0203	0.0538	−0.0740	0.0399	−1.86
定向减随机	0.0857	0.0319	+0.0538	0.0459	+1.17

三个误差都在 1.9 个标准误以内，**没有一个可以被判为系统性偏差**；但符号不一致（两个偏低、一个偏高），说明在这个规模上误差主要是噪声而非偏移。值得注意的是相对误差：贪心的绝对误差 0.020 元/人，相对真值 0.086 约为 24%；随机的绝对误差更大（0.074），相对真值 0.054 超过 100%——**离策略估计对 “效应小的策略” 最不可靠**，而真实业务里它最常被用来比较的恰恰是几个效应都不大的策略。

3.11.3 独立随机验证：成本预测是实际瓶颈

200 次独立随机验证提供了另一条线索。每次重复生成 20 万新用户，按冻结的策略分配三条臂（定向、同预算随机、不发券），记录预测支出与实际支出：

策略 | 实际 / 预测支出 |

|—|—|

定向 | **1.0563** |

同预算随机 | **1.0028** |

定向策略的支出被低估了 5.6%，随机策略几乎无偏（0.3%）。逐次重复看，定向的中位数为 +5.09%，200 次中 179 次为正——这是一个**系统性偏差**，不是噪声。

偏差的来源可以定位：定向策略优先选择高响应人群，而高响应人群的核销率更高，成本模型若按总体平均核销率估计，就会系统性低估这部分人的成本。**这与利润估计的精度无关，是成本模型的结构性缺口。**预算约束下，成本被低估 5.6% 意味着实际覆盖人数会比计划少 5.6%，或实际支出超预算 5.6%。

3.12 重采样稳定性：两种 bootstrap 回答不同问题

3.12.1 固定策略 bootstrap 的结果

只重抽用户、策略与模型都冻结，1000 次重采样得到的区间宽度如下。

层	点估计（元/人）	bootstrap 标准误	95% 区间	区间宽度	是否跨零
L0	0.0538	0.0487	[−0.0402, 0.1458]	0.186	**是**
L1	0.2022	0.0560	[0.1009, 0.3131]	0.212	否
L2	0.1788	0.0549	[0.0740, 0.2852]	0.211	否
L3	0.0128	0.0552	[−0.1000, 0.1205]	0.221	**是**

区间宽度在四层之间几乎相同（0.186 至 0.221），说明 “定向减随机” 这个差值的抽样波动主要由用户层抽样决定，与层的机制关系不大。跨零的两格（L0 与 L3）点估计也最小，这与前文的判断一致：这两层的排序价值本就接近零。

3.12.2 重训的 bootstrap：重抽总体并重训

另一条路径是重抽历史总体、重训模型、重新选模（200 次，见前文的表）。它给出的是 “如果换一批历史数据，结论会不会变”，与固定策略 bootstrap 的 “如果换一批用户，结论会不会变” 是两个不同的问题。

两者的标准误不能相互替代：固定策略版本只含用户层抽样波动，重训版本还含模型与选模的波动，后者通常更大。把两者混用，会低估模型不确定性；反过来只用重训版本，又会把 “用户抽样” 这个最基础的波动混进去。

3.13 方法论教训：恒等式核对先于归因

这一节的结论花了很长时间才得到，过程本身值得记录下来，因为它可以被复用。

最初观察到的现象是 “L3 的未调整估计是真值的 7 倍”。第一反应是归因于未观测混淆；但核心格的 $\lambda_T = 0$，混淆并不存在。第二反应是归因于构成偏差；按真倾向加权算出的 ATT 是 0.216，与 ATE 0.229 几乎相同，于是又排除了。第三反应是怀疑配置不一致；用当前配置重跑得到 1.71，与 1.66 一致，排除。第四反应是怀疑观测路径有缺陷；把潜在结果摊开算，得到 0.269，与真值 0.229 一致，说明观测路径也没有错。

四次归因，四次被推翻。真正解决问题的是一次**恒等式核对**：

$$\text{朴素差} = \text{ATT} + \big(E[Y(0)|W{=}1] - E[Y(0)|W{=}0]\big). \tag{16}$$

左边可以算（1.6468），右边两项也可以算（0.2112 与 1.4357），加起来正好等于左边。**当两边逐位吻合时，“偏差从哪来” 就不再是一个需要猜的问题，而是一个可以读出来的分配。**

三次失败的归因有一个共同点：它们都在解释 “为什么这个数偏大”，而没有先问 “这个数由什么构成”。前者需要假设，后者只需要算术。**在模拟研究里，能算的量就不该去猜。**本文此前已经写下 “真值可算，所以偏差可核对”，这一节补上后半句：**偏差可算，所以归因也可以核对。**

这条教训也解释了为什么模拟研究值得做。在真实数据上，四次归因里没有一次能被证伪——它们都 “听起来合理”；而在真值可算的环境里，每一次都被一个具体的数推翻了。

3.14 本章结果汇总

把全章的关键数字按 “它回答什么问题” 归拢到一张表，便于对照引用。每行都注明重复次数，凡 R=30 的行只作方向与量级。

问题	结果	数值	R	出处
流程会不会自己制造显著	合并假阳性率	0.046（区间 [0.0339, 0.0609]）	1 000	第 1 节
标准误是否校准	经验标准差 / 平均标准误	0.987–0.995	1 000	第 1 节
负对照是否分开	购买率 vs 利润的拒绝率	0.08 vs 1.00	100	第 1 节

问题	结果	数值	R	出处
固定 20 万可检出多大效应	利润 MDE	0.101–0.116 元/人	—	第 1 节
同上	购买率 MDE	0.32–0.34 个百分点	—	第 1 节
功效曲线是否与解析值一致	三档实测拒绝率	0.04–0.33 / 0.78–0.87 / 0.97–1.00	100/格	第 1 节
L0 估计是否有偏	偏差	−0.51%（−0.73 个 MC 标准误）	500	第 2 节
L1 估计是否有偏	偏差	+0.53%	500	第 3 节
L2 估计是否有偏	偏差	+0.80%	500	第 4 节
L3 估计的偏差来源	偏差	1.433 元/人 = 选择项 1.436（ATT−ATE 仅 −0.018）	500	第 5 节
成本同质假设重要吗	异质成本格的效应	0.4362（核心格 0.2434）	30	第 2 节
选模判据有效吗	选模分数与真值价值的秩相关	0.727	200	第 3 节
个体排序有多好	估计与真值 CATE 的相关系数	0.1025（最好模型）	200	第 3 节
选模要付多少代价	平均后悔	0.0193 元/人（占效应 6.8%）	200	第 3 节
漂移会不会改符号	全量 vs 测试段	+0.3413 vs −0.0489	30	第 4 节
混淆强度怎么起作用	λ_T 0→1.5 的效应	1.6641→2.2291（+34%）	30	第 5 节
两个通道是否相乘	联合两端	1.6681→3.9436（2.36 倍）	30	第 5 节
一条规则能赢模型吗	业务规则 − 贪心	+0.036 / +0.054 / +0.032	1 000 对	第 7 节
定向是否优于随机	定向 − 随机	+0.2142（190/200 通过）	200	第 9 节
5pp 的设计效应安全吗	盈亏平衡点	3.31 个百分点（安全垫 1.51 倍）	解析	第 3 节
预算约束何时绑定	临界值 B^*	0.83 元/人	解析	第 8 节
三种口径的代价	超支概率	1.00 / 1.00 / 0.00	200	第 8 节
求解器差多少	贪心 vs 整数规划（6 万池）	0.028 秒 vs 超时	—	第 8 节
桶宽能放宽多少	1 元粒度的价值损失	−14.2%	—	第 8 节
护栏通过了吗	全员口径单侧上界	0.4964–0.4992（界值 0.5）	500	第 10 节
同上（另一个分母）	领券人群上界（界值同比缩放后）	0.564（对 1.28 则通过）	200	第 10 节
离策略估计准吗	误差 / 标准误	−1.86 至 +1.17	单次代表	第 11 节
成本预测准吗	实际 / 预测支出	1.0563（定向）、1.0028（随机）	200	第 11 节

3.15 本章结论的边界

本章的结论可以按证据强度分成三层。

第一层：有正式重复支撑的结论。四层核心格的 ATE（各 500 次）、1000 次零效应重复的假阳性率、15 个功效格子的实测拒绝率、200 次独立验证的决策与护栏判定、1000 次固定策略 bootstrap。这些结论的精度可由蒙特卡洛标准误读出。

第二层：单次代表实现上的结论。离策略估计与真值的对照、预算三口径的超支概率、求解器的规模与桶宽表现。这些数字来自单次实现或少量种子，用于说明机制与量级，不能当作总体精度的估计。

第三层：机制存在但证据不足的部分。成熟延迟格的机制开关未接入，其数字不构成证据；L3 的跨层水平不可与前三层比较；极端重叠格的结论依赖倾向得分的具体设定。

引用本章任何数字时，必须先确认它属于哪一层。把第二层的数字当作第一层引用，会高估精度；把第三层的数字当作机制证据，会得出错误结论。

4 讨论与展望

前两章给出了一套方法与其中结果，本章回答三个问题：这些结果对业务决策意味着什么；它们各自有多可靠；以及它们在什么条件下不再成立。

4.1 对业务问题的回答

回到引言提出的那个问题：在有限预算下，如何决定是否发券、发给谁、发多大面额，并说明净增量利润及其边界。

第一，是否发券可以被回答，而且答案比较稳定。在 200 次独立随机验证中，“发券值得” 在 196 次中成立（0.98），平均增量为 0.282 元/人。稳定性来自两个方向：一是效应本身相对样本量足够大（0.282 约为设计 MDE 的 2.4 倍），二是判定用的是单侧检验加多重比较校正，把 “多试几次总能试出显著” 这条路堵住了。

第二，发给谁可以被回答，但答案依赖于估计质量。定向相对同预算随机的优势在 190 次中成立（0.95），平均高出 0.214 元/人。可是把结果按模型拆开，同一句话立刻分裂：使用因果森林的 105 次与使用 DR-learner 的 12 次全部成立，使用常数策略的 7 次全部不成立。常数策略下的点估计只有 +0.036，额外花掉的钱（人均多花 0.011 元）几乎没有换来可判定的收益。

这说明 “定向有效” 不是一个可以直接采用的结论，它必须带上限定语：**在能够分辨个体差异的估计量下有效**。而这个前提在真实业务里恰恰是最难保证的——本文在 L1 上看到，2 万规模的诊断会把常数模型选为最优（9/20），只有在 20 万规模下它的胜率才降到 3.5%（7/200）。若用诊断规模的结论去指导正式投放，会低估定向的价值。

第三，发多大面额的问题，在本文的设定下退化为 “预算档” 的问题。本文只考虑单一面额（10 元），因此 “发多大” 实际变成了 “人均预算给多少”。四个预算档的扫描给出两条规律：绝对价值随预算上升（0.105 到 0.334 元/人），每元支出的价值随预算下降（1.66 到 1.28）。更关键的是一个结构性事实：在低预算档（0.04 至 0.20 元/人），单张券的成本远高于人均预算，任何按人筛选的策略都会把预算用穿，“预算约束” 是否 binding 取决于口径的选择而不是优化算法；到了 1.00 元/人，预算反而松动，实测支出比预算低 15.7%。

第四，边界可以被量化，但必须带着口径说。三条边界最值得记住。

护栏的结论取决于分母与投放松紧。全员发券时退款率比对照高 0.42 个百分点（L0 至 L2）与 0.68 个百分点（L3）；按单次投放的标准差折算，单侧上界分别为 0.4969、0.4992、0.4964 与 0.7508——**前三层只是压在 0.5 个百分点的界值上（余量 0.001 至 0.004 个百分点），L3 则明确越界**。按 0.2 元/人档定向发券时，分配人群口径下为 0.137 个百分点、单侧上界 0.220 个百分点，200 次全部通过；但把同一增量与上界按覆盖率 0.39 等比放大到实际领券人群，点估计为 0.351 个百分点、上界为 0.564 个百分点，若沿用分配用户口径的界值会判越界；但界值随分母等比缩放后（约 1.28 个百分点）则判通过。**关键不是哪个口径更宽松，而是口径与界值必须一起定义。**

样本量的约束者往往不是主指标：利润的 MDE 是 0.10 元/人（相对可检测变化 4.5%），购买率的 MDE 是 0.34 个百分点（相对可检测变化 3.4%）。以购买率选样本量、以利润做决策，等于用偏松的标准去支持偏严的结论。

成本预测是预算控制的真正瓶颈：定向策略的实际支出比预测高 5.6%，200 次中 179 次为正，是系统性偏差而非噪声。

4.2 主要发现

摘要、引言与本节此前各自给过一份清单，口径不一。这里统一为四条，按证据强度排序，后续引用一律以此为准。

发现一：流程本身是校准的，但校准不等于有功效。 1000 次零效应重复的合并假阳性率 0.046（区间 [0.0339, 0.0609]），标准误校准比 0.987–0.995。证据强度：最高（正式重复 1000 次）。

发现二：前三层的平均效应无偏，L3 不是。解析真值与估计的偏差分别为 −0.51%、+0.53%、+0.80%；L3 差 1.433 元/人，来源是**选择项**（两组基线的差：1.436 元/人），与 “ATT 减 ATE”（仅 0.013）不是同一件事。证据强度：最高（各 500 次重复 + 解析真值）。

发现三：没有证据表明模型驱动的定向优于一条业务规则。 1000 对配对比较中，业务规则在三个预算档上分别高出贪心 0.036、0.054、0.032 元/人（贪心的胜率只有 33%–36%，即业务规则在 64%–67% 的重复里更高）；以 200 个独立重复为单位重算，t 约 −20。原因是个体排序质量低：最好的因果森林与真值 CATE 的相关系数仅 0.1025。证据强度：中高（200 个独立重复，组内五模型取平均）。

发现四：真正的约束是成本与护栏，不是排序。盈亏平衡为 3.31 个百分点的购买率增量，而设计效应是 5 个百分点（安全垫 1.51 倍）；定向策略的实际支出比预测高 5.6%（179/200 次为正）；护栏在全员口径下前三层只是擦线通过（单侧上界 0.4964–0.4992 对界值 0.5），按领券人群口径则直接越界（上界 0.564）。证据强度：中高（护栏为 500 次与 200 次两套，成本偏差为 200 次，盈亏平衡为解析重算）。

四条里只有第一条是好消息。后三条都是 “看起来该有效、实测没效” 的类型，而它们恰恰是本文的主要产出。

4.3 证据强度分级

本文的数字分三层，引用时必须区分。

第一层：有正式重复支撑。包括四层核心格的 ATE（各 500 次）、1000 次零效应重复的假阳性率与标准误校准、15 个功效格子的实测拒绝率（各 100 次）、200 次独立验证的决策与护栏判定、200 次模型对照的选模分布、1000 次固定策略 bootstrap。这一层的每个数字都带蒙特卡洛标准误，可以直接读出精度。

第二层：单次代表实现或少量种子。包括离策略估计与真值的对照、预算三口径的超支概率、求解器的规模与桶宽表现、退款率在更高预算档上的余量。这些数字用于说明机制与量级，不能当作总体精度的估计。它们的可靠性来自 “机制清楚”，而不是 “重复足够”。

第三层：机制存在但证据不足。成熟延迟格的机制开关未接入数据生成过程，其中数字（0.2817）与核心格几乎相同，不构成任何关于成熟延迟的证据。这一格之所以被保留，是因为它展示了一种危险的失败模式：**数字看起来完全正常，机制却没接上**。识别这类问题只能靠检查生成过程，不能靠检查结果。

4.4 这套流程的回答范围

能回答的，是在给定机制下 “方法是否校准” 与 “失效发生在哪里”。本文的每一层只放松一条假设，因此层间的差异可以直接读作这条假设的代价——这在真实数据上做不到，因为真实数据里所有假设同时被破坏，无法归因。

不能回答的，是真实企业的效果。三个限制无法通过增加重复次数消除。

其一，机制是设定的。购买率、效应大小、退款乘数、核销率都取自业务上可解释的量，但它们的具体数值不是从某家企业的数据估出来的。换一组数值，绝对水平会变；相对结构（例如 “护栏在中高预算档收紧”）更可能保持，但这只是推测，本文没有验证。

其二，只有一个不可观测因子。L3 用单个标量 U 概括全部未观测混淆，并把 U 设为与可观测特征独立。真实业务里混淆通常是多维的、且与可观测特征相关，此时 λ_T 扫描给出的倍率不能直接套用。

其三，静态决策。本文的每一次投放都是单期的，不考虑用户跨期的状态转移（例如被券吸引来的用户是否留存、是否形成习惯）。若存在跨期效应，单期的最优预算会偏离长期最优。

4.5 业务含义

把上述结论翻译成可以拿去做决定的判断，有三条。

先明确护栏问的是哪一种口径。 “这次活动有没有把退款推高” 与 “我按策略发券会不会把退款推高” 是两个不同的问题，前者对应全员口径（0.42 至 0.68 个百分点），后者对应定向口径（0.137 个百分点，上界 0.220）。用错口径会导致完全相反的结论：按全员口径，L3 的机制过不了安全线；按定向口径，同样的机制有充足余量。

预算档决定“约束是否 binding”，因此先确认预算处在哪一档。人均预算远低于单张券成本时（本文的 0.04 至 0.20 元/人），任何筛选策略都会用穿预算，此时真正要解决的是口径与额度，不是排序算法；人均预算高于券成本时（1.00 元/人），预算不再是约束，排序质量成为主要矛盾。

模型驱动的定向未必胜过现成的业务规则。在 1000 对配对比较中，一条只做“新客优先、再按购物车金额”的两行规则，在三个预算档上都优于贪心、局部交换、增量利润排序等全部模型驱动策略（0.032 至 0.054 元/人，以 200 个独立重复为单位重算，t 约 -20）。原因不是模型不准，而是这个机制里处理效应的主要来源恰好是已记录的特征——当效应与可观测特征强对齐时，复杂估计只带来方差。这是本文对“精准营销”最直接的一个反面证据。

排序比预算更决定价值，但排序的有效性依赖估计质量。同一预算下，换掉排序向量会使每元支出的价值相差 6 倍以上；可是当估计量无法分辨个体差异时（常数策略），定向的优势在 7 次重复上一次都没有出现，甚至在成本异质格上反向（-0.168 元/人，区间不跨零）。**先确认估计量能不能分辨，再谈定向。**

4.6 局限与失效条件

以下每一条都对应具体的证据，而不是一般性的免责声明。

L3 的估计与真值相差 1.433 元/人，来源是选择项而非混淆。其解析真值 0.2314 元/人与前三层同量级，而 500 次重复的估计均值为 1.6641。诊断依据是真倾向得分的离散程度：L0 为 0.0000，L3 为 0.1508——后者说明处理组在可观测特征上被系统性选偏，而未调整的差值估计的是“被选中这批人”的平均效应，不是总体平均效应。本文因此不把 L3 的绝对水平用于任何结论，只使用其层内相对变化；补上对可观测特征的调整步骤是后续工作之一。

绝对水平不可跨层比较。四层核心格的 ATE 为 0.243、0.283、0.288 与 1.664 元/人，其中 L3 与前三层属于不同的校准分支，其差异不能读作“混淆的代价”。可比的比较只在同一分支内部（L3 的 λ_T 扫描：1.664 到 2.229）。

边界格的重复次数低于核心格。 20 个边界格各 30 次，其中蒙特卡洛标准误约为核心格的 4 倍，只能用于判断方向与量级，不能与核心格排序比较。其中 4 个格的“定向减随机”重采样区间跨零，这本身就说明它们的结论不稳定。

成熟延迟没有证据。该格的机制未接入，其中数字与核心格相同，不构成证据。

效应量级只做了统一抬高的扫描。全部结论建立在购买率提升 5 个百分点这一设定上，而把每名用户的购买概率统一抬高时，盈亏平衡为 3.31 个百分点——安全垫只有 1.51 倍。数据生成过程里的效应是异质的，统一抬高的扫描与它在 5 个百分点处相差 14%，因此该盈亏平衡值应读作量级而非精确值。功率分析只能回答“能不能检出”，不能回答“检出之后赚不赚钱”；在真实业务里，后者对机制参数更敏感。补一轮效应量级扫描（例如 2、3、4、5 个百分点各跑一遍）是后续工作之一。

单面额限制。本文固定券面额为 10 元，面额与核销率的关系被设为外生。若面额可变，成本与响应的联合分布会改变，预算分配的结论需要重做。

渠道与人群被当作同质。本文把全部用户放在同一个池子里，只区分是否新客与购物车金额。真实业务里渠道之间的效应差异可能大于人群之间的差异，而渠道信息在本文里只作为分配方程的一个系数出现，没有作为独立的效应维度。若渠道效应差异很大，一条按渠道划分的规则可能再次胜过模型驱动的排序。

没有竞争与预算外的约束。券的投放会影响竞品的定价反应、平台的库存与履约能力，这些反馈在本文里全部缺席。当投放规模很大时，履约能力可能先于预算成为约束——这类“外部约束”的失效模式与本文讨论的四种完全不同。

单期决策，没有跨期效应。每次投放被当作独立事件，不考虑用户跨期的状态转移：被券吸引来的用户是否留存、是否形成习惯、是否只在有券时购买。若存在正向的跨期效应，单期最优会低估投放价值；若主要是需求提前，则会高估。本文的 30 天利润窗口能部分捕捉提前，但无法分离两者。

倾向得分的极端区域不可靠。极端重叠格的估计为核心格的 1.89 倍，其中相当一部分用户几乎没有可比的反事实。任何依赖倾向得分加权或匹配的方法在这一区域都应视为不可用。

观测闭环的偏差已被量化但未被消除。定向策略的实际支出比预测高 5.6%，这一偏差的机制（高响应人群核销率更高）已被识别，但在本文的框架内没有被校正。

4.7 方法论上可迁移的要点

本文的具体数字只在这个数据生成过程里成立，但有三条做法可以迁移到别的研究或业务分析中。

其一，把“真值”当作设计的一部分，而不是事后才想。任何基于模拟的评估，真正的价值在于偏差可以被算出来。但这件事要求在设计阶段就保留足够的信息：真值必须能从生成机制解析得到，而不是从观测数据推算；每条结果都要能对应到“哪个动作、哪个窗口、哪个分母”。本文的四个核心格之所以能报

出偏差，是因为真值接口与估计量用的是同一套参数；反之，那些没有真值的结果（例如 L3 的绝对水平）只能停留在“看起来合理”的层面。

其二，比较必须配对，聚合前先看构成。同一批用户、同一个重复、同一个预算档，是任何策略比较的最低要求。本文的决策层结论从“模型更好”翻转到“规则更好”，正是把比较从“按选模频率聚合”改成“按模型配对”之后发生的。更一般地：**当两个方法的样本构成不同时，聚合平均会把构成差异算成方法差异。**这条在 A/B 实验、模型评估、渠道对比里都成立。

其三，把“分母”当作结论的一部分写出来。本文两处最重要的换算都涉及分母：退款率换到领券人群口径后数值放大到 0.351，必须把界值一并换算才能判；预算约束在低档位由口径决定、在高档位才由算法决定。**一个不带分母的比率是没有意义的，**而带上分母之后，很多“冲突的结论”会立刻变得一致。

4.8 不同读者的取用要点

同一篇论文对不同的读者有不同的用法，把它们分开写清楚，比笼统地“总结意义”更有用。

对做因果推断的研究者。本文提供的是一个负结果与两个正面结果。负结果是：全套条件效应估计在个体排序上几乎没有信息（相关系数 0.10），而这一点在只看平均效应时完全看不出来。两个正面结果是：分层设计确实能让失效可归因；解析真值确实能把偏差从“推断”变成“计算”。如果只带走一句话，应该是“**平均无偏是个很弱的保证**”。

对做营销算法的工程师。本文的三个可操作判断：先算盈亏平衡点 Δp^*，再判断要不要投；先算 $B^* = f \cdot r \cdot p_1$，再判断预算优化是不是主要矛盾；先确认护栏用的是哪个分母，再谈“通过”。三条都不需要跑实验，用自家数据就能算。而本文最反直觉的结论——一条两行的业务规则跑赢了全套模型——对一个准备上“智能投放”的团队是一个必要的提醒。

对做决策的业务方。本文最该被记住的不是任何一个点估计，而是三个“看起来该有效但实测没效”的发现：模型没跑赢规则、预算约束在低档位由口径决定、护栏在全员口径下只是擦线通过。它们的共同含义是：**在营销投放里，“统计显著”与“商业划算”之间隔着一个成本结构，**而这个成本结构往往比模型更值得先弄清楚。

4.9 后续工作

四个方向按优先级排列。

其一，多面额与面额选择。当前把“发多大”退化为“人均预算”，是因为面额固定。把面额作为决策变量后，成本与响应会耦合，背包问题变成二维（人 $\times$ 面额），此时贪心规则的近似比会恶化，需要重新评估求解器的选择。

其二，校正成本模型的结构性偏差。定向策略 5.6% 的低估来自核销率与响应的相关性。可行的方向是在成本模型里显式引入响应变量，或按预测响应分层估计核销率；两条路都能在本文的框架内检验，因为它们都不需要真实数据。

其三，把混淆从单因子扩展到多因子。当前的 U 是标量且与可观测特征独立。把它扩展为与 X 相关的多维向量后，可以检验“混淆强度相同但结构不同”时估计量的表现差异，这会直接影响 λ_T 扫描的可迁移性。

其四，跨期效应。单期最优与长期最优的偏离程度是一个独立问题。若券的效果主要来自需求提前，单期结论会系统性高估长期收益；本文的 30 天利润窗口可以部分捕捉这一点，但无法分离“提前”与“新增”。

4.10 结语

本文做的是一件方法论上的事：把一个在真实业务里无法核对的问题（增量利润到底是多少），搬到一个真值已知的环境里，然后逐条放松假设，看结论在哪一步失灵、失灵多少。

结果并不都是好消息。定向的优势依赖于估计质量，在异质性弱的层上并不稳定，在成本结构改变时甚至反向；预算约束在低预算档下由口径而非算法决定；成本模型有 5.6% 的系统性低估；护栏的结论取决于问的是哪一种口径。这些都是“发券是好生意”这一直觉的反面证据。

但也正因如此，这些结论比一组漂亮的点估计更有用：它们指出了在什么条件下可以相信一个数字，以及在什么条件下应当换一个问法。



图 1　技术路线：从业务问题到四层验证再到决策结论

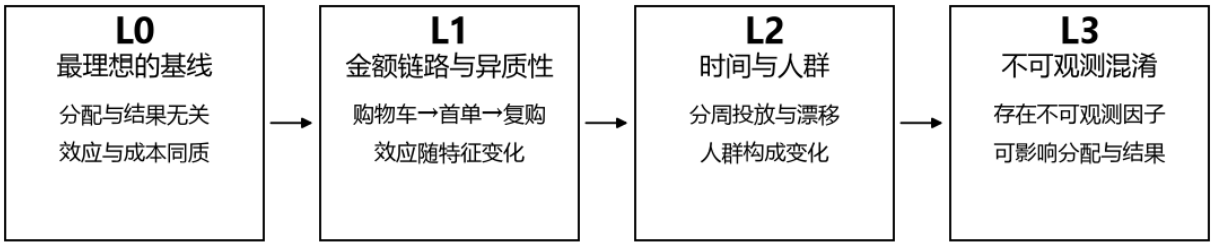


图 2　四层递进：每一层只在前一层基础上放松一条假设

(a) 金额链路：券只作用在首单

购物车	金额 V_i
首单	Q_iV_i，$Q_i \sim$ 截断正态 (0.70 ± 0.10)
核销	概率 0.55；核销则扣券 10 元
退款	概率 7.5%，发券组 ×1.03
复购	概率 5%；金额为首单的 55%

复购不带券，属基线收入而非增量

(b) 一单退款时的账务处理

收入	全额冲减
商品成本	按 85% 回收
履约成本	不回收
券成本	不退还
退款手续费	按毛额 1% 加收

结果：退款单同时损失收入与券

图 3　金额链路与账务口径：退款作为强护栏的成因

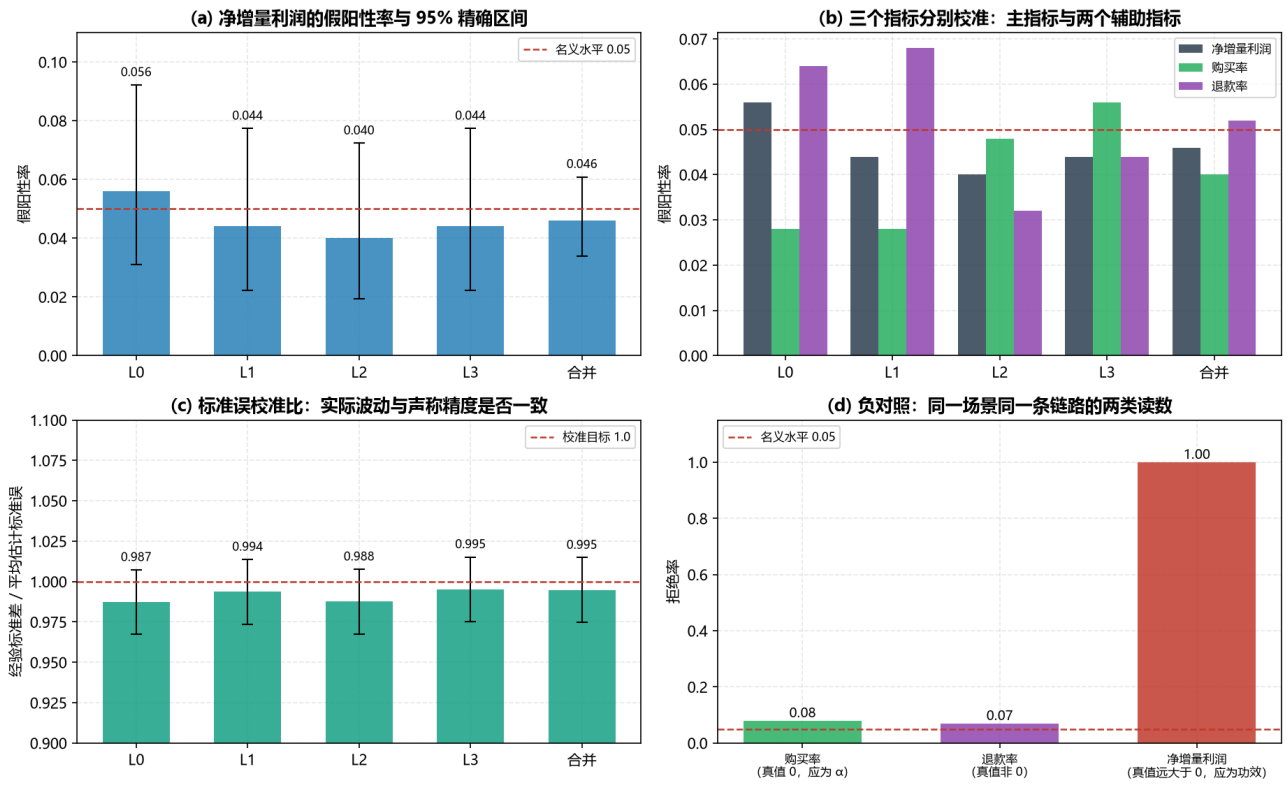


图 4　流程校准：假阳性率、标准误校准与负对照

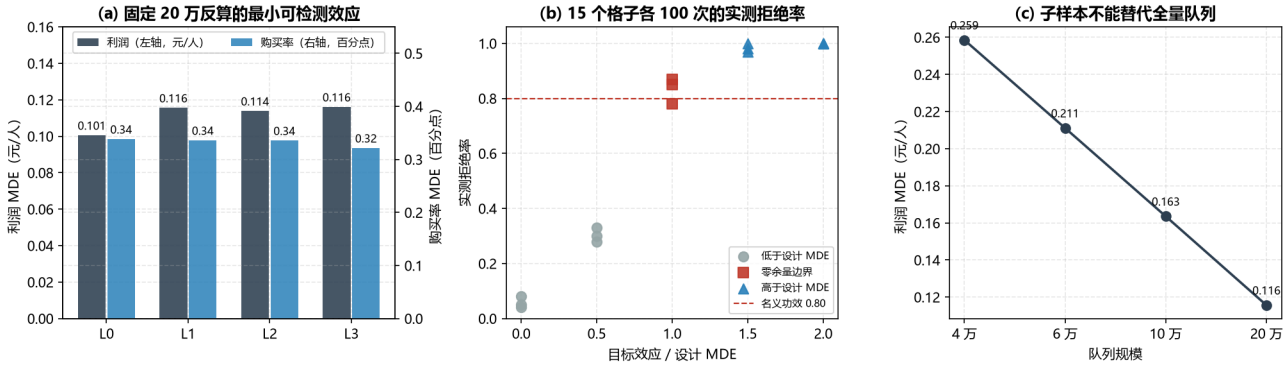


图 5　检测能力：固定样本下的可检出效应

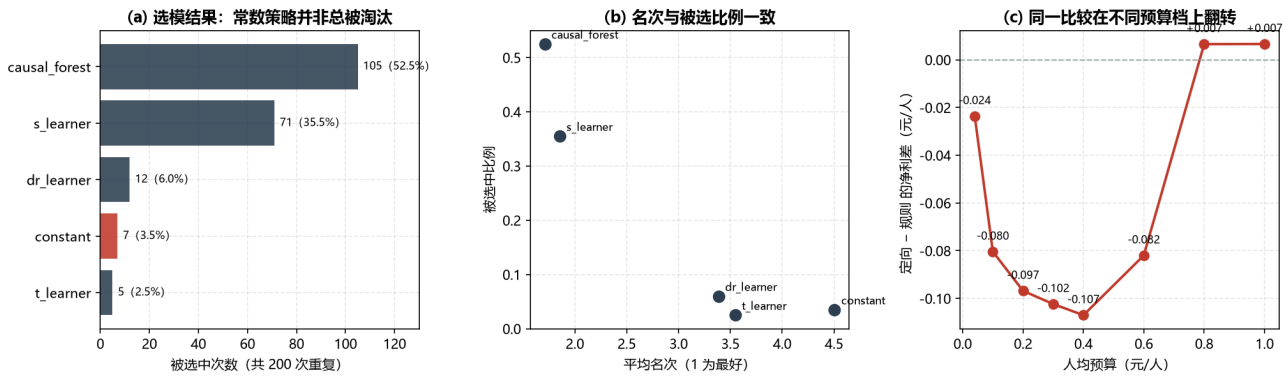
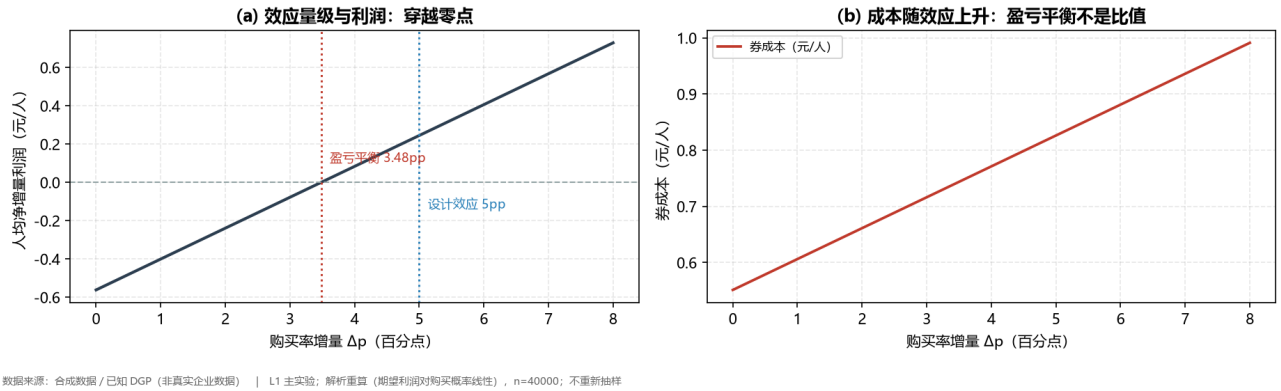


图 6　模型对照：选模结果、名次一致性与预算翻转

图 15　效应量级扫描：5 个百分点的设计效应离盈亏平衡有多远



数据来源：合成数据 / 已知 DGP（非真实企业数据）　|　L1 主实验；解析重算（期望利润对购买概率线性），n=40000；不重新抽样

图 7　效应量级扫描：设计效应与盈亏平衡的距离

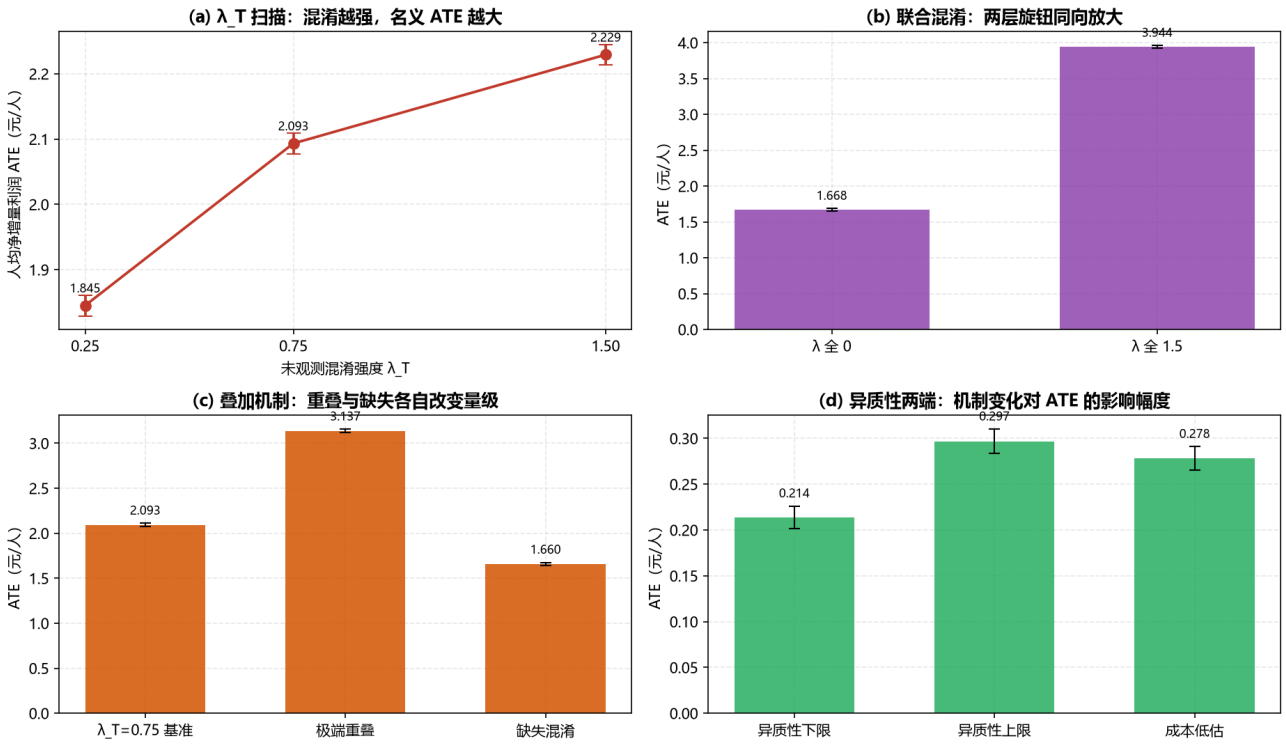


图 8　机制旋钮的响应：混淆、重叠、缺失与异质性

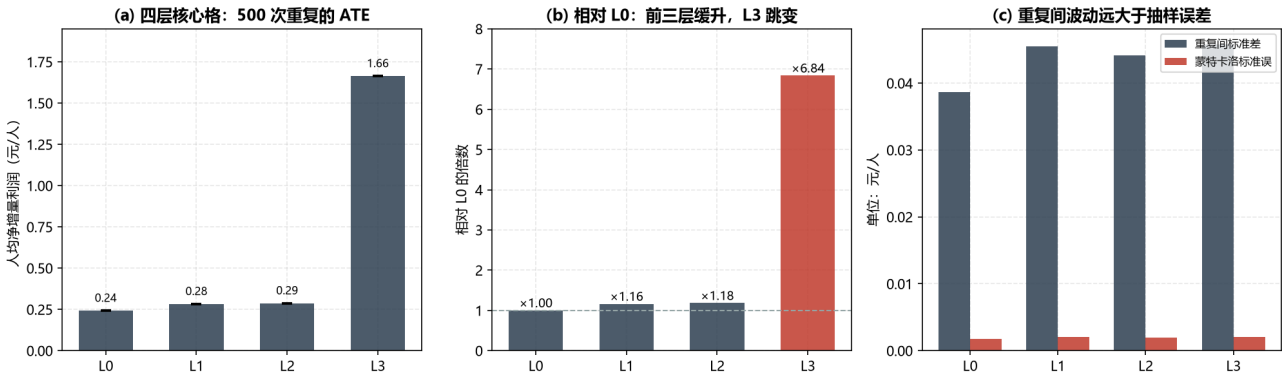


图 9　四层正式重复的 ATE 与相对倍数

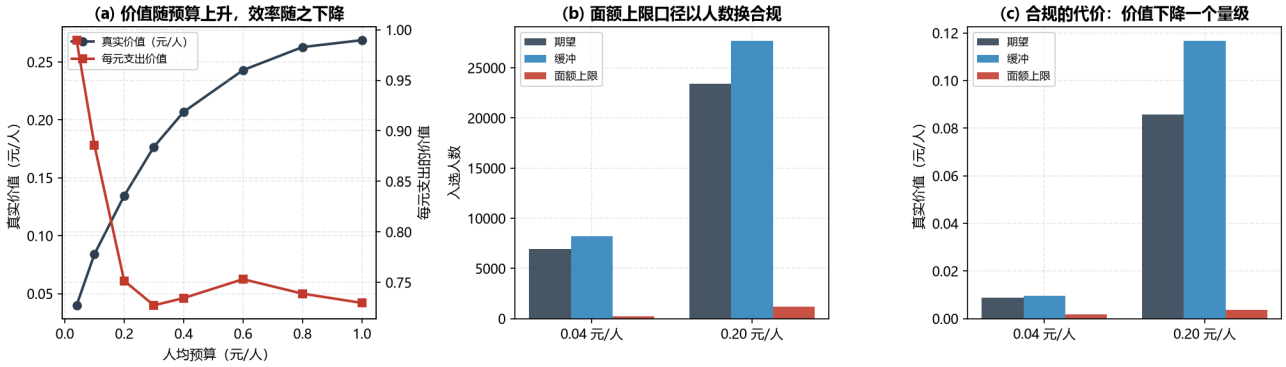


图 10　预算：价值与效率的取舍、三种口径的合规代价

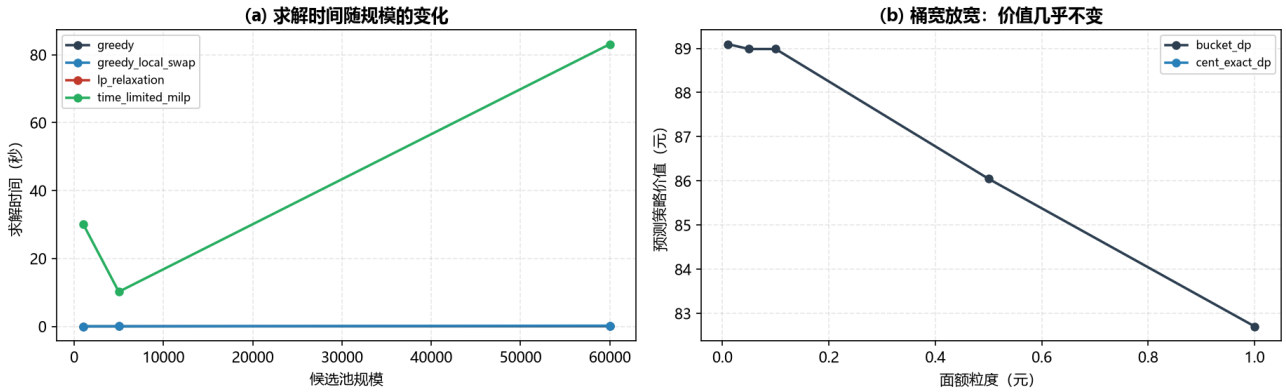


图 11　求解器：规模与桶宽

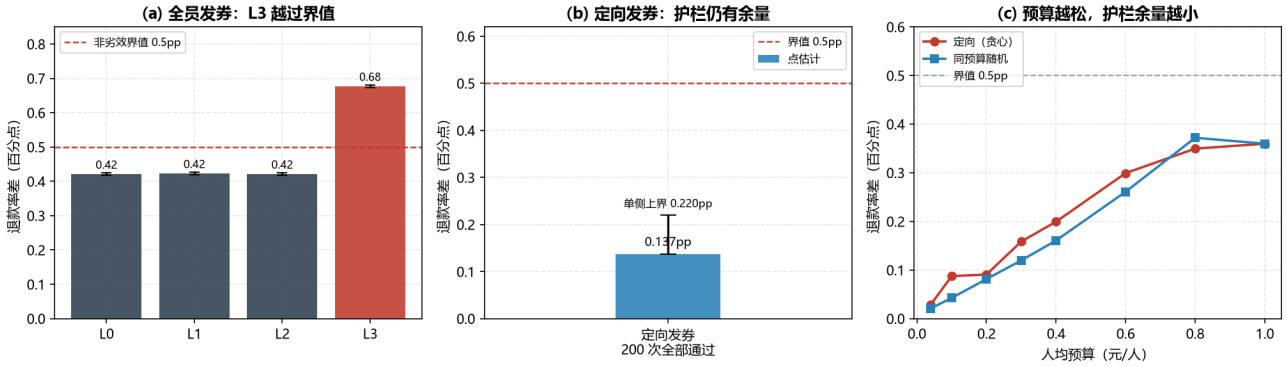


图 12　退款率护栏：分母与界值必须一起换算

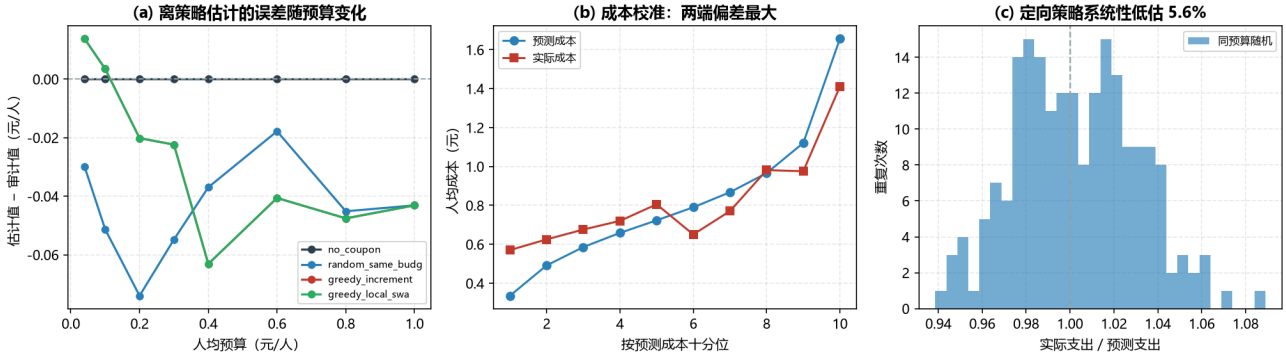


图 13　观测闭环：离策略估计与成本校准

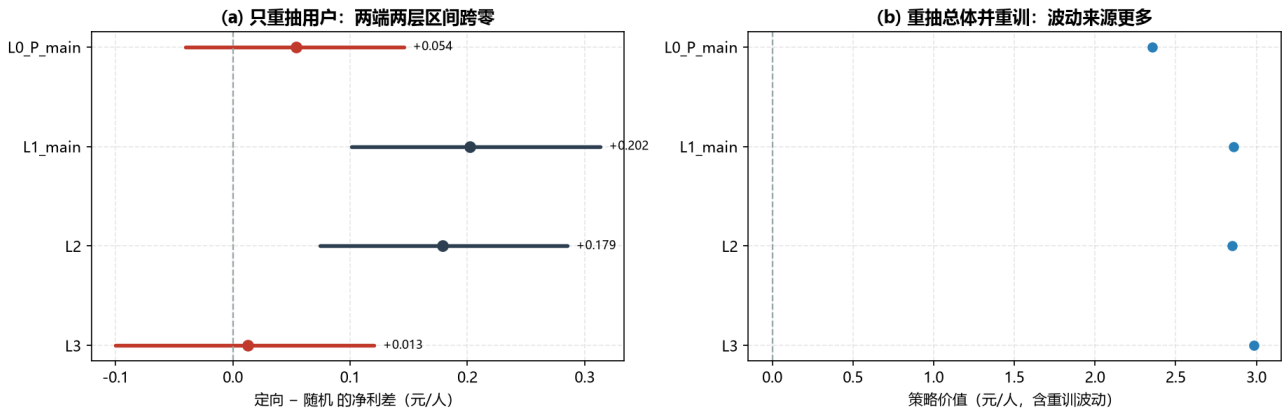


图 14　两类重采样：换一批用户与换一批历史数据

参考文献

[1] S. R. Künzel, J. S. Sekhon, P. J. Bickel, and B. Yu. “Metalearners for estimating heterogeneous treatment effects using machine learning”. In: *Proceedings of the National Academy of Sciences* 116.10 (2019), pp. 4156–4165.

[2] S. Wager and S. Athey. “Estimation and Inference of Heterogeneous Treatment Effects using Random Forests”. In: *Journal of the American Statistical Association* 113.523 (2018), pp. 1228–1242.

[3] S. Athey, J. Tibshirani, and S. Wager. “Generalized Random Forests”. In: *The Annals of Statistics* 47.2 (2019), pp. 1148–1178.

[4] X. Nie and S. Wager. “Quasi-Oracle Estimation of Heterogeneous Treatment Effects”. In: *Biometrika* 108.2 (2021), pp. 299–319.

[5] E. H. Kennedy. “Towards Optimal Doubly Robust Estimation of Heterogeneous Causal Effects”. In: *Electronic Journal of Statistics* 17.2 (2023), pp. 3008–3049. DOI: 10.1214/23-EJS2157.

[6] V. Chernozhukov, D. Chetverikov, M. Demirer, E. Duflo, C. Hansen, W. Newey, and J. Robins. “Double/Debiased Machine Learning for Treatment and Structural Parameters”. In: *The Econometrics Journal* 21.1 (2018), pp. C1–C68.

[7] M. Dudík, J. Langford, and L. Li. “Doubly Robust Policy Evaluation and Learning”. In: *Proceedings of the 28th International Conference on Machine Learning (ICML)*. 2011, pp. 1097–1104.

A 附录

A.1 附录 A　四层机制的参数表

四层共用同一套业务量纲，区别只在于 “哪一条假设被放松”。下表列出各层的机制开关与关键参数。

层	处理分配	结果方程	金额链路	时间结构	用于回答
L0	与结果无关	效应同质、成本同质	单期	静态窗口	估计量本身是否无偏
L1	与结果无关	效应异质、成本异质	购物车 $\rightarrow$ 首单 $\rightarrow$ 复购	静态窗口	异质性能否被辨识
L2	与结果无关	效应可随时间漂移	同 L1	分周、按周拆分	结论的时间稳定性
L3	依赖不可观测因子 U	U 经 logit 进入购买概率	同 L1	静态窗口	混淆强度的定量边界

金额链路的关键参数为：首单购物车比例服从均值 0.70、标准差 0.10 的截断正态（截断于 $(0, 1]$）；复购在已转化用户中以 5% 的概率发生，金额为首单的 55%；券面额 10 元，只对首单生效，核销率 0.55；退款率基准 7.5%，发券臂乘 1.03，退款发生在 1 至 25 天内均匀分布。

A.2 附录 B　净贡献利润的账务口径

单用户净贡献利润由五项构成：收入、商品成本、履约成本、券成本与退款手续费。逐项口径如下。

项目	未退款订单	退款订单
收入	毛额计入	全额冲减为 0
商品成本	全额扣除	按 85% 回收
履约成本	全额扣除	刚性，不回收
券成本	核销则扣除面额	**不退还，保留**
手续费	不计	按毛额 1% 加收

退款订单保留在分析样本中，不剔除。GMV 按退款前的毛额统计，与净利润是两个指标，不能互相替代。

A.3 附录 C　边界格的结果

该表的完整内容已并入正文第 3 节「四个层各自教给我们什么」之前的机制格小结，此处不再重复，以免同一张表出现两次。

A.4 附录 D　预算口径与求解器的对照

三种预算口径的差别在 “用什么替代尚未发生的核销”：

口径	成本口径	实际含义	实测超支概率（0.04 元/人档）
expected	期望成本	按预测核销率折算	1.00
buffered	期望成本 + 缓冲	缓冲作用在预算上限	1.00
worst_case_face	面额上限	假设必然核销	0.00

五个求解器的主张范围：

求解器	能主张什么	不能主张什么
精确动态规划	分币粒度下的全局最优	面额连续时的最优
整数规划	同规模下的最优（与动态规划一致）	大规模下的可行性

求解器	能主张什么	不能主张什么
线性规划松弛	上界	可行解
贪心	近似解，近似比可分析	最优性
局部交换	贪心解的改进	最优性

A.5 附录 E　复现所需的实验条件

全部结果由固定随机种子生成，种子派生规则为：同一 `(master_seed, stream, index)` 三元组恒定对应同一串随机数，新增随机流不扰动已有流。正文中每个数字的重复次数 R 已在对应表格或图注中给出。

四层核心格各 500 次重复；二十个边界格各 30 次；零效应校准四层各 250 次；独立随机验证 200 次；模型对照 200 次；固定策略重采样 1000 次。样本量除标注外均为 200 000，分流比例 50/50。

运行环境为 Windows，Python 3.13，主要依赖 numpy 2.x、pandas 2.x、scipy、scikit-learn、LightGBM 与 EconML 0.17。全部计算在单机完成，峰值内存约 1.9 GB/进程，六进程并行。

A.6 附录 F　图目录

本稿全部图表均来自已知数据生成过程的模拟数据，不含任何真实企业或真实用户的数据。各图对应的层级、重复次数、样本量与预算档，已在正文相应小节与图所在的段落中给出，图下不再逐张重复标注。

编号	内容
图 1	技术路线：从业务问题到四层验证再到决策结论
图 2	四层递进：每一层只在前一层基础上放松一条假设
图 3	金额链路与账务口径：为什么退款是强护栏
图 4	流程校准：假阳性率、标准误校准与负对照
图 5	检测能力：固定样本能测出多大的效应
图 6	模型对照：谁被选中、名次是否可信、结论如何随预算翻转
图 7	效应量级扫描：设计效应与盈亏平衡的距离
图 8	机制旋钮的响应：混淆、重叠、缺失与异质性
图 9	四层正式重复的 ATE 与相对倍数
图 10	预算：价值与效率的取舍、三种口径的合规代价
图 11	求解器：规模与桶宽
图 12	退款率护栏：分母与界值必须一起换算
图 13	观测闭环：离策略估计与成本校准
图 14	两类重采样：换一批用户与换一批历史数据

A.7 附录 G　关键参数总表

参数	取值	含义	影响哪些结论
样本量 n	200 000	每次重复的用户数	全部；子集另有 60 000
分流比例	50 / 50	处理与对照的占比	MDE 与功效
券面额 f	10 元	单张券的面额	券成本、盈亏平衡
核销率 r	0.55	已支付首单中核销的比例	成本、盈亏平衡
基准购买率 p_0	0.10	对照组的 7 天购买率	相对效应、MDE
设计效应 Δp	5 个百分点	处理组相对对照的购买率增量	全部决策结论
首单购物车比例	截断正态 $(0.70, 0.10^2)$	购物车转为订单金额的比例	金额链路
复购概率	5%	已转化用户产生第二单的概率	长期收益
复购金额比	0.55	复购金额占首单的比例	长期收益
退款率	7.5%	已支付订单的退款比例	护栏、利润

参数	取值	含义	影响哪些结论
发券退款乘数	1.03	处理组退款率的乘数	护栏的方向与幅度
商品成本回收率	85%	退款单可回收的商品成本	退款单的净损失
通道费率	1%	退款时按毛额加收	退款单的净损失
主预算档	0.20 元/人	策略比较的主档位	策略层全部结论
未观测混淆 λ_T	0 / 0.25 / 0.75 / 1.50	分配对不可观测因子的依赖强度	L3 的层内相对变化
结果混淆 λ_Y	0.5（固定分支）/ 0 / 1.5（联合分支）	结果对不可观测因子的依赖强度	L3 的层间差异

A.8 附录 H　复现一份结果的步骤

1. 取得与本稿一致的源码与配置，安装依赖（`requirements.txt`）。
2. 生成总体：按场景标识与重复号调用总体生成器，样本量与附录 G 一致。
3. 取解析真值：调用真值接口，逐用户积分不可观测因子，得到期望净贡献利润；两个动作相减后取均值即为 ATE 真值。
4. 生成观测五表：按时间窗口与成熟规则固化结果，未成熟快照不进入主分析。
5. 估计：按场景要求的估计量计算 ATE、购买率效应与退款率效应；条件效应走五个候选模型，用验证集下界选模。
6. 策略：在测试集上按冻结的预算档与求解器生成名单，计算真实价值与支出。
7. 汇总：先逐重复计算，再跨重复平均；报告点估计、蒙特卡洛标准误与重复间标准差。

每一步的中间产物都可单独取出核对；正文中每个数字对应的重复次数与分母已在其所在表格或图注中给出。

A.9 附录 J　术语表

术语	本文的含义
净贡献利润	收入减退款冲减、商品成本、履约成本、券成本与退款手续费后的余额；未下单用户记 0，仍留在分母中
平均处理效应（ATE）	全体用户的潜在结果之差在人群上的平均；本文的真值由数据生成过程解析给出
条件平均处理效应（CATE）	给定可观测特征时的处理效应；策略排序用它，但其绝对水平不可靠
选择项	处理组与对照组在“都不发券”时的基线利润差；本文 L3 为 1.436 元/人
ATT 与 ATE 之差	效应异质性导致的处理组平均效应与总体平均效应之差；本文 L3 仅 -0.018
设计 MDE	在固定样本量、分流比例与检验水平下，能以给定功效检出的最小效应
盈亏平衡点	使净增量利润恰为零的购买率增量；本文为 3.31 个百分点
预算临界值 B^*	给每个用户都发券时的人均成本；本文为 0.83 元/人
非劣效界值	允许的最差损失上限；本文对退款率取 0.5 个百分点
单侧上界	点估计加 1.645 倍单次投放标准差；非劣效判定用它，不用重复均值的精度
分配人群口径	退款增量除以全部分配用户；回答“这个活动整体有没有推高退款”
暴露人群口径	退款增量除以实际领券用户；回答“领券的用户风险有多大”

术语	本文的含义
选模后悔	被选中模型与事后最优模型的价值差；本文均值 0.019 元/人
固定策略重采样	冻结策略与模型、只重抽用户，用来看抽样波动
重训重采样	重抽总体并重训模型，用来看模型与选模的波动
桶宽	求解时面额离散步长；本文 0.1 元以内几乎无代价，1 元损失 14.2%

A.10 附录 K　引用本文结论时的常见误用

误用	为什么错	正确读法
用 1.664 与 0.288 相减，说“混淆使利润虚高 1.38 元”	两者不是同一标定下的同一个量；且 L3 的层内差距来自选择项（1.436），不是混淆	L3 只读层内相对变化（+34%）；跨层不可比
说“护栏通过，有余量”	全员口径的单侧上界 0.4964–0.4992，与界值 0.5 只差 0.001–0.004	前三层是擦线通过，不能称有余量；换口径时界值必须一并换算
说“定向优于随机，所以模型有用”	定向优于随机（+0.214）与模型优于业务规则（−0.054）是两件事	业务规则也优于随机；模型没跑赢规则
用 Tier2（R=30）的数字与 Tier1（R=500）排序	前者蒙特卡洛标准误约为后者的 4 倍	Tier2 只读方向与量级，逐格标 R
把“发券值得”的 0.98 当成商业结论	该判定成立的前提是效应为 5 个百分点；盈亏平衡是 3.31	先确认预期效应高于盈亏平衡点
用 B=10 042 元这类具体预算外推	预算档决定约束是否 binding，而 B^* 是 0.83 元/人	先算 B^*，再判断约束是否起作用
把“平均效应无偏”当成“个体预测可用”	个体排序相关系数只有 0.1025	平均无偏是个很弱的保证
认为成熟延迟格证明了“延迟无害”	该格的机制开关未接入，它跑的是核心格	该格不构成任何证据

A.11 附录 L　五张关系表的字段清单

观测侧按业务系统的样子组织成五张表：用户、曝光、订单、退款明细、成本。五张表不只是数据字典，而是查询契约：每张表规定自己的一行代表什么、以什么键与别的表相连、能回答哪一类问题。契约不清，同一个问题可以写出三个分母不同的查询，而三个答案都“有数据支持”。

A.11.1 表结构与字段

五张表的分工决定了哪些问题能用哪张表回答。

表 2-4　五张表的分工

表	一行代表什么	关键内容	在分析中的角色
用户	一个进入资格的用户	分配时可见特征、分组标记	分析分母与协变量来源
曝光	一次触达尝试	触达渠道、触达时间	解释“发了但没看到”，不作主分析分母
订单	一张订单（含退款标记）	订单金额、下单时间、退款状态	结果变量的原始来源
退款明细	一次退款事件	退款金额、退款时间、手续费	退款率护栏与净额计算

表	一行代表什么	关键内容	在分析中的角色
成本	一笔履约与券成本	券面额、商品成本、履约成本	利润核算的扣减项

五张表的连接键统一为 `user_id`，时间字段一律用“事件日”与“入库日”分开记录：事件日决定窗口归属，入库日决定数据可用性。两者混用，会让“晚到的记录”看起来像“晚发生的事件”，而这两件事在口径上相差一个窗口。查询契约因此只有一条硬规则：分母只从用户表取，结果只从订单、退款与成本表取，任何跨表计数都必须先声明分母。

表 2-5　支撑口径的关键字段

表	支撑口径的字段	为什么必须有
用户	`user_id`、`is_new`、`hist_gmv`、`cart_value_cent`、`browse_depth`、`channel`、`split`	分母来源与协变量白名单；`split` 保证训练与评估隔离
曝光	`event_type`、`event_day`、`ingested_day`	解释“发了但没触达”，不进入主分析分母
订单	`order_number`、`paid_day`、`refund_day`、`refunded`、各账务组件（整数分）	结果变量与利润核算的唯一事实来源
退款明细	退款金额、退款时间、手续费、回收额	退款率护栏与净额冲减
成本	券面额、商品成本、履约成本	支出与利润两条口径的分项

清洗层不删除信息，只做三件事：重复事件按最早入库时间去重、异常金额按配置倍率保留原值、晚到记录按入库日标记而不改事件日。清洗前后的差量单独保存，使数据工程损失与估计误差可以分开计量。

A.11.2 可以进入模型的特征与禁止特征

协变量只允许分配时可见的六个字段：新客标记、历史 GMV、购物车金额、浏览次数、渠道、缺失指示。禁止进入模型的特征有四类：隐藏变量 U、真实倾向得分、真实 CATE，以及四个潜在结果。

禁止项不是建议，而是数据结构上的约束。训练矩阵由白名单装配，白名单之外的列无法进入；装配阶段遇到禁止列名直接中止，而不是静默丢弃。静默丢弃比报错更危险——它会让“用了真值”与“没用真值”在产物上完全一样。白名单本身的含义也要说清：它限制的是“分配时可见”，不是“与结果相关”。一个特征相关性强但分配后才产生，仍然不能用，因为它在决策时刻还不存在。

缺失值按可见性处理。购物车金额在 MAR 机制下缺失，模型用缺失指示加空值分支处理，不做均值填补。均值填补会抹掉“缺失本身”这一信息，而缺失模式恰恰与渠道相关；填补等于把一个有信息的变量变成一个无信息的变量，同时让模型误以为自己观测到了完整数据。

这里还要交代一件与真值有关的事。L3 的真值同时保留 $\tau_{\Pi}(X)$ 与含隐藏变量的 $\tau_{\Pi}(X,U)$，后者只在审计时使用。仅依赖 X 的模型，其误差必须对积分掉 U 的真值计算；若拿 $\tau_{\Pi}(X,U)$ 当靶子，任何只看 X 的模型都会被判为“不准”，而这个“不准”来自信息集不同，不来自方法本身。