预算约束下电商营销策略的因果评估与增量利润优化

——基于已知数据生成过程的模拟验证研究

Lrvin

2026 年 10 月 23 日

数据来源：合成数据 / 已知 DGP（非真实企业数据）

摘　要

电商营销决策长期以转化率为目标，而该指标无法区分真实增量、利润侵蚀与需求提前，也支撑不了“是否发券、发给谁、发多大面额”的组合决策。本文构建已知微观生成机制的分层模拟器（L0–L3），以**每位合格用户的净增量贡献利润**为唯一主指标，在预算与风险约束下评估营销策略的因果效应与策略价值。数据以 SQLite 五张关系表与 6 个视图承载，三条口径红线被固化为 DDL 约束与视图 JOIN 结构；随机实验主线完成样本量双指标设计、AA 校验、ITT 估计、护栏非劣效与 Holm 校正；观察性主线比较朴素差分、PSM、IPW 与双稳健估计随混淆强度的失效轨迹；决策主线把异质性效应嵌入预算约束下的 0-1 背包。在 20 万用户、重复 200 次的实测中：ITT 偏差 +0.002 元/人，95% 覆盖率 0.945 ∼ 0.955；定向发券人均净增量利润 0.330 元，为随机发券 0.129 元的 2.56 倍，每元预算回报由 0.77 元升至 1.97 元，达解析最优上界的 84.9%。方法学层面得到三条边界性结论：样本量的约束指标可以不是主指标（利润高度零膨胀使转化率成为约束者）；护栏检验功效仅 0.20，“非劣效通过”不构成安全证据；即便把可观测特征的标准化均值差全部压到 0.004 以下，$\lambda = 0.25$ 的轻度不可观测混淆仍使覆盖率降至 0.75 ∼ 0.85——“平衡性诊断全绿”恰是最危险的信号。

关键词：因果推断；增量利润；异质性处理效应；预算约束优化；观察性因果；模拟验证

1 问题背景与目标

某电商平台" 加购未支付" 用户的首单转化率约 10%，运营侧持有固定预算，需决定**是否发券、发给谁、发多大面额**。转化率与 GMV 无法区分三类机制：**真实增量**（转化与利润同升）、**利润侵蚀**（本会购买者多领券，转化升而利润降）、**需求提前**（窗内升、长期零）。利润侵蚀的个体效应为负而转化率毫无反映，故以转化率为核心的目标必然高估营销价值；本文因此以净增量贡献利润为唯一主指标。评价透镜是" 深度" 的四维度与三信号（表 1），三问为：估计是否无偏且区间校准、观察性估计在何种混淆下失效、定向策略多创造多少价值。

表 1　"深度" 的四个维度、三个信号与本文的响应

条目	判据	本文的响应
维度 • 业务背景	有明确的问题与约束	加购未支付用户；$B = 10{,}042$ 元、护栏 0.5pp、7/30 天双窗口、面额 5～20 元
维度 • 分析链路	洞察 → 策略 → 评估 → 迭代	口径 →DGP→ 实验 → 异质性 → 观察性 → 优化 → 四指标 → 决策（图 1）
维度 • 可量化价值	结论可翻译为业务语言	每元回报 1.97 元、达真值最优 84.9%、覆盖 15,896 人
维度 • 思维深度	说清为什么选、trade-off、边界	三学习器的代价（§6）、贪心与背包的边界（§8）、观察性阈值（§7）
信号 • 增量利润	目标不是" 提升转化率"	$\tau_{\Pi}(X) = \mathbb{E}[\Pi(1) - \Pi(0) \mid X]$；分解出 GMV 中被券吃掉的部分（图 4b）
信号 • 真值对照	不只报一个提升百分比	已知 DGP 解析真值；六个 ITT 区间与逐用户 CATE 对真值评估（表 4、图 5）
信号 • 独立测试集	训练与评估分离、四指标并列	按用户切分 10/4/6 万；RMSE、排序、策略价值、regret 并列（表 5）

2 数据层与核算口径

数据以五张关系表组织：`users` 20 万行、`user_events` 120.1 万行、`coupon_assignment` 20 万行（分析单位）、`orders` 25,215 行（含退款单）、`user_outcomes` 40 万行。**数据层是权威口径**：SQLite 承载五张表，口径写进 SQL 而非 pandas——三条红线固化为 DDL 的 `CHECK` 与视图的 `JOIN`，违反即失败；视图 6 个、命名查询 19 条（表 2），20 项单元测试验证两条独立实现给出同一个 ITT（利润 $\mathbf{+0.6782}$、转化 $\mathbf{+0.0501}$，逐用户最大差 0.0146 元）。

表 2　SQL 数据层：6 个视图、19 条命名查询的职责与三条红线的固化位置

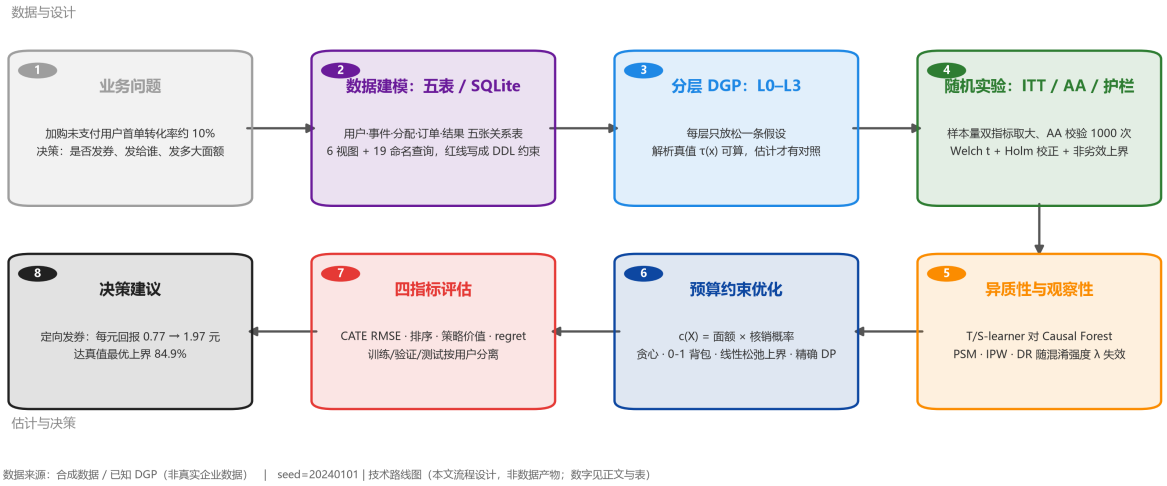
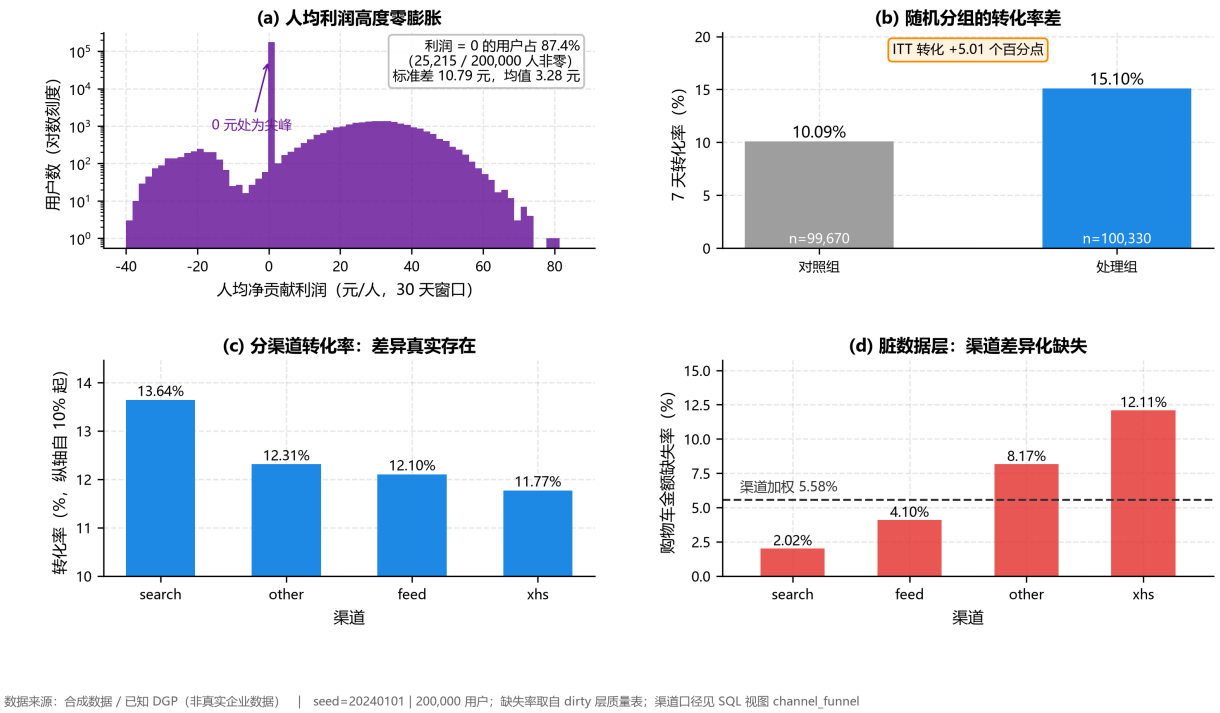


图 1 技术路线：从业务问题到决策建议的八个环节

对象	职责	红线
`v_order_profit`	逐单五项成本分列：收入冲减、退款手续费 1%、商品成本（按 85% 可回收率冲减）、履约成本（刚性）、券成本（仅核销未退券时计入）	—
`v_order_net`	逐单净贡献利润；每项只减一次，券成本不重复扣减	R3
`v_user_profit`	用户级利润；以分配表为驱动表 LEFT JOIN，未下单记 0 而非丢行	R1
`v_order_window`	以各自分配时点计算 `elapsed_days`，是双窗口的时间基础	R2
`v_outcome_convert`	7 天转化窗口；利润列强制为 NULL（尚未成熟）	R2
`v_outcome_profit`	30 天利润成熟窗口；覆盖支付、退款与成本结算	R2
19 条命名查询	口径派生 5（去重、浏览深度、逐单利润、用户级利润、双窗口合并）、业务看板 5（分组 ITT、ITT 差值、渠道漏斗、新老客、日汇总）、质量闸门 9（重复上报、孤儿订单、重复分配、窗口完整性、转化窗口利润为空、退款单保留、对照组持券、事件越界、分流比例）	R1–R3

三条红线是否证式的：**R1**（退款单不得剔除、分母为全部随机分配用户）若违反等于剔除处理后的变量、引入选择偏差并高估收益；**R2**（两窗口分开且等长）若违反会把未成熟利润当噪声；**R3**（券成本只扣一次）若违反会在利润与预算里各扣一次、低估价值。单用户净贡献利润 $\Pi_i^{\text{net}} = R_i - G_i - F_i - C_i - H_i$（收入、商品成本、履约、券成本、退款手续费）；退款单四项分别处理——收入冲减为 0 并加收 1% 通道费，商品成本按 85% 可回收率冲减，履约成本刚性不回收，券默认不退则成本保留，1,959 张退款单仍在样本内（按”成功支付订单”建样本等于隐藏这块成本）。质量检查 20 项在干净数据 **20/20 通过**、注入四类缺陷后 19/20（唯一失败项正是故意注入的重复上报 36,034 行）；脏数据层购物车缺失按渠道差异化（2%～12%，加权 **5.58%**），但若缺失只依赖可观测渠道则属 MAR 而非 MNAR，渠道内填补可消除偏倚——不把 MAR 说成 MNAR 是本文诚实性的



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | 200,000 用户；缺失率取自 dirty 层质量表；渠道口径见 SQL 视图 channel_funnel

图 2 数据层证据：利润零膨胀、分组与分渠道转化率、脏数据层的渠道差异化缺失

一部分。

3 分层数据生成过程：为什么真值可算

反事实不可观测，偏差无法直接度量；模拟验证**先设定微观生成机制**，使潜在结果与个体效应可解析计算，分析者只用可观测数据估计再与真值对照。三条纪律：真值只来自解析计算、策略学习与评估用不相交用户、结论写成条件式。分层生成器每一步只放松一条假设（表 3），参数给**业务可解释的目标量**（转化率 10%、ATE 5 个百分点），截距由一维求根反解。

表 3 分层数据生成过程：每层只增加一类麻烦

层级	增加了什么麻烦	违反的假设	真值如何计算	本文用它检验什么
L0	无，理想世界	无	常数	校准评估流程本身
L1	个体效应异质：新客更强、老客更弱	无	$\tau(x)$ 解析已知	三种 CATE 学习器的差距
L2	有限样本、30/70 不等分流、效应随时间衰减	无（设计约束）	各期效应加权平均	功效损失与区间宽度
L3	运营按可观测与不可观测因素挑人	**可忽略性**	未观测 U 已知，可积分	观察性方法的失效阈值

潜在结果采用**共单调耦合**：同一条 U_i 驱动两个潜在转化结果，保证 $Y_i(1) \geq Y_i(0)$，

订单经济特征共享抽样，使个体效应只含” 转化增量” 与” 券成本”（独立抽样会让个体效应被两倍噪声淹没）。真值为 $\tau_{\Pi}(x) = p_1(x)A_1 - p_0(x)A_0$，其中 A_t 为处理状态 t 下已转化订单的期望净贡献利润。设计意图须真实存在：新客组人均净利润的处理 − 对照差为 1.42 元、老客组仅 0.36 元，转化率差 7.34 与 4.01 个百分点——这就是” 定向发券” 的依据。

4 实验设计与识别有效性

估计目标是**意向处理效应（ITT）**：按随机分组建样本，未领券、未核销者仍留在实验组（不报告” 领券用户的效果”，那会把随机实验偷换为观察性比较）。主估计量为两组人均净贡献利润之差，因两组方差不同而用 Welch t 检验、二值指标用两比例 z 检验：

$$\widehat{\tau}_{\Pi} = \frac{1}{n_1}\sum_{i:T_i=1}\Pi_i^{\text{net}} - \frac{1}{n_0}\sum_{i:T_i=0}\Pi_i^{\text{net}}.$$

样本量按双指标分别计算再取较大值：

$$n_{\text{conv}} = \frac{(z_{1-\alpha/2}+z_{1-\beta})^2\,[p_1(1-p_1)+p_0(1-p_0)]}{\Delta_Y^2}, \qquad n_{\text{profit}} = \frac{(z_{1-\alpha/2}+z_{1-\beta})^2\cdot 2\sigma_{\Pi}^2}{\Delta_{\Pi}^2}.$$

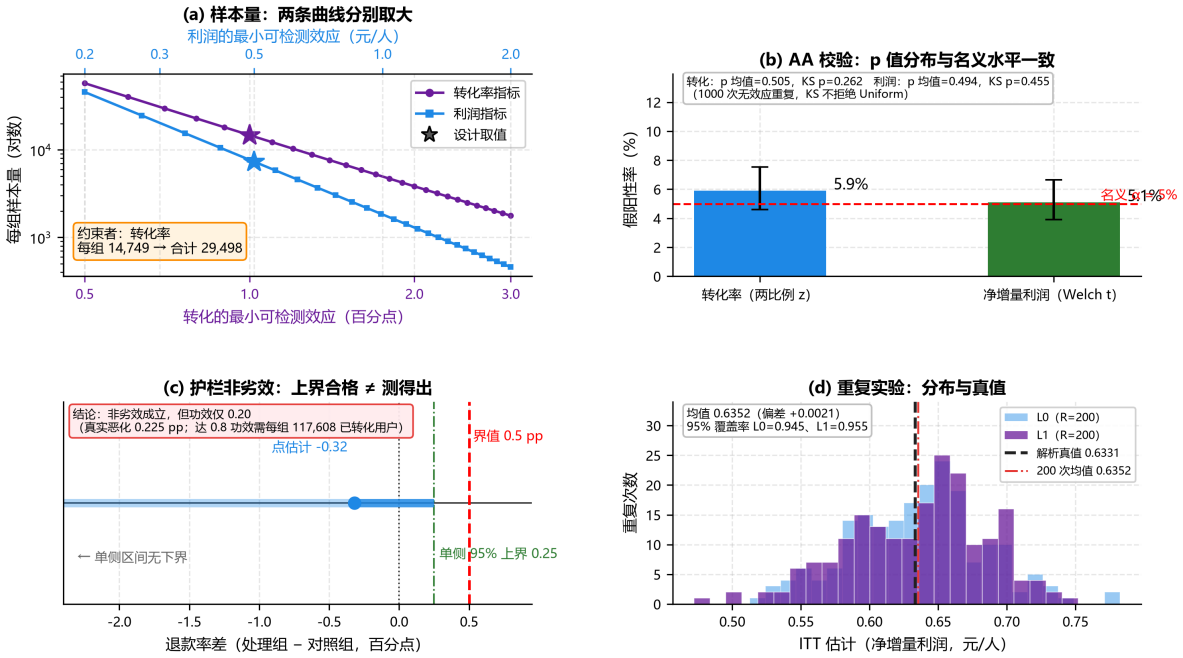
取 $p_0 = 0.10$、$\Delta_Y = 1$ 个百分点、$\sigma_{\Pi} = 10.79$ 元、$\Delta_{\Pi} = 0.5$ 元、$\alpha = 0.05$、功效 0.80，得转化率每组 **14,749** 人、利润每组 **7,324** 人，取大者合计 29,498。**约束者是转化率而非主指标**——利润 87.4% 为零、标准差仅 10.79 元，检出 0.5 元/人反比检出 1 个百分点转化更省样本。AA 校验看 1000 次无效应重复的 p 值分布：假阳性率 0.059 与 0.051（区间均含 0.05）、KS 检验 p 值 0.262 与 0.455，不拒绝均匀。护栏为退款率、界值 0.5 个百分点，“不显著” 不等于” 安全”，故用单侧置信上界判定：

$$\text{非劣效成立} \iff \hat{d} + z_{1-\alpha}\,\widehat{\text{se}}(\hat{d}) < \delta.$$

实测 $\hat{d} = -0.32$ 个百分点、标准误 0.346，上界 **0.248** 个百分点低于界值，非劣效成立——但功效仅 **0.198**：DGP 设定的真实恶化是 +0.225 个百分点（观测值符号相反），要达 0.80 功效每组需 **117,608** 名已转化用户，而当前仅 15,154 与 10,061。**不显著也可能源于根本测不出来：**报告” 护栏通过” 而不报功效，等于把功效不足的检验当作安全证明。两个预注册主指标经 Holm 校正后仍被拒绝（利润 6.18×10^{-45}、转化校正后 2.24×10^{-249}）。

5 ITT 估计与利润分解

三个层级、两个指标共六个 ITT 估计，**六个 95% 置信区间全部覆盖解析真值**（表 4）；L0 是流程校准基准，L2 区间更宽（利润区间 0.388 元对 L1 的 0.189 元）是 30/70



数据来源：合成数据 / 已知 DGP（非真实企业数据）　|　seed=20240101 | R=200（ITT）/1000（AA）；护栏功效由已转化用户数解析计算；样本量为每组、1:1

图 3　实验设计：样本量双指标、AA 校验、护栏非劣效上界与重复 200 次的 ITT 分布

不等分流牺牲功效的代价。重复 200 次的利润均值 0.6352、偏差 **+0.0021** 元/人（相对真值 0.3%），覆盖率 **0.945** 与 **0.955**（转化 0.945 与 0.950）——覆盖率同时检验点估计与标准误，比" 偏差小" 更有说服力。

表 4　样本量设计与六个 ITT 估计对真值的覆盖（n=200,000）

环节	指标	每组样本量 / 点估计	95% 置信区间	真值	结论
样本量	转化率	14,749	—	0.10	约束者
样本量	净增量利润	7,324	—	0.6331	非约束者
ITT • L0	净增量利润	0.5903	[0.4960, 0.6847]	0.6331	覆盖
ITT • L0	转化率	0.0495	[0.0466, 0.0524]	0.0500	覆盖
ITT • L1	净增量利润	0.6782	[0.5837, 0.7727]	0.6331	覆盖
ITT • L1	转化率	0.0501	[0.0472, 0.0530]	0.0500	覆盖
ITT • L2	净增量利润	0.7963	[0.6021, 0.9905]	0.8592	覆盖
ITT • L2	转化率	0.0565	[0.0504, 0.0625]	0.0595	覆盖

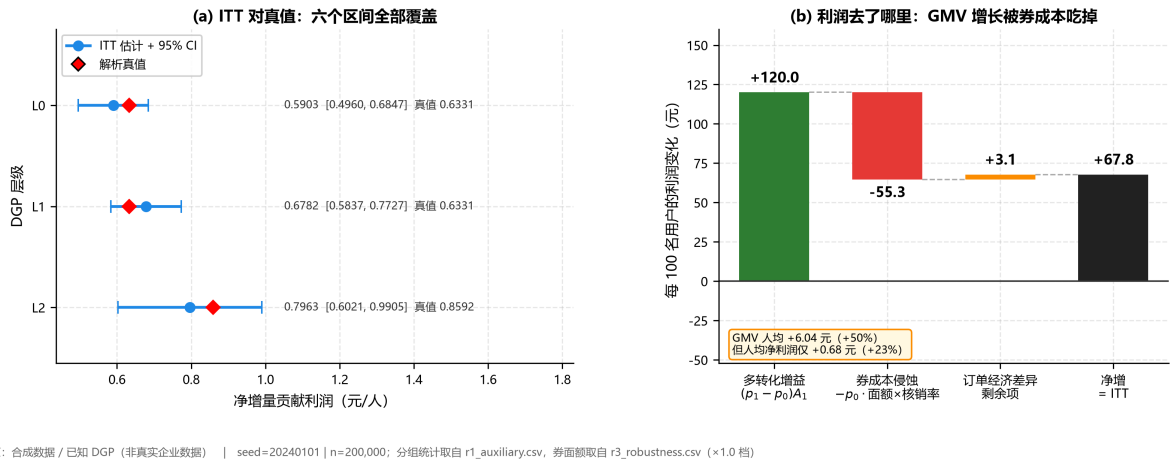


图 4 ITT 对真值的覆盖与利润侵蚀分解

人均 GMV 由 12.07 元升至 18.11 元（**+50%**），人均净利润却只由 2.94 元升至 3.62 元（**+23%**）。每 100 人可分解为：多转化 5.01 人 ×23.96 元 = **+120.0 元**，原购买者 54.8% 用券形成 **−55.3 元**券成本，订单经济差异 **+3.1 元**，合计 **+67.8 元**，与 ITT 一致——**这就是以利润而非 GMV 为主指标的理由**：按 GMV 决策会把价值高估一倍以上。核销率须并列两个口径：占已发券 8.28%（预算效率）与占已下单 54.82%（侵蚀程度），只报后者会误导。

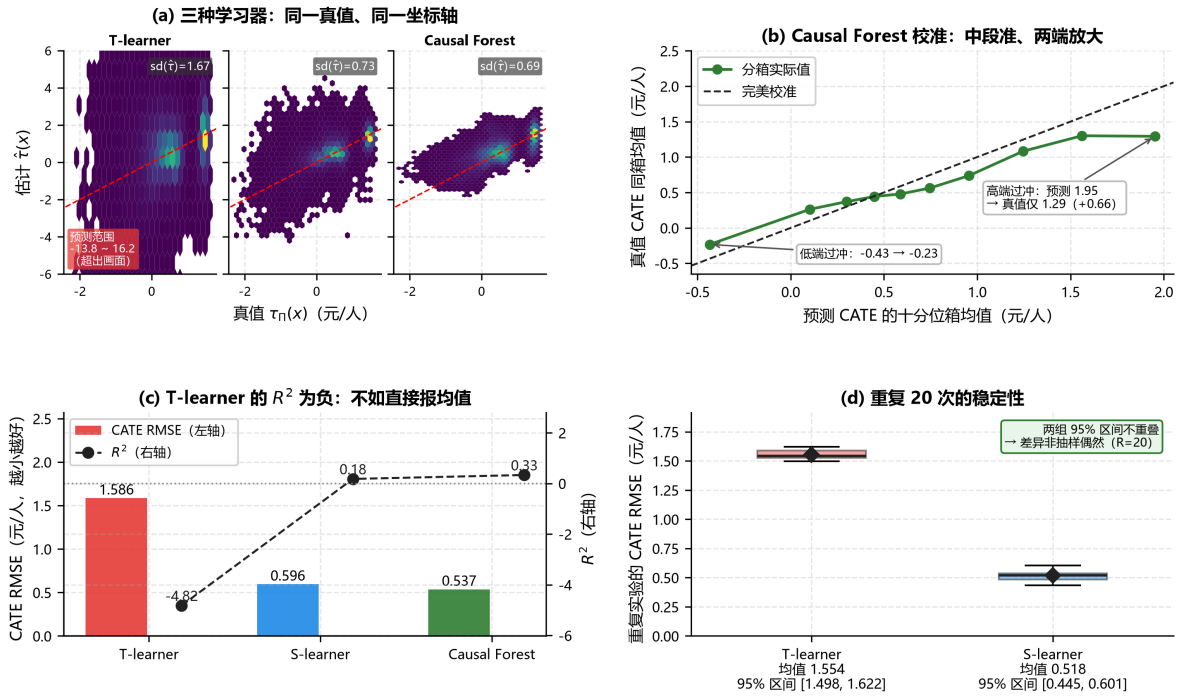
6 异质性处理效应与四指标的不可替代性

在 L1（可忽略性成立，差异纯粹来自方法）上按用户切分 10 万/4 万/6 万（表 5 与图 5）。

表 5 三种异质性效应学习器的测试集表现（**L1，测试集 6 万人**）

学习器	CATE RMSE	R^2	Spearman	Top-20% 重合度	策略价值（元/人）	预测标准差
T-learner	1.586	**−4.82**	0.332	0.353	3.5803	1.666
S-learner	0.596	0.178	0.636	0.578	3.6427	0.733
Causal Forest	**0.537**	**0.333**	**0.653**	**0.624**	**3.6563**	0.688

真值 CATE 标准差为 0.657，故 $R^2 = 1 - (\text{RMSE}/\sigma_\tau)^2$。T-learner 的 $R^2 = -4.82$ 意味着**把全部用户都预测为平均效应 0.63，精度也优于它**：它把样本一分为二、每叶节点仅数十个样本，而单用户利润标准差为 10.79 元，两个独立估计相减使误差以平方量级叠加，预测标准差 1.666 是真值的 2.5 倍——把噪声当成了异质性。Causal Forest 校准中段几乎完美（0.449 对 0.443）、两端过冲（1.953 对 1.293），故应做收缩校准或按分位分档；重复 20 次 RMSE 为 T-learner 1.554 [1.498, 1.622] 对 S-learner 0.518 [0.445, 0.601]，区间不重叠。



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | L1、测试集 60,000 人、按用户切分；真值为解析 CATE，非观测利润差

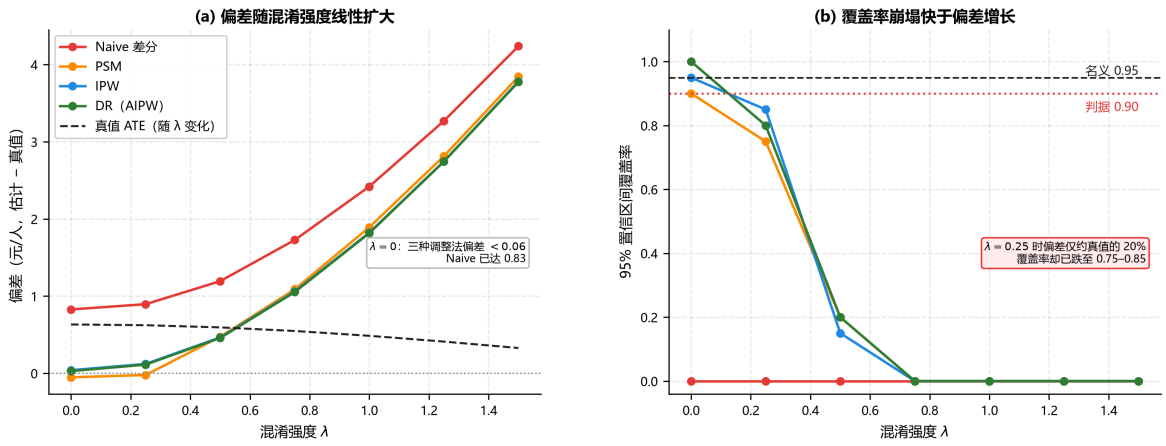
图 5 三种异质性学习器：同一真值下的还原能力、校准、精度与稳定性

四个指标不可互相替代。对真值施加常数平移 $\hat{\tau} = \tau + 5$ 使 RMSE=5，但排序指标全部为 1；T-learner 的 RMSE 是 Causal Forest 的 2.96 倍，策略价值却只差 2.1%（3.5803 对 3.6563 元/人）——策略只要求 τ 的符号大致正确。反向含义：Causal Forest 选中比例高于真值最优，属**过度投放**，策略价值最高不等于预算效率最高，这正是引入预算约束的理由。

7 观察性识别的失效边界

L3 让处理分配与基线转化率同时含未观测项（e 与 p_0 各加 λU），网格 7 点、每点重复 20 次、样本 2 万，估计器只用可观测 X、绝不接触 U。$\lambda = 0$ 时可忽略性成立但仍有**可观测**选择偏差，朴素差分依然有偏——这使”调整是否有效”与”混淆是否致命”分开（表 6 与图 6）。三条读法：$\lambda = 0$ 时三种调整法偏差 $|\cdot| \le 0.06$ 而 naive 为 +0.828（实现正确）；偏差随 λ 近似线性增长至 3.78～3.84 元；**覆盖率崩塌快于偏差**——$\lambda = 0.25$ 时 IPW/DR 偏差仅 0.11～0.12 元（真值的 1/5）、PSM 仅 −0.02 元，覆盖率已跌至 0.75～0.85。**偏差只要不为零，覆盖率即发生不可逆损坏。**

表 6 四种观察性方法的偏差与 95% 区间覆盖率随混淆强度的变化（每格 20 次重复）



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | L3、每组重复 20 次、n=20,000；λ 网格 7 点；估计器仅用可观测 X

图 6 观察性识别的失效边界：偏差与覆盖率随混淆强度变化

λ	Naive	PSM	IPW	DR	Naive 覆盖	PSM	IPW	DR
0.00	+0.828	−0.052	+0.041	+0.029	0.00	0.90	0.95	1.00
0.25	+0.896	−0.022	+0.122	+0.113	0.00	**0.75**	**0.85**	**0.80**
0.50	+1.194	+0.474	+0.465	+0.458	0.00	0.20	0.15	0.20
0.75	+1.728	+1.089	+1.061	+1.054	0.00	0.00	0.00	0.00
1.00	+2.421	+1.893	+1.823	+1.817	0.00	0.00	0.00	0.00
1.25	+3.270	+2.814	+2.747	+2.744	0.00	0.00	0.00	0.00
1.50	+4.239	+3.843	+3.782	+3.776	0.00	0.00	0.00	0.00

平衡了可观测特征，偏差依然存在。$\lambda = 0.5$ 下 IPW 加权后，7 个特征的标准化均值差由 0.05～0.35 全部压到 **0.0038 以下**（历史 GMV 0.354→0.004、购物车金额 0.353→0.003），而同一份数据上 IPW 的偏差为 **+0.465** 元/人（真值 0.595）——倾向得分只能平衡 X 中存在的变量，U 不在 X 中，它们无能为力。**平衡性诊断全绿恰是最需要警惕的时刻。**双稳健也未提供额外保护：$\lambda \geq 0.5$ 后 DR 与 IPW 差不足 0.02 元（U 同时进入两个模型）；$\lambda = 0$ 时 PSM 覆盖 0.90、DR 覆盖 1.00，说明过度覆盖与覆盖不足同为缺陷。条件式结论：$\lambda = 0$ 可用、$\lambda = 0.25$ 即不可信、$\lambda \geq 0.5$ 必须回到实验设计——**观察性方法并非”较弱的实验”，它在轻度混淆下已失效。**

8 预算约束下的策略价值

目标是 $\max_\pi \sum_i \pi_i \tau_i$，约束 $\sum_i \pi_i c_i \leq B$、$\pi_i \in \{0,1\}$，其中 $c(X) =$ 面额 $\times P(\text{核销} \mid \text{发券}, X)$ 而非直接用面额（否则高估预算占用一个数量级）。核销模型只在训练集处理组上拟合，测试集 6 万人、期望成本 0.837 元/人、$B = 10{,}042$ 元；按 R3 策略价值不再扣券成本。

表 7 六种策略在同一测试集（6 万人）、同一预算下的表现

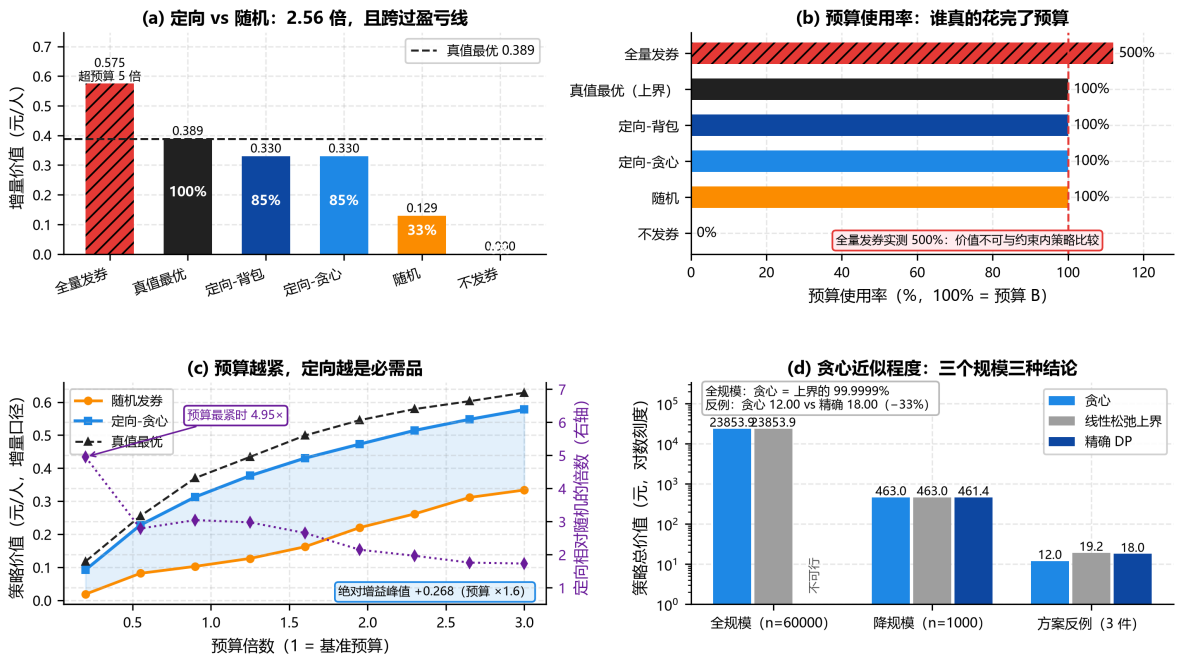
策略	选中人数	实际成本（元）	增量价值（元/人）	人均选中效应	每元回报	达真值最优
不发券	0	0	0.0000	—	—	—
全量发券	60,000	50,210	0.5747	0.630	0.69	超预算 5 倍
随机（预算 B）	12,001	10,042	0.1290	0.628	0.77	33.1%
定向-贪心	15,896	10,042	**0.3302**	**1.301**	**1.97**	**84.9%**
定向-背包	15,896	10,042	0.3302	1.301	1.97	84.9%
真值最优（上界）	16,955	10,042	**0.3892**	1.383	2.33	100%

其一，**定向相对随机 2.56 倍且跨越盈亏平衡线**：随机每投入 1 元只回收 0.77 元、整体为负，定向回收 **1.97** 元；差距不来自规模（12,001 对 15,896 人）而来自人均选中效应（0.628 对 1.301）。其二，**全量发券的" 价值最高" 是陷阱**：成本 50,210 元是预算 5 倍，其" 达上界 147.7%"无意义故置缺失。其三，**背包与贪心几乎相同**，这不是程序缺陷而是规模使然。

贪心近似分三层（图 7d）：全规模下达线性松弛上界 **99.9999%**（"大量小件" 背包，交换论证保证差距不超过单件最大价值）；降规模精确 DP 得 461.36 元反比贪心的 462.97 元低 0.35%（成本离散化误差超过真实整数间隙）；反例（预算 10，6/12、5/9、5/9）中贪心得 12、最优 18，**损失 33%**。故**背包的价值在于以 LP 上界证明贪心已足够、并处理少量大额件，而非" 多赚多少"**。预算敏感性给出相反两结论：绝对增益在 $\times 1.6$ 达峰（+0.268 元/人），相对优势在最紧时最高（$\times 0.2$ 时 4.95 倍）、随预算放宽降至 1.73 倍——**预算越紧，定向越是必需品**。四参数 $\pm 20\%$ 的 12 个单元全部" 定向优于随机" 且每元回报 >1（86.8%～92.2%）；最敏感是核销率（2.88→1.53），故**降低核销率等价于增加预算**。

9 双重差分在本项目中的适用性判定

本项目不做 DID。三条件逐条：其一需要未受干预的对照组——不满足，本文全量随机分配、两组都在券干预下，L0–L3 均无" 未受干预的第三组"；其二平行趋势必须可检验——不满足，主体设计只有一期结果（7 天与 30 天窗口是同一批用户的等长窗口，不是两期面板）；其三干预时点清晰——满足。前两条不满足，任何" 伪 DID" 都会把组间水平差当作处理效应。最小可行设计：**两期面板**（干预前/后各 30 天）+ **城市级随机化**（留出未受干预的对照城市）+ **概率尺度**检验平行趋势（若在 logit 尺度定义却在概率尺度解释，两组即使 logit 平行、概率差也会随水平发散）。配置保留 `dgp.l4.enabled: false`，三条件补齐前不报任何 DID 数字。



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | 独立测试集 60,000 人；预算 B=10,042 元；六策略同预算同人群；DP 为降规模实例

图 7 预算约束下的策略价值：六策略对比、预算使用率、预算敏感性与贪心近似程度

10 讨论与局限

三条方法学发现。主指标与样本量约束者可以分离（零膨胀使转化率成为约束者）；偏差非零导致覆盖率不可逆损坏（按零偏差校准，1/5 真值的偏差已使覆盖率跌至 0.75～0.85）；双稳健性在单一遗漏变量同时影响处理与结果的结构下不提供额外保护——这不与文献冲突，因为双稳健的前提是至少一个模型正确，而此处两个模型同时错误。

四类局限。模拟范式不能替代真实数据经验；统计功效上护栏仅 0.20、CATE 重复 20 次、CF 仅 2 次、λ 扫描样本 2 万使覆盖率含约 ±0.05 误差；实现上”背包”实为贪心加局部改进、DR 未交叉拟合、PSM 标准误忽略对照复用、缺失为 MAR；设定上未做”面额 × 人群”联合优化（面额固定 10 元）、未建模溢出与长期效应、DID 前两条不满足（§9）。

失效条件。网络溢出破坏 SUTVA 使定向收益被夸大；长期效应使 30 天窗口内的增量只是时间平移；退款在 30 天后集中爆发使利润成熟窗口不足；核销率被低估 20% 使实际超支约 25%；面额-效应曲线形状不同时”每元回报 1.97”的绝对值失效（排序结论仍成立）；分流非随机则退化为观察性场景，而它在 $\lambda = 0.25$ 即失效。

11 结论与展望

本文把”该不该发券、发给谁”从转化率叙事改写为可检验的增量利润问题：随机实验识别无偏且区间校准（0.945～0.955），观察性调整在 $\lambda = 0.25$ 即失效，预算约束下的定向发券以每元 1.97 元的回报达到真值最优的 84.9%。三条硬边界（护栏功效 0.20、轻度混淆失效、贪心 33% 反例）说明：**方法的价值不在能算出数，而在能说清这个数在什么条件下不成立**。后续方向：公开数据外部验证、面额 × 人群二维背包、护栏指标体系扩展、两期面板与城市级随机化。

参考文献

[1] Imbens G W, Rubin D B. Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction[M]. Cambridge University Press, 2015.

[2] Rosenbaum P R, Rubin D B. The central role of the propensity score in observational studies for causal effects[J]. Biometrika, 1983, 70(1): 41-55.

[3] Robins J M, Rotnitzky A, Zhao L P. Estimation of regression coefficients when some regressors are not always observed[J]. Journal of the American Statistical Association, 1994, 89(427): 846-866.

[4] Bang H, Robins J M. Doubly robust estimation in missing data and causal inference models[J]. Biometrics, 2005, 61(4): 962-973.

[5] Künzel S R, Sekhon J S, Bickel P J, Yu B. Metalearners for estimating heterogeneous treatment effects using machine learning[J]. Proceedings of the National Academy of Sciences, 2019, 116(10): 4156-4165.

[6] Wager S, Athey S. Estimation and inference of heterogeneous treatment effects using random forests[J]. Journal of the American Statistical Association, 2018, 113(523): 1228-1242.

[7] Athey S, Wager S. Policy learning with observational data[J]. Econometrica, 2021, 89(1): 133-161.

[8] Chernozhukov V, Chetverikov D, Demirer M, et al. Double/debiased machine learning for treatment and structural parameters[J]. The Econometrics Journal, 2018, 21(1): C1-C68.

全部结果由 `scripts/run_all.py` 一条命令复现（含 380 项测试）；随机性由 seed/stream/index 三元组派生，五张关系表与主结果逐字节一致。