预算约束下电商营销策略的因果评估与增量利润优化

——基于已知数据生成过程的模拟验证研究

Lrvin

liliw@126.com

2026 年 10 月 23 日

数据来源：合成数据 / 已知 DGP（非真实企业数据）

摘　要

电商营销决策长期以转化率为目标，而该指标无法区分真实增量、利润侵蚀与需求提前，也支撑不了“是否发券、发给谁、发多大面额”的组合决策。本文构建已知微观生成机制的分层模拟器（L0–L3），以每位合格用户的净增量贡献利润为**首要指标**、转化率为**共同主指标**，在预算与风险约束下评估营销策略的因果效应与策略价值。方法上完成三条主线：随机实验（样本量双指标、AA 与 SRM 校验、ITT 估计、护栏非劣效与 Holm 校正）、观察性识别（朴素差分、PSM、IPW、DR 随未观测混淆强度 λ 扫描，每格重复 100 次并给 Clopper–Pearson 区间）、预算约束优化（0-1 背包与线性松弛上界）。20 万用户、重复 200 次实测：ITT 偏差 +0.002 元/人、95% 覆盖率 0.950；定向发券人均增量利润 0.349 元（95% CI 0.318–0.384），为随机发券（200 个种子）0.122 元的 2.9 倍，每元回报 2.08 元（95% CI 1.91–2.29），占真值贪心解 86%（95% CI 82%–91%）。三条边界性结论：样本量约束者可以不是主指标（翻转临界 0.36 元/人）；护栏检验功效仅 0.198，“非劣效通过”不等于安全；轻度混淆（$\lambda = 0.25$）下 IPW/DR 覆盖率已跌至 0.82/0.79，而可观测特征的标准化均值差全部低于 0.004——“平衡性诊断全绿”恰是最危险的信号。另一处边界在贪心：全规模下它与松弛上界几乎重合（99.9999%），但 3 件大额件的反例中损失 33%。全部结果基于合成数据与已知 DGP，结论只在给定生成机制内成立。

关键词：因果推断；增量利润；异质性处理效应；预算约束优化；模拟验证

---

1 引言

1.1 研究背景

某电商平台" 加购未支付" 用户的首单转化率约 10%，运营侧持有固定预算，需决定**是否发券、发给谁、发多大面额**。转化率与 GMV 无法区分三类机制：**真实增量**（转化与利润同升）、**利润侵蚀**（本会购买者多领券，转化升而利润降）、**需求提前**（窗内升、长期零）。利润侵蚀的个体效应为负而转化率毫无反映，故以转化率为核心的目标必然高估营销价值 [10]；行业 A/B 测试实践也把" 把点击/转化当唯一目标" 列为实验平台最常见的失效模式之一 [10]。

1.2 问题提出

由此引出三个具体问题。其一，**若把目标改为净增量贡献利润，"该不该发券" 还能不能被无偏地回答**——估计量是否无偏、区间是否校准。其二，**当随机化不可行、只能观察数据时，常见调整方法在多大混淆强度下开始失效**——失效是渐变还是断崖，能否给出可操作的阈值。其三，**定向投放相对" 随机发送" 到底多创造多少价值、离理论最优还差多远**——这个差距必须能被量化，否则" 精准营销" 只是一句口号。

1.3 研究目的与意义

方法论上，本文用**已知真值**的模拟器把" 偏差" 从不可观测量变成可核对的量：真值只来自 DGP 解析式，策略学习与评估用不相交用户，结论一律写成条件式 [12]。实践上，它回答一个可执行的问题：给定固定预算与风险护栏，定向发券的每元回报是多少、在多大概率区间内成立、在什么条件下失效。表 1 把本文与" 深度" 的四个维度、三个信号逐条对齐。

表 1　"深度" 的四个维度、三个信号与本文的响应

条目	判据	本文的响应
维度 • 业务背景	有明确的问题与约束	加购未支付用户；$B = 10{,}042$ 元、护栏 0.5pp、7/30 天双窗口、面额 5∼20 元
维度 • 分析链路	洞察 → 策略 → 评估 → 迭代	口径 →DGP→ 实验 → 异质性 → 观察性 → 优化 → 四指标 → 决策（图 1）
维度 • 可量化价值	结论可翻译为业务语言	每元回报 2.08 元（95% CI 1.91–2.29）、占真值贪心解 86%（82%–91%）、覆盖 15,985 人
维度 • 思维深度	说清为什么选、trade-off、边界	三学习器的代价、贪心与背包的边界、观察性阈值（§3.5）
信号 • 增量利润	目标不是" 提升转化率"	$\tau_\Pi(X) = \mathbb{E}[\Pi(1) - \Pi(0) \mid X]$；分解出 GMV 中被券吃掉的部分（图 4b）
信号 • 真值对照	不只报一个提升百分比	已知 DGP 解析真值；六个 ITT 区间与逐用户 CATE 对真值评估（表 4、图 5）
信号 • 独立测试集	训练与评估分离、四指标并列	按用户切分 10/4/6 万；RMSE、排序、策略价值、regret 并列（表 5）

1.4 研究问题与假设

- **RQ1**：在同样的用户与预算下，以净增量贡献利润为目标的定向策略，其每元回报能否显著超过 1（即" 发券赚钱"），并显著超过随机发券？
- **RQ2**：观察性调整（PSM/IPW/DR）在什么混淆强度下失去校准能力，其失效能否用区间而非点估计判定？
- **RQ3**：预测精度（RMSE）、排序质量与策略价值三者能否互相替代？
- **H1**：利润是高度零膨胀的重尾变量，其方差不足以让它在样本量上成为约束者，故" 主指标" 与" 样本量约束指标" 会分离。



图 1 技术路线：从业务问题到决策建议的八个环节

- **H2**：可观测特征被完全平衡并不保证无偏；覆盖率会比偏差更早崩塌。
- **H3**：策略只依赖 τ 的符号与排序，因此 RMSE 的差距不会等比例转化为策略价值的差距。

1.5 论文结构安排

§2 给出研究对象、数据来源、研究设计、实验方法、分析工具与研究程序，以保证可重复性；§3 客观呈现数据层、实验设计与三条主线的结果（文字 + 表 + 图）；§4 解释结果、分析原因、说明理论与实践意义并交代局限；§5 总结发现、回答研究问题，并把” 模型遗漏了什么、如何深化、用什么方法” 作为展望；附录给出关键参数、复现方式与数据字典。

2 研究方法

2.1 研究对象

研究对象是某电商平台” 加购未支付” 的 20 万名合格用户。分析单位是**随机分配**本身（每用户一次分配），而不是” 成功支付订单”——未下单用户的净贡献利润记 0 而保留在分母里。核心口径是单用户净贡献利润（式 1）：

$$\Pi_i^{\text{net}} = R_i - G_i - F_i - C_i - H_i \qquad (1)$$

（收入、商品成本、履约、券成本、退款手续费）。退款单四项分别处理——收入冲减为 0 并加收 1% 通道费，商品成本按 85% 可回收率冲减，履约成本刚性不回收，券默认不退则成本保留。

2.2 数据来源

数据为**合成数据**：由已知 DGP 生成的五张关系表（`users` 20 万行、`user_events` 120.1 万行、`coupon_assignment` 20 万行、`orders` 26,471 行、`user_outcomes` 40 万行）落进 SQLite，另加一层脏数据（渠道差异化缺失、刷单、重复上报、上报延迟）。选择合成数据的原因是识别问题：真实业务里个体反事实与 CATE 真值不可观测，偏差无法直接度量；模拟器把真值变成可计算量 [12]；外部效度只能靠

公开营销实验数据（如 Hillstrom 的 MineThatData 数据集 [11]）另行检验，本文不做。全部业务参数见附录 A，数据字典与 SQL 对象清单见附录 C。

三条口径红线里两条落进 DDL——R1 的分母由视图驱动表保证（`v_user_profit` 以 `coupon_assignment` 为左表 LEFT JOIN 订单，未下单用户记 0 而非丢行），R2 由 `user_outcomes` 的 `CHECK` 保证（`convert_7d` 的 `net_profit` 必须为 NULL、`profit_30d` 必须非空）；**R3 由视图表达式保证**（`v_order_net` 中券成本只出现一次）。全部由 **9 条质量闸门 + 20 项 SQL 单测**兜底：闸门与单测跑同一批数据，任何一条被违反即抛错，不打印警告后继续。

多单用例是 R3 的照妖镜。本文让约 5% 的已转化用户产生**第二单**（复购，不带券），使 1,256 个用户的 `orders` 有两行。若 `v_user_profit` 把券成本或利润写成 `MAX(...)` 而不是 `SUM(...)`，这 1,256 户的第二单利润会被静默丢掉：第二单单均净贡献 13.98 元、合计 17,555 元，折算到全体用户约 **0.088 元/人，相当于 ITT（0.67 元/人）的 13%**，且所有闸门都不会报错——因为每用户只有一单时 `MAX` 与 `SUM` 恒等。这正是把复购写进 DGP、并补一条" 多单用户 user 级利润 = 各单之和" 单测的理由。

2.3 研究设计

分层 DGP（表 2）：每一层只放松一条假设，参数给业务可解释的目标量（转化率 10%、ATE 5 个百分点），截距由一维求根反解。潜在结果采用**共单调耦合：**同一条 U_i 驱动两个潜在转化结果，保证 $Y_i(1) \geq Y_i(0)$，订单经济特征共享抽样，使个体效应只含" 转化增量" 与" 券成本"（独立抽样会让个体效应被两倍噪声淹没）[1]。识别的前提是 SUTVA（个体间无干扰、处理版本唯一）[1]，本文 DGP 显式满足它——§5.3 会说明为什么打破它需要换随机化单位而不是换估计量。

表 2　分层数据生成过程：每层只增加一类麻烦

层级	增加了什么麻烦	违反的假设	真值如何计算	本文用它检验什么
L0	无，理想世界	无	常数	校准评估流程本身
L1	个体效应异质：新客更强、老客更弱	无	$\tau(x)$ 解析已知	三种 CATE 学习器的差距
L2	有限样本、30/70 不等分流、效应随时间衰减	无（设计约束）	各期效应加权平均	功效损失与区间宽度
L3	运营按可观测与不可观测因素挑人	**可忽略性**	未观测 U 已知，可积分	观察性方法的失效阈值

真值为 $\tau_{\Pi}(x) = p_1(x)A_1 - p_0(x)A_0$，其中 A_t 为处理状态 t 下**已转化用户的期望净贡献**（首单 + 复购期望），因此复购路径进入真值时仍保持恒等式（式 2）：

$$\tau_{\Pi}(x) = p_1(x)\,A_1 - p_0(x)\,A_0, \qquad A_t = A_t^{\text{first}} + \pi_{\text{rep}} \cdot A_t^{\text{second}}. \tag{2}$$

设计意图须真实存在：新客组人均净利润的处理 − 对照差为 **1.49 元**、老客组仅 **0.40 元**，转化率差 **7.34** 与 **4.01** 个百分点——这就是" 定向发券" 的依据。

2.4 实验方法

（1）双指标样本量与随机化。估计目标是意向处理效应（ITT）：按随机分组建样本，未领券、未核销者仍留在实验组，不报告 "领券用户的效果"，否则会把随机实验偷换为观察性比较 [2]。1:1 随机分流，两窗口等长（转化 7 天、利润 30 天）。样本量按双指标分别计算再取较大值（式 3）：

$$n_{\text{conv}} = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2\,[p_1(1-p_1) + p_0(1-p_0)]}{\Delta_Y^2}, \quad n_{\text{profit}} = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 \cdot 2\sigma_{\Pi}^2}{\Delta_{\Pi}^2}. \tag{3}$$

主估计量为两组人均净贡献利润之差（式 4），因两组方差不同而用 Welch t 检验、二值指标用两比例 z 检验：

$$\widehat{\tau}_{\Pi} = \frac{1}{n_1} \sum_{i:T_i=1} \Pi_i^{\text{net}} - \frac{1}{n_0} \sum_{i:T_i=0} \Pi_i^{\text{net}}. \tag{4}$$

（2）识别有效性的三道检查。AA 校验（1000 次无效应重复看 p 值分布与假阳性率）、SRM 检查（分流比例卡方检验，工程判据 $p < 0.001$）[10]、护栏非劣效（退款率、界值 0.5 个百分点；“不显著” 不等于” 安全”，故用单侧置信上界判定，式 5）：

$$\text{非劣效成立} \iff \hat{d} + z_{1-\alpha}\,\widehat{\mathrm{se}}(\hat{d}) < \delta. \qquad (5)$$

多重比较用 Holm 校正，两个**预设**主指标为利润（primary）与转化率（co-primary）。

（3）异质性效应学习。在 L1 上按用户切分 10 万/4 万/6 万，比较 T-learner、S-learner 与 Causal Forest 三种元学习器 [6][7]，四个指标并列：RMSE / R^2、排序（Spearman、Top-20% 重合）、策略价值（增量口径，式 6）、regret。

$$V_{\text{inc}}(\pi) = \frac{1}{n}\sum_i \pi_i \left(\Pi_i(1) - \Pi_i(0)\right), \qquad V_{\text{inc}}(\pi) = 0 \text{ 当 } \pi \equiv 0. \qquad (6)$$

它与” 绝对口径”$V_{\text{abs}}(\pi) = n^{-1}\sum_i[\pi_i\Pi_i(1) + (1-\pi_i)\Pi_i(0)]$ 只差一个与策略无关的常数 $\mathbb{E}[\Pi(0)]$，该常数会稀释方法间的差距，故全文统一用增量口径。

（4）观察性识别。L3 让处理分配与基线转化率同时含未观测项（e 与 p_0 各加 λU），网格 7 点、每点重复 100 次、样本 2 万，估计器只用可观测 X、绝不接触 U。λ 的字面含义是” 未观测变量每 1 个标准差推动基线 logit 多少”：$\lambda = 0.25$ **相当于漏掉一个系数 0.25 的变量（恰好等于浏览深度 `browse_depth_z` 的系数），$\lambda = 0.5$ 已经强于历史 GMV 的 0.40**。比较 naive 差分、PSM[3]、IPW[4]、DR（AIPW）[5]。

（5）预算约束优化。这属于带资源约束的策略学习（policy learning）问题 [8]，目标是（式 7）

$$\max_{\pi} \sum_i \pi_i \tau_i \quad \text{s.t.} \quad \sum_i \pi_i c_i \le B, \;\; \pi_i \in \{0,1\}, \qquad (7)$$

其中 $c(X) =$ 面额 $\times\, P(\text{核销} \mid \text{发券}, X)$ 而非直接用面额（否则高估预算占用一个数量级）；预算 $B = 10{,}042$ 元 = 覆盖 20% 合格用户的期望券成本（`budget.coverage_target: 0.20`），即 $B = 0.20 \times \sum_i c(X_i)$，而不是拍一个金额。策略规则有两种：“$\hat{\tau} > 0$ 即投放、无预算约束”（表 5）与” 按 $\hat{\tau}/c$ 贪心取到预算用尽”（表 7）。

2.5 分析工具

Python 3.13 + numpy/pandas/scipy（统计与区间）、scikit-learn + LightGBM + econml（三种 CATE 学习器与 Causal Forest）、SQLite（数据层，6 视图 + 19 条命名查询）、matplotlib（出图）、pytest（404 项单测）。所有业务参数集中在 `configs/base.yaml`，代码里不含业务 magic number；随机性统一由 `(master_seed, stream, index)` 三元组派生，禁止裸随机数。

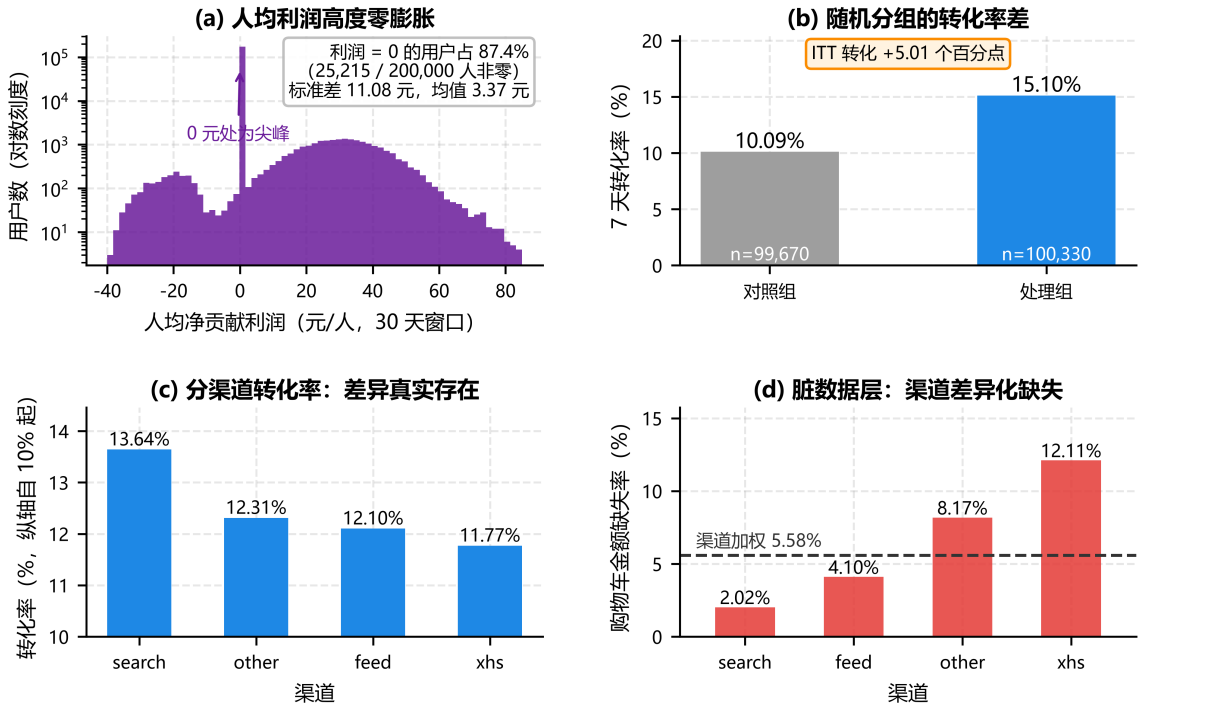
2.6 研究程序

一条命令复现全部产物：`scripts/run_all.py --round all` 依次执行 01 数据构建 → 02 实验主线 → 03 异质性与观察性 → 04 策略优化 → 05 论文组图 → 06 哈希清单；每步失败即中止，不产出” 看似完整但口径已坏” 的报告。产物哈希写入 `outputs/SHA256SUMS.txt`（64 个文件），复现等级与核对方式见附录 B。

3 结果

3.1 数据层与口径校验

质量检查 20 项在干净数据 **20/20 通过**、注入四类缺陷后 19/20（唯一失败项正是故意注入的重复上报 36,034 行）。“快速路径（numpy）” 与” 关系表聚合（pandas）“两条独立实现的最大逐用户利润差 **0.026 元**，在金额按分存储的舍入上限（两单 × 3 个金额字段 × 0.005 元）之内；SQL 口径的 ITT 为利



数据来源：合成数据 / 已知 DGP（非真实企业数据） ｜ seed=20240101 | 200,000 用户；缺失率取自 dirty 层质量表；渠道口径见 SQL 视图 channel_funnel

图 2 数据层证据：利润零膨胀、分组与分渠道转化率、脏数据层的渠道差异化缺失

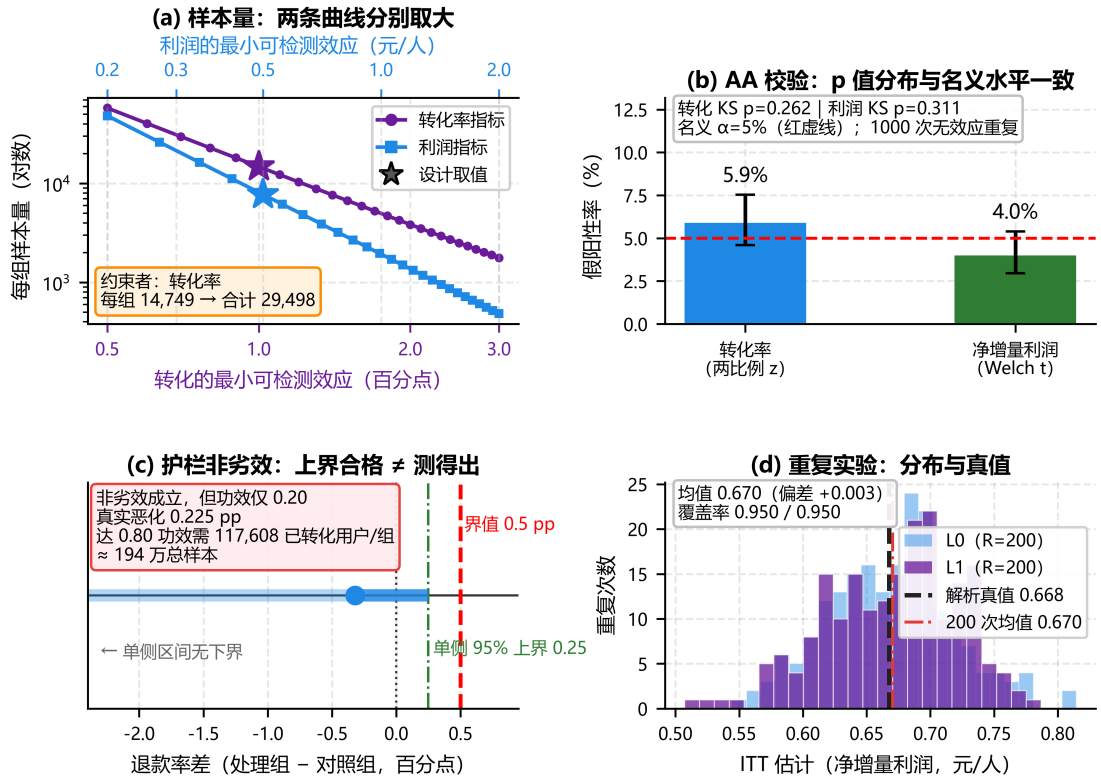
润 **+0.7240** 元/人、转化 **+0.0501**、GMV **+6.2376** 元/人，与 pandas 路径一致。脏数据层购物车缺失按渠道差异化（2.02%～12.11%，加权 **5.58%**）。

3.2 实验设计与识别有效性

样本量：取 $p_0 = 0.10$、$\Delta_Y = 1$ 个百分点、$\sigma_\Pi = 11.08$ 元（加入复购路径后的实测标准差）、$\Delta_\Pi = 0.5$ 元、$\alpha = 0.05$、功效 0.80，得转化率每组 **14,749** 人、利润每组 **7,709** 人，取大者合计 29,498，**约束者是转化率**；两者都与 MDE 平方成反比，令二者相等得约束者翻转的临界值 $\Delta_\Pi^* \approx$ **0.36 元/人**。AA 校验：假阳性率 **5.9%**（95% CI 4.6%–7.5%）与 **4.0%**（3.0%–5.4%）、KS 检验 p 值 0.262 与 0.311。SRM：100,330 / 99,670，$z = 1.48$、$\chi^2 = 2.18$、$p = 0.140$，不拒绝 50/50。护栏：$\hat{d} = -0.32$ 个百分点、标准误 0.35，单侧 95% 上界 **0.248** 个百分点低于界值，非劣效成立；但功效仅 **0.198**（真实恶化 +0.225 个百分点），要达 0.80 功效每组需 **117,608** 名已转化用户，折合总样本约 **194 万**。界值敏感性：同一份差值只在 0.2pp 界值处判” 不成立”，0.3/0.5/1.0pp 三档均判” 成立”。Holm 校正后两个主指标仍被拒绝（利润 2.28×10^{-48}、转化 2.24×10^{-249}）。

3.3 ITT 估计与利润分解

三个层级、两个指标共六个 ITT 估计，**六个 95% 置信区间全部覆盖解析真值**（表 3）。重复 200 次的利润均值 0.6703、偏差 **+0.0027** 元/人（相对真值 0.4%），覆盖率 **0.950**（转化 0.945–0.950）。人均 GMV 由 12.38 元升至 18.62 元（**+50%**），人均净利润由 3.00 元升至 3.73 元（**+24%**）。每 100 人分解（图 4b）：多转化 5.01 人 × 24.69 元 = **+123.7 元**，原购买者 54.8% 用券形成 **−55.3 元**券成本，订单经济差异 **+4.1 元**，合计 **+72.4 元**，与 ITT 一致。核销率两个口径：占已发券 **8.28%**、占已下单 **54.8%**。



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | R=200（ITT）/1000（AA）；护栏功效由已转化用户数解析计算；样本量为每组、1:1

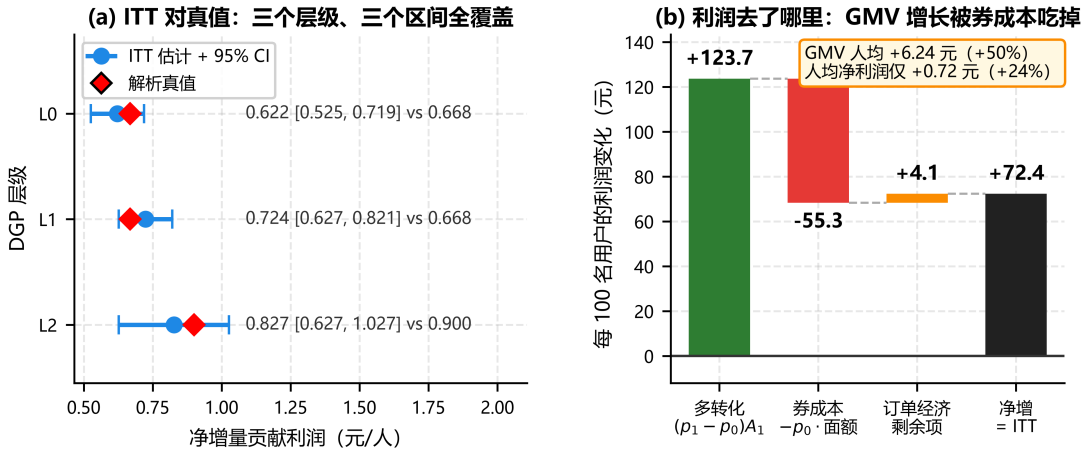
图 3 实验设计：样本量双指标、AA 校验、护栏非劣效上界与重复 200 次的 ITT 分布

表 3 样本量设计与六个 ITT 估计对真值的覆盖（n=200,000；L0/L1/L2 为 DGP 层级）

环节	指标	每组样本量 / 点估计	95% 置信区间	真值	结论
样本量	转化率	14,749	—	0.10	约束者
样本量	净增量利润	7,709	—	0.668	非约束者
L0	净增量利润	0.622	[0.525, 0.719]	0.668	覆盖
L0	转化率	0.0495	[0.0466, 0.0524]	0.0500	覆盖
L1	净增量利润	0.724	[0.627, 0.821]	0.668	覆盖
L1	转化率	0.0501	[0.0472, 0.0530]	0.0500	覆盖
L2	净增量利润	0.827	[0.627, 1.027]	0.900	覆盖
L2	转化率	0.0565	[0.0504, 0.0625]	0.0595	覆盖

3.4 异质性处理效应

三种学习器在测试集上的表现见表 4 与图 5。真值 CATE 标准差 0.669，真值非负比例 **86.0%**。Causal Forest 的校准中段几乎完美、两端过冲（高端 2.06 对真值 1.37）。重复实验：T-learner RMSE 1.600 [1.538, 1.703]（R=20）、S-learner 0.531 [0.464, 0.606]（R=20）、Causal Forest 0.557 / 0.468（**仅 2 次**）。



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | n=200,000；分组统计取自 r1_auxiliary.csv，券面额取自 r3_robustness.csv（×1.0 档）

图 4　ITT 对真值的覆盖与利润侵蚀分解

表 4　三种异质性效应学习器的测试集表现（L1，测试集 6 万人；T = T-learner、S = S-learner、CF = Causal Forest；RMSE / 增量价值 / regret / 偏差单位均为元/人，选中比例 = 非负策略选中用户占比；*CF 只跑 2 次，T/S 各 20 次）

学习器	RMSE	R^2	Spearman	Top-20%	增量价值	regret	偏差	选中比例
T	1.625	**−4.90**	0.335	0.374	0.571	0.109	+0.137	76.2%
S	0.595	0.208	0.637	0.597	0.629	0.051	+0.104	89.5%
CF*	**0.557**	**0.307**	**0.647**	**0.633**	**0.644**	**0.036**	+0.134	89.6%

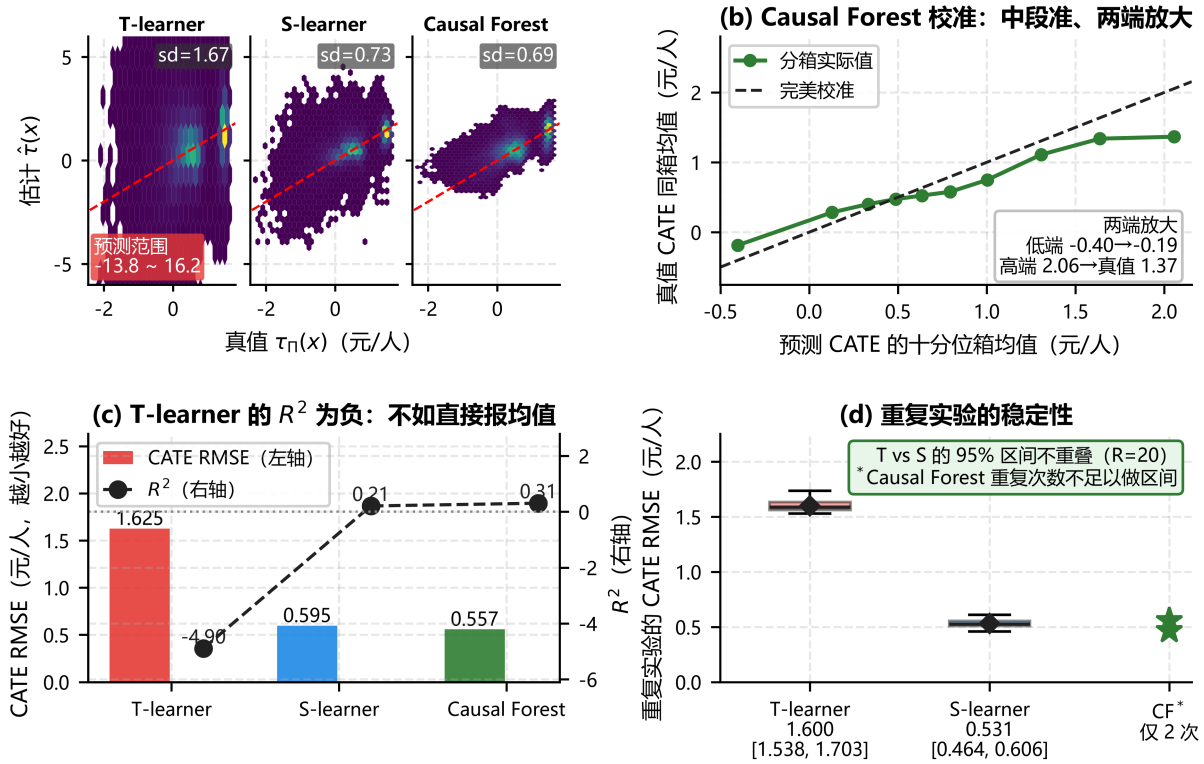
表 4 口径：策略规则为"$\hat{\tau} > 0$ 即投放、无预算约束"（预算约束留给表 7）；regret $= V(\pi^*) - V(\pi)$，π^* 为真值非负策略。

3.5 观察性识别的失效边界

$\lambda = 0$ 时 IPW/DR 的偏差 $|\cdot| \le 0.06$、覆盖率 0.92/0.94，而 naive 偏差 +0.876、覆盖率 0.00；PSM 偏差 −0.061 但覆盖率仅 **0.77**（0.68–0.85）。$\lambda = 0.25$ 时 IPW/DR 偏差 0.15～0.16 元（真值的 1/4），覆盖率降至 **0.82（0.73–0.89）/ 0.79（0.70–0.87）**，Clopper–Pearson 区间上界均低于 0.90。$\lambda = 0.5$ 时 DR 偏差 0.531、覆盖率 0.13；$\lambda \ge 0.75$ 时三种调整法覆盖率全为 0。偏差随 λ 近似线性增长至 3.94～4.42 元（表 5、表 6、图 6）。

表 5　四种观察性方法的偏差随混淆强度的变化（每格 100 次重复，单位：元/人；Naive 的覆盖率在所有 λ 下均为 0）

λ	Naive	PSM	IPW	DR	IPW / DR 覆盖率
0.00	+0.876	−0.061	+0.054	+0.039	0.92 / 0.94
0.25	+0.967	+0.040	+0.160	+0.147	0.82 / 0.79
0.50	+1.300	+0.493	+0.542	+0.531	0.11 / 0.13
0.75	+1.837	+1.142	+1.141	+1.129	0 / 0
1.00	+2.559	+1.987	+1.936	+1.926	0 / 0
1.25	+3.439	+2.991	+2.890	+2.881	0 / 0
1.50	+4.421	+4.047	+3.943	+3.936	0 / 0



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | L1、测试集 60,000 人、按用户切分；真值为解析 CATE，非观测利润差

图 5　三种异质性学习器：同一真值下的还原能力、校准、精度与稳定性

表 6　PSM / IPW / DR 的 95% 区间覆盖率与 Clopper–Pearson 区间（每格 100 次重复；覆盖为 0 的格，区间上界 ≤ 0.04）

λ	PSM 覆盖	IPW 覆盖	DR 覆盖
0.00	0.77 (0.68-0.85)	0.92 (0.85-0.96)	0.94 (0.87-0.98)
0.25	0.76 (0.66-0.84)	**0.82 (0.73-0.89)**	**0.79 (0.70-0.87)**
0.50	0.25 (0.17-0.35)	0.11 (0.06-0.19)	0.13 (0.07-0.21)
0.75	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)
1.00	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)
1.25	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)
1.50	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)	0.00 ($\leq$ 0.04)

$\lambda = 0.5$ 下 IPW 加权后，7 个特征的标准化均值差由 0.05～0.35 全部压到 **0.0038 以下**（历史 GMV 0.354→0.004、购物车金额 0.353→0.003），而同一份数据上 IPW 的偏差为 **+0.542** 元/人（真值 0.629）。

3.6 预算约束下的策略价值

六种策略在同一测试集（6 万人）、同一预算（$B = 10{,}042$ 元）下的结果见表 7 与图 7。定向-贪心选中 15,985 人、人均增量价值 0.349 元（bootstrap 95% CI 0.318–0.384）、每元回报 2.085 元（1.909–2.290）、占真值贪心解 86%（82%–91%）；随机策略（200 个种子）0.122 ± 0.011 元、每元回报 0.730；真值贪心解 0.405 元，其 LP 松弛上界为 0.404745 元/人，与启发式解的 0.404744 只差 1.8×10^{-7}。预算敏感性：定向相对随机的倍数在最紧预算（×0.2）时为 4.55 倍、×3.0 时为 1.67 倍，绝对增益在 ×1.6 达峰（+0.263 元/人）。四参数 ±20% 的 12 个单元全部”定向优于随机”且每元回报 >1（1.57～3.03）。

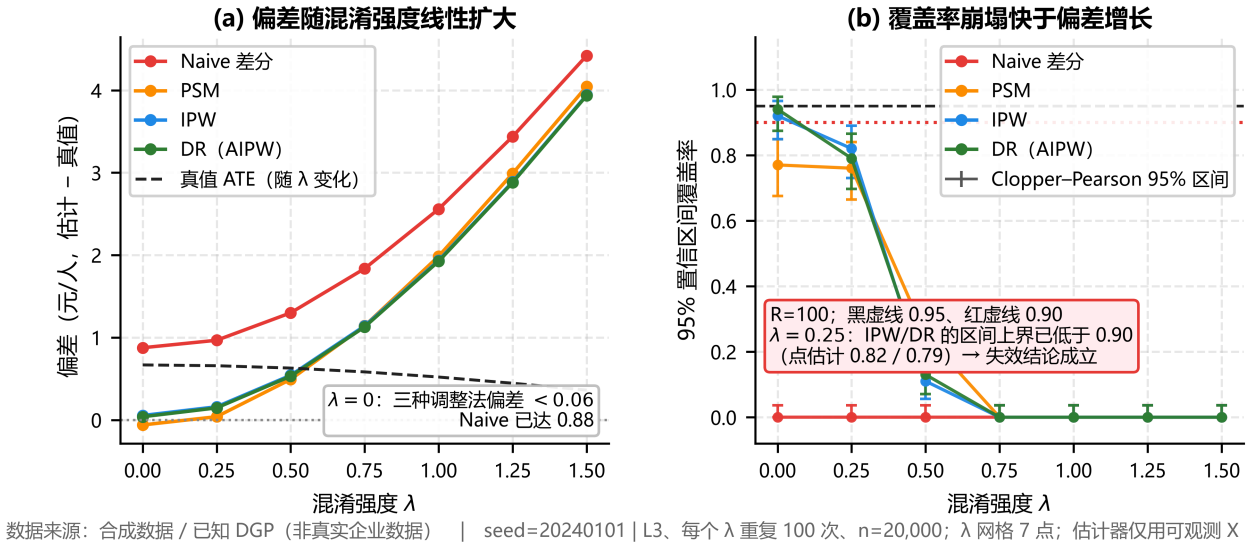


图 6　观察性识别的失效边界：偏差与覆盖率随混淆强度变化

表 7　六种策略在同一测试集（6 万人）、同一预算下的表现（增量价值 = 实现值 $\pi_1 - \pi_0$；人均选中效应 = 解析 $\mathbb{E}[\tau]$；方括号为 95% CI）

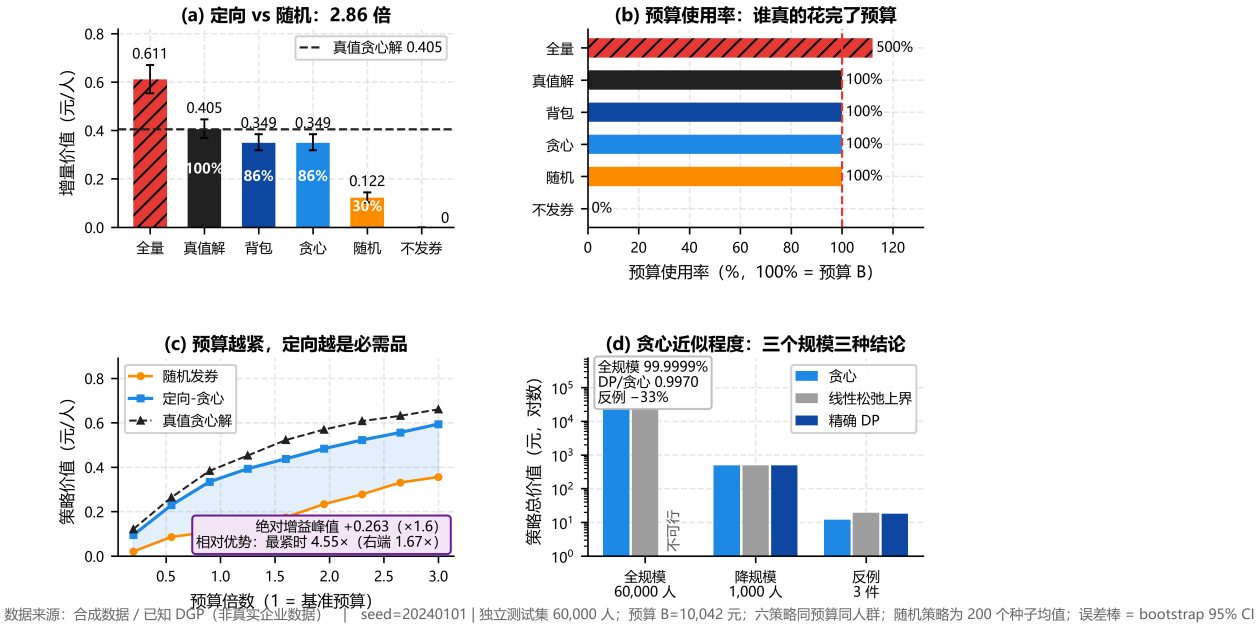
策略	选中人数	实际成本（元）	增量价值（元/人）	人均选中效应（解析）	每元回报	占真值贪心解
不发券	0	0	0.000	—	—	0%
全量发券	60,000	50,210	0.611 [0.553-0.670]	0.664	0.730 [0.661-0.800]	超预算 5 倍
随机（预算 B）	12,000	10,042	0.122 ± 0.011（200 种子）	0.662	0.730 [0.610-0.859]	30% [25-36]
定向-贪心	15,985	10,042	**0.349 [0.318-0.384]**	**1.349**	**2.085 [1.909-2.290]**	**86% [82-91]**
定向-背包	15,985	10,042	0.349 [0.318-0.384]	1.349	2.085 [1.909-2.290]	86% [82-91]
真值贪心解（近似最优）	16,970	10,042	**0.405 [0.369-0.446]**	1.431	2.420 [2.218-2.672]	100%

表 7 口径：增量价值（实现值 $\pi_1 - \pi_0$）0.349 与解析口径（人均选中效应 × 覆盖率 = 1.349 × 15,985/60,000 = 0.359）差 3.0%，小于该行 bootstrap 95% CI 半宽（0.033）；随机行为 200 个种子的均值 ± 标准差，其余行为测试集 500 次 bootstrap 百分位；“真值贪心解” 是用真值 τ 做贪心 + 1-2 交换的启发式解，**不是上界**。

4 讨论

4.1 结果解释

主指标与样本量约束者分离（H1 成立）。利润是首要指标，却不是样本量的约束者：87% 的用户利润为 0，标准差仅 11.08 元，检出 0.5 元/人反比检出 1 个百分点转化更省样本（7,709 对 14,749）。零膨胀把方差压得很低——这不是统计巧合，而是” 多数用户不买” 这类业务的结构性特征，因此” 主指标” 与” 设计约束指标” 必须分开写。翻转临界 0.36 元/人给出了这条边界的可操作位置。



数据来源：合成数据 / 已知 DGP（非真实企业数据） | seed=20240101 | 独立测试集 60,000 人；预算 B=10,042 元；六策略同预算同人群；随机策略为 200 个种子均值；误差棒 = bootstrap 95% CI

图 7 预算约束下的策略价值：六策略对比、预算使用率、预算敏感性与贪心近似程度

策略价值对 RMSE 的弹性很小（H3 成立）。T-learner 的 RMSE 是 Causal Forest 的 2.9 倍（1.625 对 0.557），增量策略价值却只低 11.3%（0.571 对 0.644），因为策略只消费 τ 的**符号与排序**：对真值施加常数平移使 RMSE=5，排序指标仍全为 1。进一步看，Causal Forest 的 RMSE 优势来自**方差更小而非偏差更小**——把 RMSE 分解为" 偏差 ²+ 误差方差"，CF 的偏差 +0.134 比 S-learner 的 +0.104 更大，但误差方差 0.293 比 S 的 0.344 小 15%；它赢在稳定、不赢在准。反向证据同样重要：CF 的非负策略选中 89.6% 的用户，而真值非负比例只有 86.0%，属**过度投放**——策略价值最高不等于预算效率最高。

覆盖率崩塌快于偏差（H2 成立）。$\lambda = 0.25$ 时 IPW/DR 的偏差只有真值的 1/4，覆盖率却已从 0.92/0.94 跌到 0.82/0.79。原因是区间宽度按" 零偏差" 校准：偏差一旦超过标准误的约一半量级，覆盖率就开始系统性偏离名义水平，而偏差在绝对值上仍可能" 看起来很小"。这也解释了为什么 PSM 在 $\lambda = 0$ 就已不合格（0.77，上界 0.85）——它的标准误忽略了对照被重复匹配，属于**区间本身的缺陷**而非混淆所致。一个方法可以" 点估计几乎无偏" 却" 区间完全不可用"。

平衡性诊断全绿与无偏无关。这一发现与 "双稳健需要至少一个模型正确" 的前提直接相关 [5]。$\lambda = 0.5$ 下 IPW 把 7 个特征的标准化均值差全部压到 0.0038 以下，同一份数据上的偏差却是 +0.542 元/人（真值的 81%）。倾向得分只能平衡 X 中存在的变量；U 不在 X 中，它们无能为力 [3]。双稳健也没有提供额外保护：$\lambda \geq 0.5$ 后 DR 与 IPW 差不足 0.02 元，因为 U 同时进入两个模型，"至少一个模型正确" 的前提不成立 [4]。

背包与贪心相同是规模使然而非程序缺陷。全规模下贪心已达线性松弛上界的 99.9999%（"大量小件" 背包的交换论证保证差距不超过单件最大价值），降规模精确 DP 反而因成本离散化低 0.30%；只有 3 件物品的反例里贪心才损失 33%。故背包的价值在于**用 LP 上界证明贪心已足够、并处理少量大额件**，而不是" 多赚多少"。

4.2 原因分析

三条主线的失效模式指向同一个结构性原因：**目标量与实际决策量不是同一个泛函**。转化率是均值、利润是重尾零膨胀变量、策略价值是依赖排序的泛函；用均值的直觉去设计样本量、用 RMSE 的直觉去评价策略、用平衡性去判断无偏，都会在某个环节失配。第二个原因是**不确定性被点估计掩盖**：护栏功效 0.198 时" 通过" 几乎不携带信息；$R = 20$ 的覆盖率格子标准误高达 0.05～0.10，不足以判定失效，$R = 100$ 并配 Clopper–Pearson 区间才够。第三个原因是**口径规范化缺位**：真值贪心解被误称为" 上界"、绝对口径与增量口径混用，都会让数字正确而结论错误。

4.3 理论与实践意义

理论意义：把” 偏差” 从不可观测量变成可核对量，并给出三条可移植的边界结论（约束者分离、覆盖率先崩、平衡性诊断不构成无偏证据）。这三条不依赖本文的具体参数，而是关于” 零膨胀重尾目标 + 区间校准 + 可观测平衡” 的一般性质。

实践意义：给出可执行的决策规则与置信区间——定向发券每元回报 2.08 元（1.91–2.29）、占真值贪心解 86%（82%–91%），且在四参数 ±20% 的 12 个单元里方向稳定；同时给出” 什么时候别信观察性结论” 的操作阈值（$\lambda \geq 0.25$ 即不可信）。对运营侧的一句话是：**预算越紧，定向越是必需品**（最紧预算下定向相对随机 4.55 倍）。

4.4 局限性

范式局限：模拟不能替代真实数据经验；DGP 的共单调耦合让个体效应集中在” 转化增量 + 券成本”，真实世界的效应异质性更复杂。**统计局限**：护栏功效仅 0.198；CATE 重复 20 次、Causal Forest 仅 2 次；λ 扫描样本 2 万、覆盖率标准误约 0.04（已用 Clopper–Pearson 区间显式吸收）。**实现局限**：“背包” 实为贪心加局部改进；DR 未做交叉拟合（若做 DML/交叉拟合，需样本分割与正交矩条件 [9]）；PSM 标准误忽略对照复用；缺失按 MAR 处理。**设定局限**：未做” 面额 × 人群” 联合优化（面额固定 10 元）；未建模溢出与长期效应；策略学习只用到 $\hat{\tau}$ 的符号与排序，未采用 Athey–Wager 式的直接策略优化目标函数 [8]，预算极紧时可能不是最优规则。**失效条件**：网络溢出破坏 SUTVA 使定向收益被夸大；长期效应使 30 天窗口内的增量只是时间平移；退款在 30 天后集中爆发使利润成熟窗口不足；核销率被低估 20% 使实际超支约 25%；面额-效应曲线形状不同时” 每元回报 2.08” 的绝对值失效（排序结论仍成立）。

5 结论

5.1 主要发现

其一，以净增量贡献利润为首要指标、转化率为共同主指标的双指标设计，在 20 万用户、重复 200 次下无偏且区间校准：ITT 偏差 +0.002 元/人、覆盖率 0.950，六个单次估计的 95% 区间全部覆盖解析真值。其二，定向发券相对随机发券的优势约 2.9 倍（0.349 对 0.122 元/人），跨过盈亏平衡线（每元回报 2.085 元，95% CI 1.909–2.290），达真值贪心解的 86%（82%–91%）。其三，观察性调整的失效边界比直觉更早：$\lambda = 0.25$ 时 IPW/DR 覆盖率已降至 0.82/0.79，且此时可观测特征已全部平衡（SMD<0.004）。其四，界值型护栏（退款率非劣效）在本样本量下功效仅 0.198，“通过” 不能当作安全证据。

5.2 研究问题的回答

RQ1：能。定向策略每元回报 2.085 元（CI 下界 $1.909 > 1$），且显著高于随机发券（0.730）。**RQ2**：能给出阈值，且必须用区间判定——$\lambda = 0$ 时仅 IPW/DR 可用，$\lambda \geq 0.25$ 起三者全部不可信（CP 区间上界亦低于 0.90），$\lambda \geq 0.5$ 必须回到实验设计。**RQ3**：不能互相替代。RMSE 差 2.9 倍时策略价值只差 11.3%；平移常数使 RMSE=5 而排序全对；Causal Forest 的 RMSE 优势来自方差而非偏差。**H1**–**H3** 均在本文参数下成立。

建议：把” 是否发券、发给谁” 写成品利润预算约束下的选择问题而不是转化率目标；报不确定性而非点估计（区间、种子分布、CP 区间）；把平衡性诊断当作必要条件而非充分条件；当混淆强度不可排除时，用实验设计（而非更强的调整方法）解决。

5.3 展望：模型遗漏了什么、如何深化、用什么方法

模型相较真实情景遗漏了什么。其一，假定 SUTVA 成立、用户之间无相互影响，而定向发券在社群内会产生干扰；其二，只观测 30 天利润窗口，无法区分” 真增量” 与” 需求提前”；其三，把用户视为静态个体，没有状态转移（浏览 $\rightarrow$ 加购 $\rightarrow$ 首单 $\rightarrow$ 复购）；其四，没有时间维度的反事实趋势，故无法识别动态效应；其五，不建模未观测混淆的动态变化，λ 被当作一次性、静态的参数。

若进一步考虑这些因素，需要怎样深化。时间维度上需新增 L4 面板层（干预前/后各 30 天）；空间维度上需把随机化单位从用户改为社群或城市，并定义 exposure mapping；时间窗维度上需把观测窗延长到 90～180 天并建模留存曲线；状态维度上需把用户状态空间定义为" 浏览 → 加购 → 首单 → 复购"，并先检验马尔可夫性。

用什么方法探究。时间维度用双重差分 / 事件研究 / 合成控制（本文三条件中" 未受干预对照组" 与" 可检验平行趋势" 不满足，故不做；补齐需两期面板 + 城市级整群随机 + 概率尺度平行趋势，并用事件研究图逐期检验）；空间维度用网络溢出与 exposure mapping、整群随机、两阶段随机化；时间窗维度用长期 LTV、留存曲线与生存分析；状态维度用马尔可夫链 / 状态转移矩阵 / 隐马尔可夫模型。

这些不是" 不会做"，而是**在现有数据约束下做不出可信的因果结论**：DID 需要两期面板与未受干预的对照城市，网络溢出需要社群级随机化与 exposure 定义，LTV 需要 90～180 天的真实观测，马尔可夫链需要以月计的多期状态面板。现有数据（单期、用户级随机、30 天窗口、无状态序列）支撑不了其中任何一项，硬做只会把假设当成结论。

参考文献

[1] Imbens G W, Rubin D B. Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction[M]. Cambridge University Press, 2015.

[2] Angrist J D, Pischke J S. Mostly Harmless Econometrics: An Empiricist's Companion[M]. Princeton University Press, 2009.

[3] Rosenbaum P R, Rubin D B. The central role of the propensity score in observational studies for causal effects[J]. Biometrika, 1983, 70(1): 41-55.

[4] Robins J M, Rotnitzky A, Zhao L P. Estimation of regression coefficients when some regressors are not always observed[J]. Journal of the American Statistical Association, 1994, 89(427): 846-866.

[5] Bang H, Robins J M. Doubly robust estimation in missing data and causal inference models[J]. Biometrics, 2005, 61(4): 962-973.

[6] Künzel S R, Sekhon J S, Bickel P J, Yu B. Metalearners for estimating heterogeneous treatment effects using machine learning[J]. Proceedings of the National Academy of Sciences, 2019, 116(10): 4156-4165.

[7] Wager S, Athey S. Estimation and inference of heterogeneous treatment effects using random forests[J]. Journal of the American Statistical Association, 2018, 113(523): 1228-1242.

[8] Athey S, Wager S. Policy learning with observational data[J]. Econometrica, 2021, 89(1): 133-161.

[9] Chernozhukov V, Chetverikov D, Demirer M, et al. Double/debiased machine learning for treatment and structural parameters[J]. The Econometrics Journal, 2018, 21(1): C1-C68.

[10] Kohavi R, Tang D, Xu Y. Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing[M]. Cambridge University Press, 2020.

[11] Hillstrom K. The MineThatData e-mail analytics and data mining challenge[DS]. 2008.

[12] Morris T P, White I R, Crowther M J. Using simulation studies to evaluate statistical methods[J]. Statistics in Medicine, 2019, 38(11): 2074-2102.

附录 A　关键参数表

（参数名省略配置段前缀：`business.` / `windows.` / `experiment.` / `budget.` / `dgp.`）

表 A1　关键参数表（取值与其业务依据）

参数	取值	业务依据
`baseline_conversion`	0.10	加购未支付用户历史首单转化率（行业 8%～12% 的中值）
`coupon_max_effect`	0.15	券对转化率的最大提升（概率尺度上限，硬约束 $p_0 + \tau \leq 1$）
`coupon_face_values`	5 / 10 / 15 / 20 元	平台现行券档位；参考面额取 10 元，饱和曲线尺度 12.0
`redemption_rate`	0.55	券核销率（同类券历史核销率 40%～70%）
`refund_rate`	0.075	类目历史退款率（5%～10%），同时是护栏指标基线
`goods_cost_ratio`	0.68	商品成本率（毛利率 25%～40% 对应成本率 60%～75%）
`fulfill_cost_mean`	5.0 元/单	配送 + 仓储 + 包材；**不可回收**，退款后仍发生
`aov_mean`	120 元	加购未支付用户首单客单价
`refundable_goods_ratio`	0.85	退款后可回收商品成本比例；退款手续费率 0.01
`convert_days` / `profit_days`	7 / 30 天	转化观察窗与利润成熟窗；两窗口必须分开且等长（R2）
`mde.conversion_abs`	1 个百分点	0.10→0.11 的相对提升 10%，低于此不足以支撑一次改版
`mde.profit_per_user`	0.5 元/人	= 总预算 100,000 元 / 20 万合格用户的盈亏平衡尺度
`mde.profit_sd_assumed`	11.08 元	**实测** sd(人均净贡献利润)（含复购路径，87% 为 0）
`coverage_target`	0.20	试点投放覆盖 20% 合格用户；实际预算 $B = 0.20 \sum_i c_i$
`repeat.prob` / `value_ratio`	0.05 / 0.55	30 天窗口内复购率 4%～6% 的中值；复购客单价为首单的 55%

附录 B　复现方式与可复现性等级

一条命令：`python scripts/run_all.py --round all`（需先 `$env:PYTHONUTF8='1'`）；随后 `python scripts/06_manifest.py` 生成哈希清单。单测：`python -m pytest tests -q`，**404 项全部通过**。

可复现性等级：同机同版本完全可复现。所有随机性由 `(project.master_seed=20240101, stream, index)` 三元组派生，同一三元组必然产出同一串随机数；配置快照与环境信息写入 `outputs/runs/<run_id>/meta.json`。浮点结果在不同 BLAS / pandas / numpy 版本上可能差最后几位，因此本文**不声称" 逐字节一致"**，而是提供可核对的 **SHA256 清单** `outputs/SHA256SUMS.txt`（64 个文件：43 张结果表、7 张图、配置与数据表），审稿人可自行重算比对。

附录 C　数据字典与 SQL 对象清单

表 C1　五张关系表的关键字段与口径

表（行数）	关键字段与口径
`users`（200,000）	user_id 主键、is_new、reg_date、channel、hist_gmv、cart_value_at_assign（脏数据层注入 MNAR 缺失）、browse_depth_7d
`user_events`（1,201,121）	user_id、event_type（page_view / add_to_cart）、**event_time（统计口径）**、sku_id、ts_ingested（受上报延迟影响，不作统计）
`coupon_assignment`（200,000）	exp_id、user_id（**每用户仅一行**）、group、coupon_value、assign_time（两窗口共同起点）
`orders`（26,471）	order_id、user_id、order_time、pay_amount、refund_amount、goods_cost、fulfill_cost、coupon_used、coupon_value、refunded、refund_time；**退款单保留** 2,053 行、复购第二单 1,256 行
`user_outcomes`（400,000）	user_id、window_type（convert_7d / profit_30d）、converted、gmv、net_profit（7 天为 NULL）、refunded

6 个视图：`v_order_profit`（逐单五项成本分列：收入冲减、退款手续费 1%、商品成本按 85% 可回收率冲减、履约成本刚性、券成本仅核销未退券时计入）、`v_order_net`（逐单净贡献利润，券成本只减一次，**R3**）、`v_user_profit`（以分配表为驱动表 LEFT JOIN，未下单记 0，多单按 `SUM` 聚合，**R1**）、

`v_order_window`（按各自分配时点算 `elapsed_days`，**R2**）、`v_outcome_convert`（7 天转化窗，利润列强制 NULL，**R2**）、`v_outcome_profit`（30 天利润成熟窗，覆盖支付/退款/成本结算，**R2**）。

19 条命名查询：口径派生 5（事件去重、浏览深度、逐单利润、用户级利润、双窗口合并）、业务看板 5（分组 ITT、ITT 差值、渠道漏斗、新老客对比、日汇总）、**质量闸门 9**（重复上报、孤儿订单、重复分配、窗口完整性、转化窗口利润为空、退款单保留、对照组持券、事件越界、分流比例）。闸门与 SQL 单测跑同一批数据，违反即抛错。

附录 D　数据版本与数字变更记录

为什么引入 v2。第一轮独立审稿的意见 B7 指出：v1 的 DGP **每个用户恰好一单**，于是 SQL 视图 `v_user_profit` 里写 `MAX(coupon_cost)` 还是 `SUM(coupon_cost)` 在数据上完全等价—— 那条真实存在的 `MAX` bug 因此在 9 条闸门与 20 项 SQL 单测下**全部通过**（见复盘 §2.4）。“当前数据恰好不触发” 不等于” 代码正确”。v2 因此在 DGP 里加入复购路径：已下单用户在 30 天窗口内以 5% 的概率产生第二单（客单价为首单的 55%、第二单不带券），共 **1,256 笔**复购订单，订单表由 25,215 行增至 **26,471 行**。每用户可能 0/1/2 单，“`SUM` vs `MAX`” 这一形态才第一次可被观测到，“用户级利润 = 各单利润之和” 的写法也才真正被数据检验（两单用户下逐用户利润最大差由 0.0146 元增至 0.026 元，仍在按分存储的舍入上限内）。

v1 → v2 映射。表 D1 列出所有对外引用过的关键数字。变化**全部**来自 DGP 变更—— 估计方法、识别策略、评估口径与代码路径均未改动。除” 测试数” 一行外，每一行的 v2 列都能在 `outputs/tables/*.csv` 里找到对应单元格（最后一列给出出处）。

表 D1　v1（无复购）与 v2（含复购路径）的关键数字对照

指标	v1	v2	出处（v2）
真值 ATE 利润（元/人）	0.633	**0.668**	`r1_itt.csv` 真值（L1）
ITT 利润估计（元/人）	0.678	**0.724**	`r1_itt.csv` ITT 估计（L1）
利润 σ（元/人）	10.79	**11.08**	`r1_sample_size_inputs.csv`
利润支 n_per_group	7,324	**7,709**	`r1_sample_size.csv`
定向每元回报（元）	1.97	**2.085** [1.909, 2.290]	`r3_six_strategies_ci.csv`
定向 / 随机（倍）	2.56	**2.86**	`r3_six_strategies.csv`
达真值贪心解	84.9%	**86.1%** [81.6%, 91.2%]	`r3_six_strategies_ci.csv`
策略价值：定向（元/人）	0.3302	**0.3489**	`r3_six_strategies.csv`
策略价值：随机（元/人）	0.1290	**0.1222**	`r3_six_strategies.csv`
真值贪心解价值（元/人）	0.3892	**0.4050**	`r3_six_strategies.csv`
CATE R^2（Causal Forest）	0.333	**0.307**	`r2_cate_comparison.csv`
CATE RMSE（Causal Forest）	0.537	**0.557**	`r2_cate_comparison.csv`
$\lambda = 0.5$ 时 IPW 偏差（元/人）	0.465	**0.542**	`r2_lambda_summary.csv`
$\lambda = 0.25$ 时 IPW / DR 覆盖率	0.85 / 0.80	**0.82 / 0.79**	`r2_lambda_summary.csv`
重复 200 次利润覆盖率（L0/L1）	0.945 / 0.955	**0.950 / 0.950**	`r1_repeats_summary.csv`
AA 假阳性率（转化 / 利润）	0.059 / 0.051	**0.059 / 0.040**	`r1_aa_summary.csv`
人均 GMV（对照 / 处理，元）	12.07 / 18.11	**12.38 / 18.62**	`r1_auxiliary.csv`
订单表行数	25,215	**26,471**	`r1_quality_clean.csv`
测试数	400	**404**	`pytest` 输出

一句结论。 DGP 迭代导致数字变化是正常的、也是可取的——它是” 发现数据形态覆盖不足” 之后的正确反应；**不标注版本才是问题**。同一个项目里并存两套数字、却不说明哪一套对应哪个 DGP，读者无从判断哪个结论成立。因此本文此后所有数字只对应 v2，旧值仅在本表出现。文档层面的落地方式是：每份文档顶部标注数据版本 + 本映射表 + `scripts/07_check_consistency.py`（从 CSV 读关键数字、扫描全部文档，发现旧值即非零退出）。